

PROYECTO

Automatización de SaaS

SaaSphere



CICLO FORMATIVO DE GRADO SUPERIOR

Administración de Sistemas Informáticos en Red



I.E.S. «Venancio Blanco» SALAMANCA

AUTOR

ÁNGEL MARTÍN QUERO

TUTOR

MARÍA DEL CARMEN PÉREZ VÁZQUEZ

Licencia

Esta obra está bajo una licencia Reconocimiento-Compartir bajo la misma licencia 3.0 España de Creative Commons. Para ver una copia de esta licencia, visite <http://creativecommons.org/licenses/by-sa/3.0/es/> o envíe una carta a Creative Commons, 171 Second Street, Suite 300, San Francisco, California 94105, USA.



Resumen

¿Qué es SaaSphere?

Es una plataforma de infraestructura distribuida y multitenant desplegada sobre hardware propio (nivel usuario), diseñada para ofrecer servicios web gestionados a pequeñas y medianas empresas como alternativa a las agencias tradicionales y a los proveedores cloud de pago. Su diferenciador principal es un agente de inteligencia artificial LeIA (Openclaw) que opera la infraestructura de forma autónoma, observa el estado del clúster, razona sobre él y ejecuta o propone acciones sin intervención humana constante.

Arquitectura

El ecosistema de SaaSphere cuenta con cinco nodos, sobre Vmware ESXI, todos basados en Debian 13: LeIA: Nodo baremetal con capacidad de computo para ejecutar LLM locales, openclaw de forma nativa siendo el cerebro del sistema.

Matrix: Registro de contenedores, ingress del trafik con HTTPS automático, lets Encrypt, aquí se ejecutan los servicios web.

Sauron: Stack de monitoreo completo, con diversas aplicaciones que usaran tanto los operadores, como la propia IA para analizar las métricas.

Heimdall: Puerta VPN, brinda acceso remoto seguro

Fallback: Nodo K3s con NoSchedule, se activará via OpenClaw ante caída del nodo principal.


Funcionamiento

LeIA solo es una IA que toma decisiones, k3s es el ejecutor, tiene ciertas tareas determinadas con anterioridad y muchos límites de ejecución, está programado en Python, lee las métricas de prometheus, los logs de Loki, razona usando un modelo más potente, pero mucho mas lento.

Actúa solo dentro de los niveles de autonomía previamente definidos, las acciones irreversibles conllevan una aprobación humana, todas las decisiones quedan registradas, y todas las acciones, outputs...

¿Por qué este proyecto?

Todo el mundo siempre busca la IA más inteligente, la que tenga mayor capacidad de cómputo... pero yo considero que eso no debe ser así, me he basado en el dicho de “hasta un niño puede hacerlo”, por lo tanto, he pensado que una IA con la mínima potencia que puede haber, es capaz de gestionar un sistema completo, diciéndole que debe hacer, cuando y como, todo eso es información que yo le he brindado a LeIA para que pueda trabajar, programando sus posibilidades, scripts que puede usar, bases de datos de registro... con Claude Code, una IA mucho más inteligente, pero MUY cara.



Dicho de otra manera, “Un tonto le ha dicho a un listo que hacer”, el tonto sigue siendo tonto, pero si le dicen “haz un Backup”, y lo próximo que encuentra es una herramienta llamada “Backup”, hasta sin saber que es un “Backup” vas a poderlo hacer.



Índice de contenido

Tabla de contenido

.....	1
Licencia.....	2
Resumen.....	3
Índice de contenido.....	4
Índice de figuras.....	6
Introducción	7
Necesidades Del Sector Productivo	8
Análisis de la situación actual.....	8
Barreras detectadas	8
Tipos de clientes	9
Análisis de la competencia:.....	9
SaasPhere vs la competencia.....	10
Ventajas.....	10
Desventajas	10
Conclusión del análisis.....	10
Obligaciones fiscales, laborales y de prevención de riesgo	11
Modelo de ventas	12
Precio	12
Costes	13
Margen.....	14
Rentabilidad.....	14
Ayudas/subvenciones:.....	15
Conclusión de las ayudas.....	15
Diseño del proyecto	16
1. Requisitos y restricciones	16
1.1. Requisitos funcionales	16
1.2. Requisitos no funcionales.....	17
1.3. Restricciones del proyecto.....	18



2.	Decisiones de diseño	18
2.1.	K3s frente a kubernetes.....	18
2.2.	Ollama frente a API externa.....	18
2.3.	Sistema de monitorización	18
3.	Arquitectura	19
3.1.	Visión general	19
3.2.	Nodos Físicos	19
3.3.	Estructura por capas	20
4.	Modos de funcionamiento.....	21
4.1.	Funcionamiento normal.....	21
4.2.	Funcionamiento degradado	21
4.3.	Prioridad de restauración.....	21
	Implementación.....	22
1.	Fase 1 – Preparación de hardware → 3H	22
a.	Instalación y configuración básica.....	22
b.	Pruebas	23
2.	Fase 2 – Entorno virtual en ESXI → 3H	23
a.	Instaladas Heimdall Sauron y Matrix	23
b.	Asignadas IP estáticas	23
c.	Habilitados y configurados servicios básicos:.....	23
d.	Pruebas	24
3.	Fase 3 – Configuración de red VPN → 1 día	25
a.	Instalar Wireguard	25
b.	Configurar archivos de configuración	25
c.	Abrir puertos necesarios.....	26
d.	Pruebas	27
4.	Fase 4 – servicios de monitorización → 1 semana	28
a.	Despliegue de prometheus, Grafana y Loki.....	28
b.	Pruebas	30
5.	Fase 5 – Orquestación de contenedores → 1 semana	35
a.	Configuración K3s	35
b.	Pruebas	37
6.	Fase 6 – Fallback → 1 día.....	38
a.	Seguridad	38
b.	Confianza con registro	38
c.	Incorporación al clúster	39



d. NoSchedule taint.....	39
7. Fase 7 – Despliegue de LeIA → 2 / 4 semanas	40
a. Fase 1: Esqueleto	40
b. Fase 2: Cliente Ollama y agente base	41
c. Fase 3: Tools de lectura	43
d. Fase 4: Aprobación por telegram	46
e. Fase 5: Tools	47
f. Fase 6: Triggers, scheduling y reactividad	55
g. Fase 7: Observabilidad y trazabilidad	55
h. Fase 8: SSH controlado	62
i. Fase 9: Hardening y resiliencia.....	62
j. Fase 10: Demo/pruebas	¡Error! Marcador no definido.
8. Fase 8 – Pruebas generales→ 2 semanas.....	62
Mayores dificultades	66
Dificultad 1	71
Diseño Del Proyecto	¡Error! Marcador no definido.
Pruebas	¡Error! Marcador no definido.
Definición De Procedimientos De Control Y Evaluación	¡Error! Marcador no definido.
Fuentes	73
Anexos	74

Índice de figuras

Ilustración 1 - SaaSphere.....	7
--------------------------------	---



Introducción



III

Este documento responde a la realización del módulo de Proyecto del CFGS en Administración de Sistemas Informáticos en Red. El módulo de Proyecto complementa, la formación establecida para el resto de los módulos profesionales que integran el título en las funciones de análisis del contexto, diseño del proyecto y organización de la ejecución.

Hoy en día, muchos autónomos y empresas carecen de presencia en internet, y en muchos casos esto se debe al gran coste inicial que supone el desarrollo de una web, y a no tener los conocimientos necesarios para estructurar una web, monitorizarla ni mantenerla.

De esta situación, nace SaaSphere, una empresa ficticia orientada a la creación de servicios y aplicaciones web de manera integral, desde la compra del dominio, hasta el alojamiento, en modalidad de SaaS. Todo esto se realiza mediante una suscripción mensual, eliminando así esa inversión inicial por parte del cliente, permitiendo a todos acceder a estos servicios, sin conllevar ningún cargo de gestión técnica de la infraestructura para el contratador.

El objetivo principal del proyecto es diseñar e implementar la infraestructura técnica necesaria para soportar este servicio propuesto para SaaSphere, para lo cual se empleará una arquitectura modular basada en contenedores Docker orquestados mediante K3s, distribuidos en varios nodos físicos y virtuales. La infraestructura incorporará tecnologías como: Nginx, WireGuard, Prometheus, ollama y nemoclaw, con un nodo especializado en la inteligencia artificial para la automatización del mantenimiento y el análisis del sistema.

La diferencia de SaaSphere frente a cualquier otra empresa proveedora de servicios similares, es la amplia implementación de la inteligencia artificial, automatizando soporte y mantenimiento, pudiendo crear tareas rutinarias de forma autónoma.

A lo largo del documento se detallan el análisis del sector, el diseño de la arquitectura, las de implementación y la validación del sistema, incluyendo reuniones con clientes tanto simulados como reales para demostrar la efectividad de la propuesta.

Necesidades Del Sector Productivo

A continuación, se identifican las necesidades detectadas en el sector productivo que originan la oportunidad de negocio que se detalla en los siguientes puntos.

Análisis de la situación actual

Se ha realizado un análisis del nivel de digitalización empresarial en España, y se aprecia que las empresas grandes suelen tener web, aproximadamente el 84,5% de estas, mientras que las grandes pymes, aproximadamente el 65% también tienen, el dato se reduce en pequeños negocios con menos de 10 empleados, que solo el 50% tiene página web, y los autónomos, solo el 25 % de ellos tienen página web.



Tabla 1 - Analisis de la situación

Ilustración 2 - Grafico 1

Tipo de empresa	Peso en España	% con web	% sin web	Contribución % sin web
Grandes empresas	0.2 %	84,5 %	15,5 %	0,31 %
Pymes (10-250 trabajadores)	4.6 %	65 %	35 %	2,80 %
Empresas < 10 trabajadores	41.6 %	50 %	50 %	17,50 %
Autónomos	53.6 %	25 %	75 %	41,25 %
Total	100 %	—	—	61,86 % sin web

Por lo tanto, en base al nº de autónomos, pymes y grandes empresas, actualmente **61,86%** no tiene web.

A continuación, analizamos los problemas que han dado lugar a estos datos.

Barreras detectadas

Coste: El coste inicial de los servicios web tradicionales es muy alto, superando los miles de euros, suponiendo un gran desembolso de dinero para las pequeñas empresas y autónomos que busquen tener un servicio web, ya sea una aplicación o una página estática.

Falta de conocimientos técnicos: El desconocimiento provoca miedo de entrar a nuevos tipos de servicios, ya que no saben cómo funcionan, ni cómo gestionarlo.

La costumbre: Muchas empresas llevan toda la vida viviendo “del boca a boca”, cosa que funciona, pero no permite que se den a descubrir tanto como podrían.

Experiencias negativas: Muchas empresas han perdido tiempo y dinero gracias a proveedores que no les han podido dedicar todo el tiempo que ellos necesitaban.

Desconfianza: Los perfiles menos familiarizados con las nuevas tecnologías, tienen cierta desconfianza del funcionamiento y de la utilidad de este tipo de servicios.

Estos son todos los problemas que se presentan a la hora de establecer el contacto con un cliente, todo depende del tipo de empresa o particular que se le ofrezca el servicio.

Más adelante se desarrolla la forma de abordar las barreras detectadas.

Tipos de clientes

Se han separado los tipos de cliente en función al tamaño de la empresa, haciendo un estudio de que solución se adapta más a cada uno en la mayoría de los casos.

Autónomos: La mayor parte de los clientes potenciales son autónomos, contribuyen el 53,6% del [tejido empresarial español](#), siendo aproximadamente 1.600.000 autónomos, tienen un presupuesto limitado y necesitan algo sencillo y funcional, para poder hacer un primer contacto con sus clientes.

Pymes: constituyen el 46,2% del tejido empresarial, aproximadamente 1.300.000 empresas, cuentan con un mayor presupuesto, pero sus necesidades varían, muchas siguen sin contar con una página web y necesitan funcionalidades específicas en función a su sector.

Grandes empresas: el 0.2% del tejido empresarial, que son 6.035 empresas, pertenece a las grandes empresas, la inmensa mayoría cuentan con una página web, existe un pequeño porcentaje que puede no tener porque siempre trabaje con los mismos clientes y consideren que no es necesaria, pero no serán los clientes principales

Análisis de la competencia:

Se va a basar el análisis basándolo en varias empresas de la competencia, estas son: La Teva web, apiumhub y tallium inc.

La teva web: Es una empresa con sede en Barcelona, muchos años de experiencia y con un gran equipo detrás, hacen diseño web y trabajan sobre todo con WordPress, tienen reconocimientos como “la mejor agencia de marketing digital de Barcelona”.

Emplean content managers como: wordpress, shopify o prestashop.

Sus precios parten desde los 2.940€.

Su valoración en Google es de un 4.7/5

Apiumhub: Es un hub tecnológico que se especializa en DevOps, automatización, desarrollo web y arquitectura de software. Usan las tecnologías más modernas y han colaborado con grandes marcas, tienen fama por hacer arquitecturas escalables.

Usan tecnologías como react, Swift o kubernetes.

Sus tarifas oscilan entre los 15.000€ y los 20.000€ por proyecto.

Su valoración en Google es de un 4.8/5

Tallium INC: Es una gran empresa a nivel internacional y trabajan de manera 100% remota, se especializan en aplicaciones web y en el sector de la tecnología, usan tecnologías emergentes como la IA y la realidad virtual.

Usan React, node, flutter e incluso VR/AR.

Tienen un precio mínimo de 10.000€ solo desarrollan software específico para grandes empresas.

Su valoración en Google es de un 4.8/5

SaaSPhere vs la competencia

Ventajas

- Velocidad de despliegue: gracias a la cooperación con la inteligencia artificial SaaSPhere es capaz de generar las webs y ponerlas en producción en tiempo récord, sin la necesidad de largas esperas después de que el cliente realice las correcciones que necesite frente a las propuestas de la empresa.
- Accesibilidad: El precio de SaaSPhere frente al de la competencia es mucho mejor, por lo que todas las pequeñas empresas que no pudiesen permitirse una web, pero si la necesitasen, acudirán a SaaSPhere
- Soporte: El soporte técnico de SaaSPhere está mediante inteligencia artificial, por lo que responde rápido ante incidencias y de manera automática
- Coste inicial: Debido a ser modelo SaaS, no necesita una gran inversión inicial.

Desventajas

- No existe una reputación real de la empresa SaaSPhere
- Equipo unipersonal al inicio
- El código es y será propiedad de SaaSPhere
- Dependencia de un pago mensual del cliente.

Conclusión del análisis

Tras analizar el mercado actual de desarrollo y alojamiento web, se observa una tendencia clara: las empresas establecidas del sector se orientan hacia proyectos de alto presupuesto, con precios de entrada que oscilan entre los 2.000€ y los 20.000€ por proyecto, dirigiéndose principalmente a medianas y grandes empresas con capacidad de inversión inicial elevada.

Este enfoque deja desatendido un segmento amplio y en crecimiento: autónomos, microempresas y pequeñas pymes que necesitan presencia digital pero no pueden asumir una inversión inicial de esa magnitud, ni disponen de los conocimientos técnicos para gestionar su propia infraestructura web.

SaaSPhere se posiciona precisamente en ese hueco, ofreciendo un modelo de suscripción mensual que elimina la barrera de entrada económica y traslada toda la responsabilidad técnica al proveedor. A esto se suma la automatización mediante inteligencia artificial como elemento diferenciador real frente a la competencia, permitiendo tiempos de respuesta ante incidencias prácticamente inmediatos, mantenimiento continuo sin intervención manual y una disponibilidad del servicio que las agencias tradicionales no pueden garantizar con equipos humanos de tamaño reducido.

No obstante, SaaSPhere presenta limitaciones propias de una empresa en fase inicial: ausencia de historial demostrable, infraestructura hardware con capacidad limitada y un equipo unipersonal. Estas limitaciones condicionan el tipo de proyectos que puede abordar, quedando fuera del alcance actual los desarrollos de alta complejidad técnica o los clientes de gran escala.

En conclusión, SaaSPhere no compite directamente con las grandes agencias del sector, sino que cubre una necesidad que estas no atienden, con un modelo de negocio más accesible, un soporte más ágil y una automatización que reduce estructuralmente los costes operativos.

Obligaciones fiscales, laborales y de prevención de riesgo

Este negocio, es una actividad económica que, en un principio, realizaría yo solo, mientras no necesitase contratar más empleados, por lo que lo planteare de esa manera, sin empleados.

- Debemos de estar dados de alta en hacienda bajo el modelo 037, indicando nuestro inicio de la actividad.
- Debemos hacer la declaración del IVA.
- La declaración del IRPF.
- Llevar los libros de la contabilidad.
- Emitir facturas de nuestros servicios.
- Declarar operaciones con terceros bajo el modelo 347.

Riesgos laborales:

- Plan de prevención donde se definan las medidas de seguridad.
- Formación básica en prevención
- Condiciones ergonómicas en el puesto de trabajo.
- Seguridad eléctrica.
- Protección contra incendios, con énfasis en las salas con equipos informáticos.
- Cumplir normativa de protección de datos.



Modelo de ventas

Todos los precios, costes y materia económica, son calculadas en un contexto “real”, de lo que se debería adquirir bajo un punto de vista personal.

En caso de querer llevar a cabo esta actividad, el hardware real en el que se ha realizado el proyecto no cumple con los requisitos de seguridad ni de disponibilidad que debería de otorgar un servicio como este.

Se ha calculado para este hardware en la nube, de características similares al del proyecto.

Precio

Se han definido 3 tipos de producto que se van a ofertar, junto a 3 niveles de soporte que se hará a los clientes, esto forma 9 ofertas diferentes que se seleccionarán en función a las necesidades del cliente.

Productos:

- **Landing Page:** Web estática, una sola página orientada, con Dominio, SSL, formulario de contacto, y con diseño responsive.
- **Web Corporativa:** Todo lo anterior, más varias páginas diferentes, con blog de noticias gestionable por el cliente desde CMS sencillo, galería, múltiples formularios... y personalización frontend completa para el cliente, adaptada a sus necesidades.
- **Web con gestión de usuarios:** Todo lo anterior, más registro/login, area privada, gestión de contenido por cada perfil (por ejemplo, diferenciar entre usuarios por países). Puede ser una página interna, tienda online, gestión de reservas (con coste extra por conexión con CRM).

Niveles de soporte:

- **Basic:** Monitorización automática, alertas, reinicio automático de servicios. Sin intervención humana.
- **Standard:** Lo anterior, más tiempo de respuesta a incidencias menor a 4h en horario laboral, 3 cambios menores incluidos en el pack.
- **Premium 24/7:** Lo anterior, más respuesta fuera de horario, cambios menores ilimitados, informes mensuales, reunión trimestral y métricas ampliadas.



Pack con precios	Basic	Standard	Premium 24·7
Landing Page	59 €/mes	89 €/mes	129 €/mes
Web Corporativa	99 €/mes	149 €/mes	199 €/mes
Web con usuarios	179 €/mes	249 €/mes	349 €/mes

Costes

Infraestructura realista

Servidor	Rol	Especificaciones	Coste
VPS Principal	K3s + Traefik + Registry	4 vCPU, 8GB RAM, 80GB SSD	~15 €/mes
VPS Monitorización	Prometheus + Grafana + Loki	2 vCPU, 4GB RAM, 40GB SSD	~8 €/mes
VPS Fallback	K3s agent de respaldo	2 vCPU, 4GB RAM, 40GB SSD	~8 €/mes
Total VPS			31 €/mes

IA en producción

Depende de para que proceso, se debería de usar un modelo u otro, para ciertos razonamientos GPT-5.5 / Claude Opus 4.7, y para ejecuciones GPT-5.4 / Claude Sonnet 4.6

Modelo	Input (\$ / 1M tokens)	Output (\$ / 1M tokens)	Comentario
GPT-5.5	5.00	30.00	Máxima capacidad, más caro en output
Claude Opus 4.7	5.00	25.00	Más barato en output
GPT-5.4	2.50	15.00	Muy equilibrado
Claude Sonnet 4.6	3.00	15.00	Algo más caro en input
GPT-5.4 mini	0.75	4.50	Muy barato y eficiente
Claude Haiku 4.5	1.00	5.00	Alternativa barata

Servicios fijos

Concepto	Coste
Almacenamiento backups (Hetzner S3)	~5 €/mes
CDN (Cloudflare)	0 € (tier gratuito)
Software de facturación	~15 €/mes
Cuenta max de Claude para desarrollo web	900€/mes
Cuenta pro de ChatGPT para creación de imágenes y desarrollo	103€/mes
API IA para automatización en LeIA (aprox en base a los precios de arriba)	100€/mes
Cuota autónoma (año 1)	80€/mes
Total:	424€/mes



Coste por cliente

Concepto	Tipo	Importe
Configuración y despliegue inicial	One-time	~100 €
Dominio del cliente	Variable mensual	~1 €/mes
Recursos VPS proporcionales	Variable mensual	~2 €/mes
Total variable recurrente		~3 €/mes
Coste total primer año por cliente		~136 €

**Margen**

Se ha calculado teniendo en cuenta un cliente con cada tipo de contrato que se ofrece en SaaSphere.

Producto + Soporte	Precio	Coste variable	Margen bruto	% Margen
Landing · Basic	59 €	3 €	56 €	95%
Landing · Standard	89 €	3 €	86 €	97%
Landing · Premium	129 €	3 €	126 €	98%
Corporativa · Basic	99 €	3 €	96 €	97%
Corporativa · Standard	149 €	3 €	146 €	98%
Corporativa · Premium	199 €	3 €	196 €	98%
Usuarios · Basic	179 €	3 €	176 €	98%
Usuarios · Standard	249 €	3 €	246 €	99%
Usuarios · Premium	349 €	3 €	346 €	99%

Rentabilidad

Se calcula la rentabilidad en base a 9 clientes el primer año, que es un numero viable para el servicio ofrecido.

Concepto	Mensual	Anual
Ingresos	1.170 €	14.040 €
Costes variables (9 × 3 €)	27 €	324 €
Costes fijos	424 €	5.088 €
Beneficio neto	719 €	~8.628 €



Ayudas/subvenciones:

- Kit digital.

Esta ayuda depende de muchos aspectos, en el nuestro nos puede dar una financiación de hasta 2000€ debido a que como he comentado, me gustaría empezar la empresa por mi cuenta, y si fuera necesario, contratar gente más adelante, pero al ser autónomo la ayuda es de hasta 2000€.

Se emplearía la ayuda para invertir en “*Business intelligence*”. He considerado que la cantidad dinero no es suficiente para invertir en infraestructura, por lo que prefiero invertirlo en métricas y datos para analizar el negocio y ver en qué sectores y aspectos se está vendiendo más, por ejemplo:

Usar aplicaciones como Fabric (Microsoft) para analizar los datos de las ventas, descubrir en que comunidades autónomas estamos generando más ventas, en función al tipo de cliente, y así focalizar las llamadas por zonas para maximizar las ofertas efectivas.

Esta inversión es más importante de lo que parece, ya que conocer el mercado es lo más importante, y previo al lanzamiento podemos hacer estimaciones basadas en estudios, pero una vez empezemos, analizando nuestros propios datos podemos hacer predicciones basadas en lo que nosotros mismos hemos observado en el transcurso de nuestra actividad.

Por lo tanto, estas métricas serán mucho más precisas que las que podamos elaborar antes de iniciar la actividad de la empresa, y me parece una inversión muy acertada.

- Jóvenes emprendedores (ENISA).

Ayuda por parte del gobierno de España para jóvenes emprendedores.

El baremo que nos ofrecen es de 25.000€ - 75.000€.

Este dinero si se usara para invertir en infraestructura, los servidores locales que no tengan que ver con inteligencia artificial, pueden pagarse con este dinero, y en caso de acceder a la máxima financiación, podremos permitirnos también los servidores de IA, que tienen un precio mucho más elevado.

Este problema que presenta no permitirnos la IA local no es tan grande como parece, ya que las grandes empresas como OpenAI o Anthropic, nos permiten emplear sus modelos de IA pagando por cada Token que enviemos en cada interacción.

Por lo tanto, podremos mantener este modelo hasta que tengamos la estabilidad económica como para comprar nuestros propios servidores de Inteligencia Artificial.

Conclusión de las ayudas

Podremos beneficiarnos de muchas de ellas, pero dependerá de la cuantía de la ayuda donde invirtamos este dinero. Para sacarle el máximo rendimiento posible, buscando aumentar los beneficios, reduciendo costes, o aumentando el flujo de clientes.



Ilustración 3 - Subvenciones

Diseño del proyecto

1. Requisitos y restricciones

1.1. Requisitos funcionales

REQUISITO	JUSTIFICACIÓN
DESPLEGAR SERVICIOS DE FORMA DISTRIBUIDA ENTRE VARIOS NODOS	Eliminar el punto único de fallo: si un nodo cae, el resto del sistema sigue operativo
EJECUTAR TODOS LOS SERVICIOS EN CONTENEDORES DOCKER	Aislar cada servicio, facilitar su migración y reducir la superficie de ataque
ORQUESTAR LOS CONTENEDORES MEDIANTE K3S	Controlar de forma centralizada el ciclo de vida de cada contenedor
CENTRALIZAR LOS SERVICIOS PRINCIPALES EN EL NODO MATRIX	Aprovechar el nodo con más recursos como punto de ejecución principal
MANTENER UN NODO DE RESPALDO (FALLBACK) PERMANENTEMENTE DISPONIBLE	Garantizar la continuidad del servicio ante la caída de cualquier nodo principal
SOPORTAR FUNCIONAMIENTO EN MODO DEGRADADO	Mantener activos únicamente los servicios esenciales ante pérdida de recursos
PRIORIZAR SERVICIOS CRÍTICOS ANTE SITUACIONES DE FALLO	Definir qué servicios deben sobrevivir ante una caída parcial
GENERAR ALERTAS AUTOMÁTICAS ANTE UMBRALES CRÍTICOS	Notificar de forma inmediata cuando alguna métrica supere los límites establecidos
PROPORCIONAR ACCESO REMOTO SEGURO MEDIANTE VPN	Permitir la administración del sistema desde cualquier ubicación
ANALIZAR MÉTRICAS E INFRAESTRUCTURA MEDIANTE INTELIGENCIA ARTIFICIAL	Automatizar el análisis de logs y métricas, reduciendo la carga operativa
CAPACIDAD DE DESPLIEGUE AUTOMÁTICO DE SERVICIOS	Levantar servicios sin intervención manual, habilitando una operativa más eficiente
PERMITIR EL REINICIO AUTOMÁTICO DE SERVICIOS O NODOS ANTE FALLOS	Reducir el tiempo de inactividad sin necesidad de intervención humana



1.2. Requisitos no funcionales

REQUISITO	MÉTRICA / CRITERIO DE ACEPTACIÓN
ALTA DISPONIBILIDAD	El servicio debe mantenerse operativo ante la caída de un nodo completo
RESILIENCIA	Recuperación de errores de software, hardware o humanos sin pérdida permanente de datos
ESCALABILIDAD HORIZONTAL	Añadir nuevos nodos o contenedores sin rediseñar la arquitectura
MODULARIDAD	Cada servicio debe poder actualizarse o eliminarse sin afectar al resto
PORTABILIDAD	Todos los servicios migrables a hardware diferente sin modificar su configuración interna
EFICIENCIA DE RECURSOS	Arquitectura funcional con el hardware disponible, sin infraestructura empresarial
OBSERVABILIDAD COMPLETA	Todos los nodos y servicios exponen métricas accesibles desde Prometheus y Grafana
SEPARACIÓN DE RESPONSABILIDADES	Cada nodo tiene un rol definido y no asume funciones de otro salvo en fallo
OPERABILIDAD	Operable con conocimiento estándar de Linux, Docker y K3s

1.3. Restricciones del proyecto

ID	RESTRICCIÓN	IMPACTO EN EL DISEÑO
R-01	Hardware doméstico y de gama media	Limita servicios simultáneos y tamaño de modelos de IA en local
R-02	Proyecto unipersonal	La arquitectura debe priorizar la automatización para compensar la falta de equipo
R-03	Presupuesto reducido	Se descartan soluciones cloud de pago; se opta por modelos locales con Ollama
R-04	GPU de gama media (RTX 3060 Ti)	Modelos de IA limitados en tamaño; se contempla uso de APIs externas como respaldo
R-05	Nodo Fallback con recursos muy limitados (4 GB RAM)	Solo puede asumir servicios esenciales en modo degradado

2. Decisiones de diseño

2.1. K3s frente a kubernetes

Kubernetes estándar requiere una cantidad mínima de recursos considerable y una complejidad operativa elevada para un entorno de un solo administrador. K3s es una distribución certificada de Kubernetes diseñada para entornos con recursos limitados, manteniendo la compatibilidad con todos los manifiestos y herramientas del ecosistema.

Dado el hardware disponible y el carácter unipersonal del proyecto, K3s ofrece la misma orquestación con una huella de recursos notablemente menor.

2.2. Ollama frente a API externa

El uso de una API externa (OpenAI, Anthropic) implica dependencia de un tercero, coste por token y envío de datos potencialmente sensibles fuera de la infraestructura. Ollama permite ejecutar modelos de lenguaje en local sobre la GPU del nodo LelA, manteniendo los datos dentro del entorno y eliminando el coste recurrente por inferencia.

La limitación es la capacidad del hardware, por lo que se contempla el uso de APIs externas como alternativa de respaldo para casos que superen las capacidades locales.

2.3. Sistema de monitorización

Soluciones como Datadog o New Relic ofrecen observabilidad completa integrada, pero con un coste mensual inasumible en la fase inicial. El stack Prometheus + Grafana + Loki es el estándar de facto en entornos opensource, con comunidad activa, amplia documentación y total compatibilidad con el ecosistema Kubernetes/Docker.



3. Arquitectura

3.1. Visión general

La arquitectura de SaaSphere se organiza en tres nodos físicos con roles claramente diferenciados, sobre los que se construyen capas de virtualización, contenerización y servicios. El objetivo es que ningún servicio crítico dependa de un único punto de fallo.

3.2. Nodos Físicos

LelA — Nodo de Inteligencia Artificial

COMPONENTE	ESPECIFICACIÓN
TIPO	PC de escritorio de alto rendimiento
ROL	Análisis, automatización e inteligencia artificial
RAM	32 GB
PROCESADOR	Intel Core i9-12900KF
GPU	NVIDIA RTX 3060 Ti

ESXi — Nodo Principal de Virtualización

COMPONENTE	ESPECIFICACIÓN
TIPO	Servidor físico con VMware ESXi
ROL	Nodo principal, aloja las máquinas virtuales del proyecto
RAM DISPONIBLE	10 GB (12 GB físicos, 2 GB reservados para el hipervisor)
PROCESADOR	4x Intel Xeon E31220 @ 3.10 GHz



Máquinas virtuales alojadas:

VM	SO	RAM	vCPU	DISCO	ROL	SERVICIOS
HEIMDALL	Debian	1 GB	1	50 GB	Servidor VPN	WireGuard
SAURON	Debian	3 GB	1	100 GB	Monitorización	Prometheus, Grafana, Loki
MATRIX	Debian	6 GB	3	500 GB	Nodo principal	K3s, Docker, Nginx

Fallback — Nodo de Respaldo

COMPONENTE	ESPECIFICACIÓN
TIPO	Portátil reutilizado como miniservidor
ROL	Nodo de respaldo ante caídas del nodo ESXi
RAM	4 GB
PROCESADOR	Intel Pentium 2020M @ 2.40 GHz

En condiciones normales, Fallback permanece en espera sin ejecutar servicios de producción. Su activación es automática ante la detección de caída de un nodo principal. Dadas sus limitaciones, únicamente asume los servicios críticos: VPN y proxy inverso como mínimo.

3.3. Estructura por capas

CAPA	NOMBRE	DESCRIPCIÓN
1	Física	Hardware real: tres nodos conectados en red local mediante switch
2	Virtualización	Ejecuta múltiples VMs con recursos controlados
3	Contenerización	Docker y K3s en Matrix, cada servicio corre en su propio contenedor aislado
4	Servicios del sistema	WireGuard, Prometheus + Grafana + Loki, Nginx
5	Servicios de cliente	Aplicaciones y webs por cliente, accesibles desde el exterior
6	Automatización e IA	LeIA consulta métricas, analiza logs y ejecuta acciones correctivas de forma autónoma



4. Modos de funcionamiento

4.1. Funcionamiento normal

En condiciones normales:

El tráfico externo entra por el proxy inverso (Nginx en Matrix), que lo redirige al contenedor correspondiente según el dominio del cliente.

K3s gestiona el ciclo de vida de todos los contenedores activos.

Sauron recopila métricas de todos los nodos y servicios de forma continua. Grafana las visualiza y dispara alertas si algún umbral es superado.

Heimdall mantiene activo el túnel WireGuard para acceso administrativo remoto en todo momento.

LelA analiza periódicamente el estado del sistema: revisa logs, detecta patrones anómalos y ejecuta acciones correctivas sin intervención humana.

4.2. Funcionamiento degradado

Cuando Sauron o LelA detectan un fallo, el sistema evalúa si K3s puede reubicar el servicio en Matrix. Si no es posible, se activa el nodo Fallback con los servicios esenciales. LelA analiza la causa del fallo, notifica al operador por Telegram e intenta la restauración automática. Los servicios se restauran de forma progresiva por orden de prioridad, evitando sobrecargar el hardware durante la recuperación.

4.3. Prioridad de restauración

PRIORIDAD	SERVICIO	MOTIVO
1	WireGuard (VPN)	Sin acceso remoto no se puede intervenir manualmente
2	Proxy inverso (Nginx)	Sin él, ningún cliente tiene acceso a su servicio
3	Monitorización (Prometheus)	Necesaria para evaluar el estado durante la recuperación
4	Servicios de cliente	Restaurados por orden de criticidad del cliente

La restauración se realiza de forma progresiva y no simultánea para evitar sobrecargar el hardware y generar un segundo incidente durante la recuperación.



Implementación

Se ha planteado una implementación por fases en función a los recursos HW disponibles, levantándolos en orden de necesidad, debido a dependencias de unos servicios sobre otros.

Con cada fase se harán pequeñas pruebas, para comprobar si esta funcionando de manera correcta.

1. Fase 1 – Preparación de hardware → 3H

a. Instalación y configuración básica

Hardware instalado:

Nodo	Tipo	CPU	RAM	Disco	GPU	SO Instalado	Versión SO
LeIA	PC Escritorio	Intel Core i9-12900KF	32 GB	100 GB SSD / 500 GB HDD	NVIDIA RTX 3060 Ti 8GB VRAM	Debian	13
ESXi	Servidor físico	4x Intel Xeon E31220 @ 3.10GHz	12 GB (10 GB disponibles)	3 TB	—	VMware ESXi	7
Fallback	Portátil	Intel Pentium 2020M @ 2.40GHz	4 GB	750 GB	—	Debian	13


Configuración de red:

Campo	LeIA	ESXi	Fallback
IP estática asignada	192.168.1.200	192.168.1.99	192.168.1.210
Máscara de red	24	24	24
Puerta de enlace	192.168.1.1	192.168.1.1	192.168.1.1
DNS configurado	8.8.8.8	8.8.8.8	8.8.8.8
Switch/VLAN	Físico	Físico	Físico
Conectividad entre nodos	PING OK	PING OK	PING OK



b. Pruebas

Las pruebas se han realizado mediante pings entre desde LeIA (en windows) hacia los otros dispositivos.



```
PS C:\Users\angel> ping 192.168.1.210

Haciendo ping a 192.168.1.210 con 32 bytes de datos:
Respuesta desde 192.168.1.210: bytes=32 tiempo<1m TTL=64
Respuesta desde 192.168.1.210: bytes=32 tiempo<1m TTL=64
Respuesta desde 192.168.1.210: bytes=32 tiempo=1ms TTL=64
Respuesta desde 192.168.1.210: bytes=32 tiempo=1ms TTL=64

Estadísticas de ping para 192.168.1.210:
    Paquetes: enviados = 4, recibidos = 4, perdidos = 0
              (0% perdidos),
    Tiempos aproximados de ida y vuelta en milisegundos:
        Mínimo = 0ms, Máximo = 1ms, Media = 0ms
PS C:\Users\angel> ping 192.168.1.99

Haciendo ping a 192.168.1.99 con 32 bytes de datos:
Respuesta desde 192.168.1.99: bytes=32 tiempo<1m TTL=64
Respuesta desde 192.168.1.99: bytes=32 tiempo<1m TTL=64
Respuesta desde 192.168.1.99: bytes=32 tiempo<1m TTL=64
Respuesta desde 192.168.1.99: bytes=32 tiempo<1m TTL=64

Estadísticas de ping para 192.168.1.99:
    Paquetes: enviados = 4, recibidos = 4, perdidos = 0
              (0% perdidos),
    Tiempos aproximados de ida y vuelta en milisegundos:
        Mínimo = 0ms, Máximo = 0ms, Media = 0ms
```

Los resultados son correctos y todas las maquinas tienen conexión entre ellas

2. Fase 2 – Entorno virtual en ESXI → 3H

a. Instaladas Heimdall Sauron y Matrix

Instalación realizada correctamente partiendo de una VM plantilla, todas las maquinas tienen la misma configuración exceptuando hostname y dirección IP.

b. Asignadas IP estáticas

Asignadas las siguientes direcciones IP:

- Sauron: 192.168.1.201
- Matrix: 192.168.1.202
- Heimdall: 192.168.1.203

c. Habilitados y configurados servicios básicos:

- `/etc/apt/sources.list` configurado con repositorios Debian 13 Trixie
- **Paquetes base instalados:** curl, vim, htop, sudo, openssh-server
- **Seguridad:** fail2ban, ufw, auditd, PermitRootLogin deshabilitado, unattended-upgrades
- **Monitorización:** prometheus-node-exporter activo en puerto 9100
- **Auditoría manual:** lynis y rkhunter instalados
- **Sistema:** PATH global configurado, alias `c=clear`, IP estática con hotplug

d. Pruebas

Se ha probado la conexión con cada una de las máquinas virtuales mediante SSH y se aprecia que funciona, ya se puede operar desde un solo equipo sin necesidad de usar entornos virtuales.

The image shows three terminal windows side-by-side, each connected to a different virtual machine via SSH. The first window is connected to 'angel@Sauron', the second to 'angel@Matrix', and the third to 'angel@Heimdall'. Each terminal displays the output of the 'ip a' command, showing network interface details for 'lo' and 'ens192'. The output for 'lo' is identical in all three, showing a loopback address of 127.0.0.1. The output for 'ens192' shows different IP addresses: 192.168.1.201 for Sauron, 192.168.1.202 for Matrix, and 192.168.1.203 for Heimdall. The terminals also show MAC addresses and other network configuration details.

Se comprueba que las 3 máquinas están activas dentro de VMware ESXi, la maquina “SaaSphere” es una plantilla para crear las demás, las otras dos son maquinas viejas personales.

The image shows the VMware ESXi vSphere Client interface. On the left, there is a sidebar with navigation options like 'Host', 'Máquinas virtuales', 'Almacenamiento', and 'Redes'. The main area displays a table of virtual machines. The table has columns for 'Máquina virtual', 'Condición', 'Espacio utilizado', 'Sistema operativo invitado', 'Nombre del host', 'CPU de host', 'Memoria de host', and 'Orden de inicio a...'. There are six virtual machines listed: 'ServidorWeb Nginx', 'windows-server', 'SaaSphere', 'Heimdall', 'Sauron', and 'Matrix'. Each machine has a status icon (a green checkmark) and a 'Normal' condition. The 'SaaSphere' machine is highlighted in blue. Below the table, there is a 'Filtros rápidos' section and a 'Tareas recientes' section.

Máquina virtual	Condición	Espacio utilizado	Sistema operativo invitado	Nombre del host	CPU de host	Memoria de host	Orden de inicio a...
ServidorWeb Nginx	Normal	506,62 GB	Debian GNU/Linux 11 (64 bits)	Desconocido	0 MHz	0 MB	1
windows-server	Normal	350 GB	Microsoft Windows Server 2022 (64 bits)	Desconocido	0 MHz	0 MB	Sin establecer
SaaSphere	Normal	50 GB	Debian GNU/Linux 11 (64 bits)	Desconocido	0 MHz	0 MB	Sin establecer
Heimdall	Normal	3,66 GB	Debian GNU/Linux 11 (64 bits)	heimdall	84 MHz	869 MB	Sin establecer
Sauron	Normal	5,58 GB	Debian GNU/Linux 11 (64 bits)	saaron	151 MHz	3,02 GB	Sin establecer
Matrix	Normal	8,59 GB	Debian GNU/Linux 11 (64 bits)	matrix	441 MHz	2,61 GB	Sin establecer



3. Fase 3 – Configuración de red VPN → 1 día

a. Instalar Wireguard

Se instala WireGuard con la siguiente configuración:

- Interfaz de red física de Heimdall: ens192
- Red VPN: 10.10.0.0/24
- Puerto: UDP 51820
- IP Heimdall VPN: 10.10.0.1/24

Se configura un almacén de claves en la ruta:


/etc/wireguard/keys/<nombre_clave>

Se generan 3 primeras claves:

- Una para un portátil.
- Otra para un móvil.
- Otra genérica por si una falla.

b. Configurar archivos de configuración

Archivo de configuración **/etc/wireguard/wg0.conf**:



```
GNU nano 8.4 /etc/wireguard/wg0.conf
[Interface]
Address = 10.10.0.1/24
ListenPort = 51820
PrivateKey =

PostUp = iptables -A FORWARD -i wg0 -j ACCEPT; iptables -t nat -A POSTROUTING -o ens192 -j MASQUERADE
PostDown = iptables -D FORWARD -i wg0 -j ACCEPT; iptables -t nat -D POSTROUTING -o ens192 -j MASQUERADE

# --- Port til ---
[Peer]
PublicKey =
AllowedIPs = 10.10.0.2/32

# --- iPhone ---
[Peer]
PublicKey =
AllowedIPs = 10.10.0.3/32

# --- Peer gen rico ---
[Peer]
PublicKey =
AllowedIPs = 10.10.0.4/32
```



c. Abrir puertos necesarios

Estos son los puertos abiertos en la maquina

```

angel@Heimdall: ~
root@Heimdall:/home/angel# ufw status
Status: active

To Action From
--
22/tcp ALLOW Anywhere
51820/udp ALLOW Anywhere
22/tcp (v6) ALLOW Anywhere (v6)
51820/udp (v6) ALLOW Anywhere (v6)

root@Heimdall:/home/angel#

```

Y estos en el router

	Wireguard	51820	51820	UDP	192.168.1.203	<button>editar</button>	<button>borrar</button>
---	-----------	-------	-------	-----	---------------	-------------------------	-------------------------

Y este el archivo de configuración con el código QR de enlace del cliente móvil

```

angel@Heimdall: ~
root@Heimdall:/home/angel# qrencode -t ansiutf8 < /etc/wireguard/clients/iphone.conf

```



```

root@Heimdall:/home/angel# cat /etc/wireguard/clients/iphone.conf
[Interface]
PrivateKey = 
Address = 10.10.0.3/32
DNS = 1.1.1.1

[Peer]
PublicKey = 
Endpoint = 85.96:
AllowedIPs = 10.10.0.0/24, 192.168.1.0/24
PersistentKeepalive = 25
root@Heimdall:/home/angel#

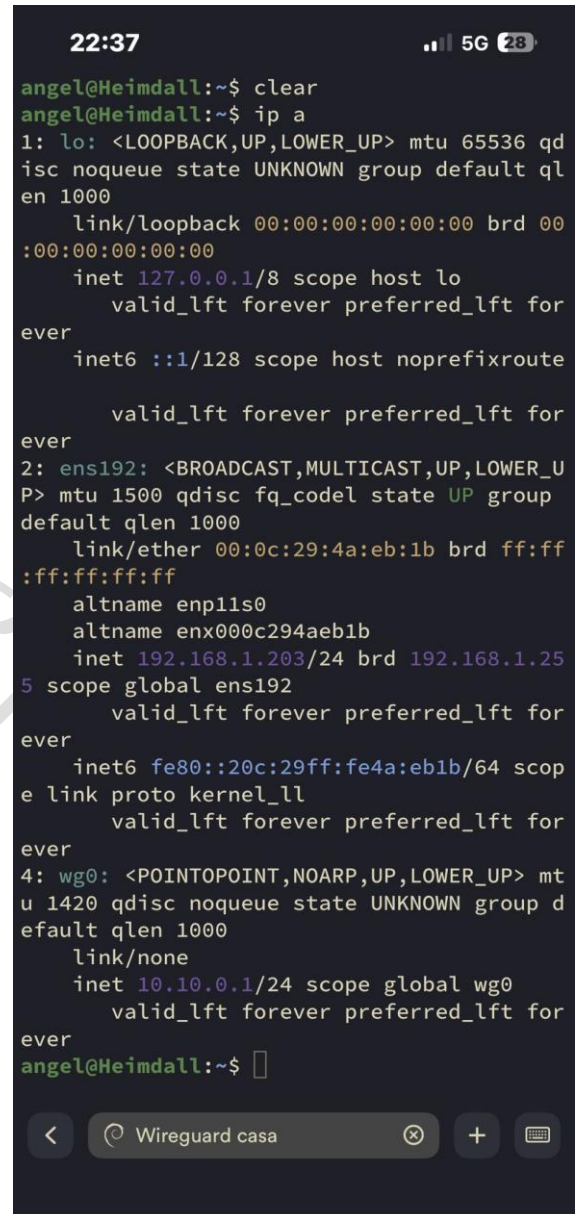

```



d. Pruebas

Se ha probado la conexión desde el cliente móvil debido a ser el que va a usarse la mayor parte del tiempo desde la VPN.

Se aprecia que permite tanto conectar la VPN, como vía SSH.



4. Fase 4 – servicios de monitorización → 1 semana

a. Despliegue de prometheus, Grafana y Loki

Se han desplegado 6 contenedores para ejecutar los servicios:

Grafana → Para mostrar las métricas


Prometheus → Recoge las métricas

Loki → Almacena logs

Blackbox → Comprueba estado de diversos nodos


Promtail → Busca logs

Alertmanager → Alerta de caídas de servicios y nodos



NAME	IMAGE	COMMAND	SERVICE	CREATED	STATUS	PORTS
alertmanager	prom/alertmanager:v0.27.0	"/bin/alertmanager --"	alertmanager	6 minutes ago	Up 6 minutes	0.0.0.0:9093->9093/tcp, [::]:9093->9093/tcp
blackbox-exporter	prom/blackbox-exporter:v0.25.0	"/bin/blackbox_exporter"	blackbox-exporter	5 hours ago	Up 5 hours	0.0.0.0:9115->9115/tcp, [::]:9115->9115/tcp
grafana	grafana/grafana:11.3.1	"/run.sh"	grafana	5 hours ago	Up 5 hours	0.0.0.0:3000->3000/tcp, [::]:3000->3000/tcp
loki	grafana/loki:3.2.1	"/usr/bin/loki -conf."	loki	5 hours ago	Up 2 hours	0.0.0.0:3100->3100/tcp, [::]:3100->3100/tcp
prometheus	prom/prometheus:v2.55.1	"/bin/prometheus --c."	prometheus	4 minutes ago	Up 4 minutes	0.0.0.0:9090->9090/tcp, [::]:9090->9090/tcp
promtail	grafana/promtail:3.2.1	"/usr/bin/promtail --"	promtail	5 hours ago	Up 5 hours	

Se ha dejado la carpeta: /opt/monitoring/grafana/dashboards para almacenar los dashboards del proyecto, permitiendo editar directamente el JSON.



```

angel@sauron:/opt/monitoring$ tree
.
├── alertmanager
│   └── alertmanager.yml
├── blackbox
│   └── blackbox.yml
├── docker-compose.yml
├── grafana
│   ├── dashboards
│   │   ├── blackbox.json
│   │   ├── loki-logs.json
│   │   └── node-exporter-full.json
│   ├── provisioning
│   │   ├── dashboards
│   │   │   └── dashboards.yml
│   │   └── datasources
│   │       └── datasources.yml
├── loki
│   └── loki-config.yml
├── prometheus
│   ├── prometheus.yml
│   └── rules
│       └── saasphere.yml
└── promtail
    └── promtail-config.yml

12 directories, 12 files
angel@sauron:/opt/monitoring$
  
```



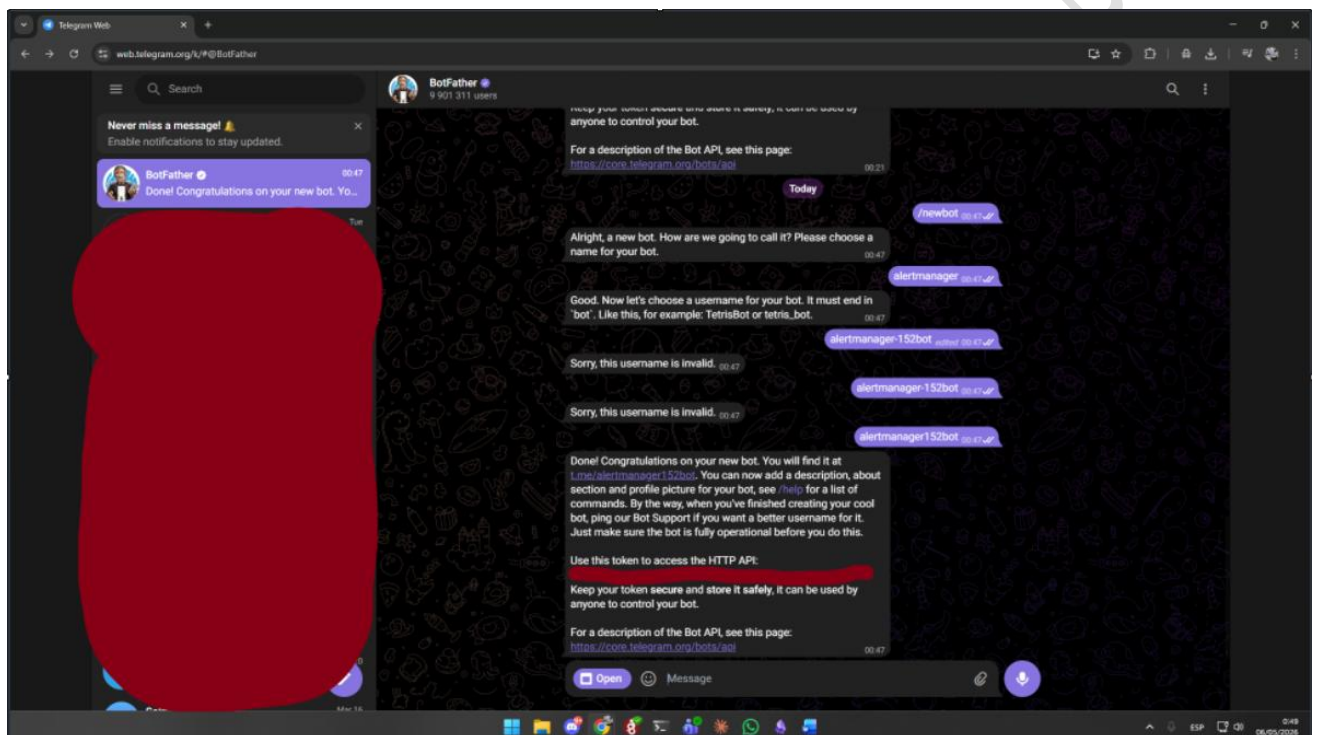
Para reducir el número de puertos abiertos, se ha configurado una red interna en docker para la comunicación de los contenedores.

```
angel@sauron: /opt/monitori X angel@matrix: ~ X angel@heimdall: ~ X angel@Fallback: ~ X + v
angel@sauron:/opt/monitoring$ sudo docker network inspect monitoring_monitoring --format '{{range .Containers}}{{.Name}} -> {{.IPv4Address}}{{"\n"}}{{end}}'
prometheus -> 172.18.0.6/16
alertmanager -> 172.18.0.7/16
grafana -> 172.18.0.2/16
loki -> 172.18.0.4/16
blackbox-exporter -> 172.18.0.5/16
promtail -> 172.18.0.3/16

angel@sauron:/opt/monitoring$
```

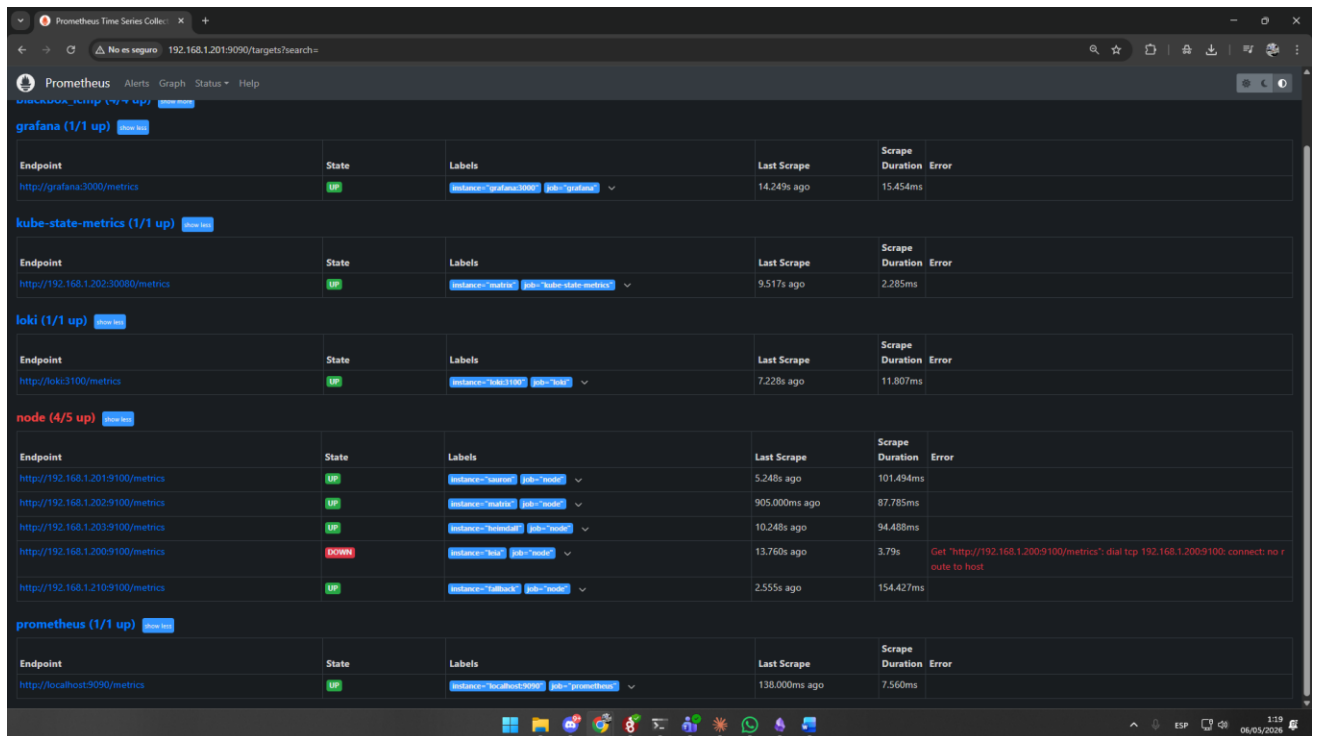
Los targets de prometheus están configurados dentro de /opt/monitoring/prometheus/prometheus.yml, las reglas de alertas en /opt/monitoring/prometheus/rules/saasphere.yml y la configuración del alertmanager en cat /opt/monitoring/alertmanager/alertmanager.yml, toda la configuración en el GitHub del proyecto.

Ahora se configura el bot de telegram para recibir las alertas.



b. Pruebas


Acceso desde mi equipo al panel web de Prometheus



The screenshot shows the Prometheus 'Targets' page. It displays a list of scrape targets with columns for Endpoint, State, Labels, Last Scrape, Scrape Duration, and Error. The targets are grouped by job name: grafana, kube-state-metrics, loki, node, and prometheus.

Job	Endpoint	State	Labels	Last Scrape	Scrape Duration	Error
grafana (1/1 up)	http://grafana:3000/metrics	UP	instance="grafana:3000" job="grafana"	14.24s ago	15.454ms	
kube-state-metrics (1/1 up)	http://192.168.1.202:30080/metrics	UP	instance="metrics" job="kube-state-metrics"	9.517s ago	2.285ms	
loki (1/1 up)	http://loki:3100/metrics	UP	instance="loki:3100" job="loki"	7.228s ago	11.807ms	
node (4/5 up)	http://192.168.1.201:9100/metrics	UP	instance="node1" job="node"	5.248s ago	101.494ms	
	http://192.168.1.202:9100/metrics	UP	instance="node2" job="node"	905.000ms ago	87.785ms	
	http://192.168.1.203:9100/metrics	UP	instance="node3" job="node"	10.248s ago	94.488ms	
	http://192.168.1.200:9100/metrics	DOWN	instance="node4" job="node"	13.760s ago	3.79s	Get "http://192.168.1.200:9100/metrics": dial tcp 192.168.1.200:9100: connect: no route to host
	http://192.168.1.210:9100/metrics	UP	instance="node5" job="node"	2.555s ago	154.427ms	
prometheus (1/1 up)	http://localhost:9090/metrics	UP	instance="localhost:9090" job="prometheus"	138.000ms ago	7.560ms	

Se prueba a hacer una consulta prometheus

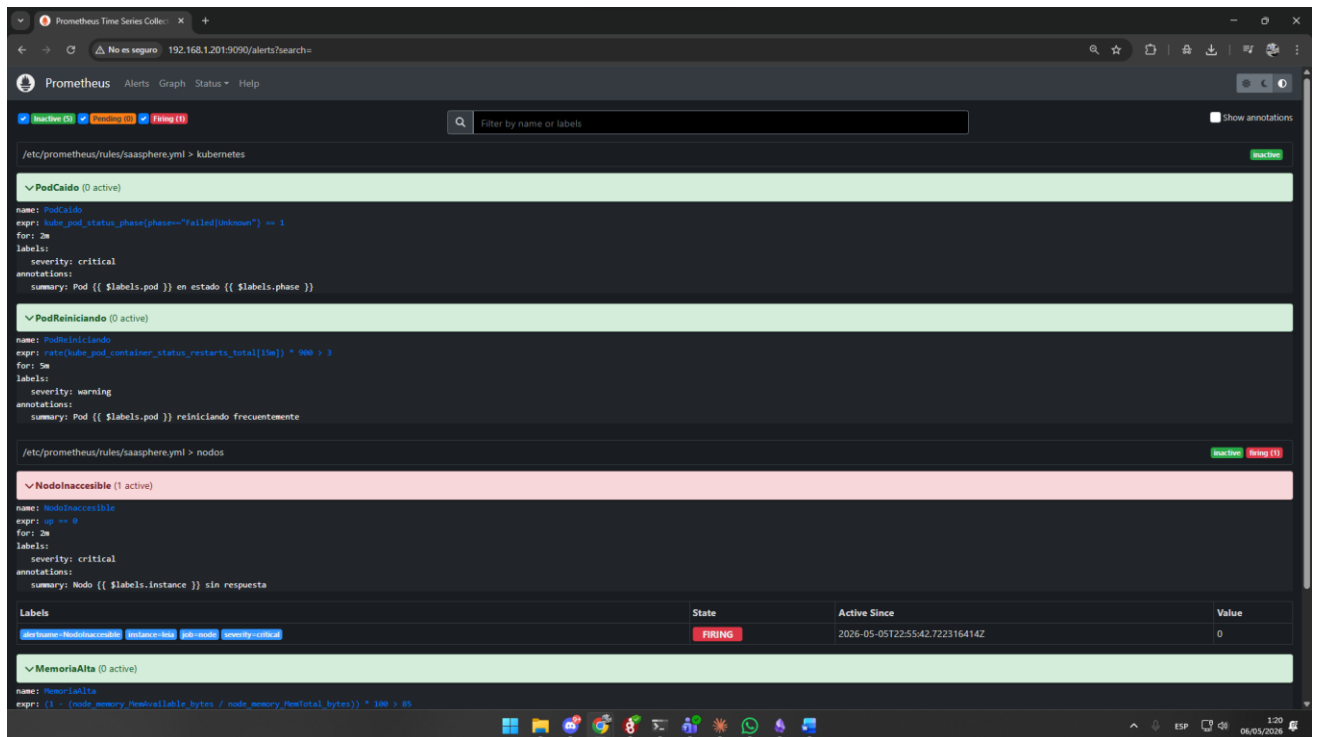


The screenshot shows the Prometheus 'Query' page. The query is: `100 - (avg by(instance) (rate(node_cpu_seconds_total{mode="idle"}[5m])) * 100)`. The result is displayed in a table with 4 rows and 2 columns: instance and value.

instance	value
instance="balblack"	2.994738842106491
instance="saucan"	4.035087719298261
instance="thindall"	3.1263157894736366
instance="tratin"	3.6327485380118674




Se comprueban las alertas actuales



The screenshot shows the Prometheus Alerts page. The top navigation bar includes 'Prometheus', 'Alerts', 'Graph', 'Status', and 'Help'. Below the navigation bar, there are tabs for 'Active (3)', 'Pending (0)', and 'Firing (1)'. A search bar is present with the text 'Filter by name or labels'. The main content area displays a list of alerts. The first alert is 'PodCaído (0 active)' with a green bar. The second is 'PodReiniciando (0 active)' with a green bar. The third is 'NodoInaccesible (1 active)' with a red bar. The fourth is 'MemoriaAlta (0 active)' with a green bar. Below the alerts, there is a table with columns 'Labels', 'State', 'Active Since', and 'Value'. The table shows one row for 'NodoInaccesible' with state 'FIRING' and active since '2026-05-05T22:55:42.722316414Z'.

Labels	State	Active Since	Value
alertname=NodoInaccesible, instance=leia, job=node, severity=critical	FIRING	2026-05-05T22:55:42.722316414Z	0

Se comprueba el panel del alertmanager para demostrar su correcto funcionamiento, existe una alerta de que el nodo Leia no tiene funcionamiento ya que aún no está configurado.



The screenshot shows the Alertmanager Alerts page. The top navigation bar includes 'Alertmanager', 'Alerts', 'Silences', 'Status', 'Settings', and 'Help'. Below the navigation bar, there is a 'New Silence' button. The main content area displays a list of alerts. The first alert is 'NodoInaccesible' with a red bar. The alert details show the summary 'Nodo leia sin respuesta' and the labels 'cluster=sasphere', 'job=node', 'monitor=sauron', and 'severity=critical'.


Labels	State	Active Since	Value
alertname=NodoInaccesible, instance=leia, job=node, severity=critical	FIRING	2026-05-05T22:55:42.722316414Z	0




Ejecuto una alerta manualmente mediante la API de alertmanager

```
angel@sauron: /opt/monitori x angel@matrix: ~ x angel@heimdall: ~ x angel@Fallback: ~  
angel@sauron:/opt/monitoring$ curl -s -X POST http://localhost:9093/api/v2/alerts \  
-H 'Content-Type: application/json' \  
-d '{  
  "labels": {"alertname": "NodoInaccesible", "instance": "matrix", "severity": "critical"},  
  "annotations": {"summary": "Nodo matrix sin respuesta durante 2 minutos"}  
}'  
angel@sauron:/opt/monitoring$ |
```

Y desde el móvil podemos comprobar que llega correctamente a telegram




Hay acceso a Grafana correctamente configurado




Se ha probado con panel por defecto de GitHub para poder probar si grafana está funcionando correctamente con prometheus.

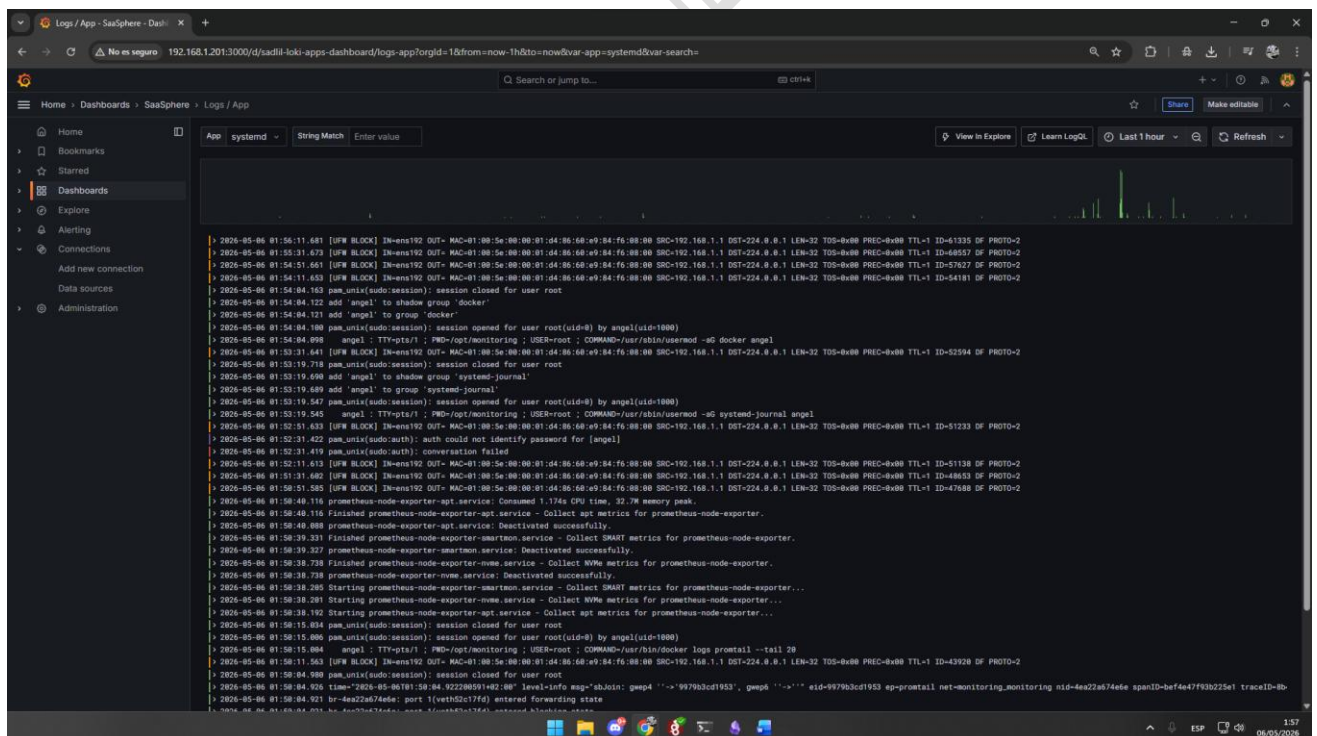
Se aprecia que el panel está funcionando de manera correcta.



Se comprueba también un panel de Blackbox para asegurarnos que detecta todos los host UP y Down, LeIA en este momento esta Down así que esta perfecto.



Loki está configurado correctamente también, se puede apreciar los logs que está leyendo y registrando.



Enlace al video de prueba de alertmanager:

<https://youtu.be/89v1eMKmVMc>



5. Fase 5 – Orquestación de contenedores → 1 semana

a. Configuración K3s

SaaSphere utiliza k3s como herramienta para poder orquestar los contenedores dentro del nodo Matrix, pese a que el que controle los contenedores vaya a ser LeIA, lo hará mediante comandos y configuraciones de k3s.

LeIA decidirá cuando lanzar un cliente, la imagen que se debe utilizar, cuando emplear el nodo Fallback, LeIA trabajara sobre k3s, dejando registro y log de todas sus acciones, construyendo así un sistema autogestionado la única función de K3s es mantener lo que LeIA configure, levantando contenedores si hace falta.

Aquí se puede apreciar que k3s tiene el clúster operativo y todos sus componentes están Running.

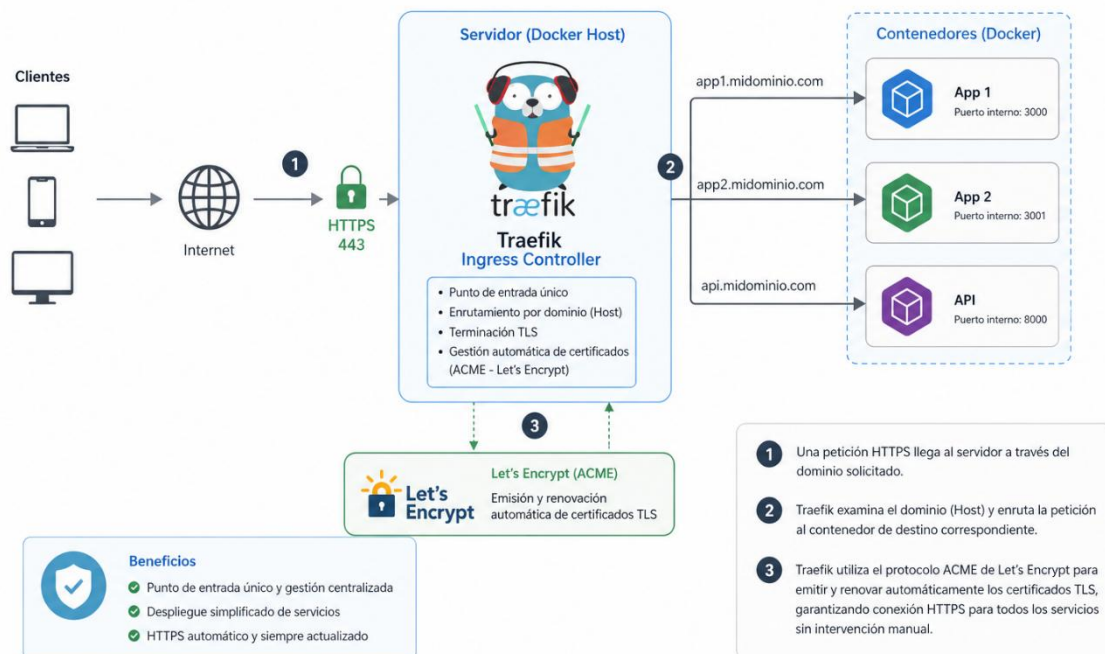
```
angel@Matrix:~$ kubectl get nodes -o wide
NAME      STATUS   ROLES    AGE   VERSION   INTERNAL-IP   EXTERNAL-IP   OS-IMAGE             KERNEL-VERSION   CONTAINER-RUNTIME
matrix    Ready    control-plane 23d   v1.34.6+k3s1 192.168.1.202 <none>        Debian GNU/Linux 13 (trixie) 6.12.74+deb13+1-amd64 containerd://2.2.2-bd1.34

angel@Matrix:~$ kubectl get pods -A
NAMESPACE   NAME                                     READY   STATUS    RESTARTS   AGE
kube-system  coredns-76c974cb66-q79mk              1/1     Running   2 (10d ago) 23d
kube-system  helm-install-traefik-crd-vvzj5         0/1     Completed 0          23d
kube-system  helm-install-traefik-nc72r            0/1     Completed 0          23d
kube-system  kube-state-metrics-6678455479-mgghk    1/1     Running   0          17h
kube-system  local-path-provisioner-8686667995-jz7ck 1/1     Running   2 (10d ago) 23d
kube-system  metrics-server-c8774f4f4-wkk7c        1/1     Running   2 (10d ago) 23d
kube-system  syclb-traefik-3858b1dc-bp4pt          2/2     Running   4 (10d ago) 23d
kube-system  traefik-74d7f58f9b-jwrfq             1/1     Running   2 (10d ago) 23d
```

Para cumplir con los requisitos para desarrollo web, se han necesitado herramientas como Traefik, que actúa enrutando las peticiones web que llegan al contenedor correspondiente, gestiona los certificados TLS, usando ACME de Let's Encrypt, garantizando así que todos los servicios tienen conexión HTTPS.

Traefik como Ingress Controller con TLS automático

Punto de entrada único, enrutamiento por dominio y gestión automática de certificados con Let's Encrypt (ACME)



```
angel@Matrix:~$ kubectl get svc -n kube-system | grep traefik
traefik      LoadBalancer   10.43.122.112   192.168.1.202   80:31095/TCP,443:31876/TCP   23d
angel@Matrix:~$
```



Se ha configurado además un registro privado de imágenes, con registry v2, actúa como repositorio interno de imágenes Docker dentro de la red local, LeIA genera la imagen del nuevo cliente, la almacena en el registro, k3ss descarga las imágenes desde ahí cuando haya que desplegarlo, eliminando así dependencias de terceros.

```
angel@Matrix: ~  
angel@Matrix:~$ curl http://localhost:5000/v2/_catalog  
{"repositories":[]}  
angel@Matrix:~$ sudo docker images | grep matrix  
[sudo] password for angel:  
WARNING: This output is designed for human readability. For machine-readable output, please use --format.  
angel@Matrix:~$
```

Dentro de cada namespace, existe un entorno completamente independiente, donde se dan los recursos a cada contenedor, su configuración y sus reglas de red, así no existe la posibilidad de interferir con otros clientes. Usando este modelo se facilita la eliminación, solo debemos borrar ese namespace y ya.

Para gestionar el riesgo de las operaciones que puede realizar LeIA sobre nuestro clúster, se usa control de acceso basado en roles, LeIA dispone de su cuenta con permisos restringidos, solo puede usar lo mínimo y necesario para desplegar y gestionar los recursos en diferentes namespace.

Pero por ejemplo no tiene permiso para configurar el clúster, ni de escalar sus propios privilegios, de esta forma se reduce el impacto en caso de que LeIA intente ejecutar algo que no debe.

```
angel@Matrix: ~  
angel@Matrix:~$ kubectl get serviceaccount -n saasphere-system  
NAME      SECRETS  AGE  
default   0        23d  
leia-agent 0        23d  
angel@Matrix:~$ kubectl get clusterrolebinding leia-rolebinding -o yaml  
apiVersion: rbac.authorization.k8s.io/v1  
kind: ClusterRoleBinding  
metadata:  
  annotations:  
    kubernetes.io/last-applied-configuration: |  
      {"apiVersion":"rbac.authorization.k8s.io/v1","kind":"ClusterRoleBinding","metadata":{"annotations":{},"name":"leia-rolebinding"},"roleRef":{"apiGroup":"rbac.authorization.k8s.io","kind":"ClusterRole","name":"leia-role"},"subjects":[{"kind":"ServiceAccount","name":"leia-agent","namespace":"saasphere-system"}]}  
      creationTimestamp: "2026-04-06T22:47:06Z"  
  name: leia-rolebinding  
  resourceVersion: "1332"  
  uid: 29e96e33-3528-4a09-9341-49cde1591f69  
roleRef:  
  apiGroup: rbac.authorization.k8s.io  
  kind: ClusterRole  
  name: leia-role  
subjects:  
- kind: ServiceAccount  
  name: leia-agent  
  namespace: saasphere-system  
angel@Matrix:~$
```

A mayores se ha instalado Kube-state-metrics para poder monitorizar los kubernetes desde Grafana


```
angel@Matrix: ~  
angel@Matrix:~$ curl http://192.168.1.202:30080/metrics | grep kube_pod  
% Total % Received % Xferd Average Speed Time Time Current  
Dload Upload Total Spent Left Speed  
0 0 0 0 0 0 0 0 --:--:-- --:--:-- --:--:-- 0# HELP kube_pod_completion_time  
[STABLE] Completion time in unix timestamp for a pod.  
# TYPE kube_pod_completion_time gauge  
kube_pod_completion_time{namespace="kube-system",pod="helm-install-traefik-nc72r",uid="dfd4c5c9-c7e8-4bc2-9dd5-071a1f89bc19"} 1.775515531e+09  
kube_pod_completion_time{namespace="kube-system",pod="helm-install-traefik-crd-vvzj5",uid="db81cfe6-4f6b-414d-8f1a-10d60-495f-4b31-57551400-100"} 1.77551400-100
```




b. Pruebas

Para comprobar que el servicio k3s funciona, se hace un despliegue básico, y luego se hará con un Ingress para verificar que Traefik funciona correctamente.

Viendo el puerto, se prueba a acceder vía navegador web, debe haber una respuesta http de Nginx.




```
angel@Matrix: ~$ kubectl create deployment hello --image=nginxdemos/hello
deployment.apps/hello created
angel@Matrix: ~$ kubectl expose deployment hello --port=80 --type=NodePort
service/hello exposed
angel@Matrix: ~$ kubectl get svc hello
NAME      TYPE      CLUSTER-IP      EXTERNAL-IP      PORT(S)          AGE
hello     NodePort  10.43.67.112     <none>           80:31688/TCP     6s
angel@Matrix: ~$
```



NGINX

Server address: 10.42.0.23:80
Server name: hello-7b7dc84bcf-7qtrj
Date: 03/May/2026:19:40:39 +0000
URI: /

☐ Auto Refresh



K3s Cluster Status - Paneles de control

Estado de Nodos

Componente	Estado
matrix (202) — Node Exporter	UP
fallback (210) — Node Exporter	UP
matrix (202) — k3s API :6443	UP
fallback (210) — k3s API :6443	DOWN

Historial

k3s API — Disponibilidad (probe_success)

Node Exporter — Disponibilidad

Recursos del Sistema

CPU — Uso (%)

Memoria — Uso (%)



6. Fase 6 – Fallback → 1 día

a. Seguridad

Se ha aplicado la misma configuración básica que al resto de nodos, incluyendo configuraciones firewall y fail2ban, auditd con auditoria básica para el sistema, unattended-upgrades para aplicar actualizaciones de seguridad, y desactivar la zona de intercambio Swap, que es necesario por k3s en los nodos del clúster.

```
angel@Fallback:~$ sudo ufw status verbose
Status: active
Logging: on (low)
Default: deny (incoming), allow (outgoing), deny (routed)
New profiles: skip

To Action From
--
22/tcp ALLOW IN 192.168.1.0/24
9100/tcp ALLOW IN 192.168.1.201
10250/tcp ALLOW IN 192.168.1.0/24
8472/udp ALLOW IN 192.168.1.0/24
angel@Fallback:~$
```

```
angel@Fallback:~$ sudo fail2ban-client status sshd
Status for the jail: sshd
|- Filter
| - Currently failed: 0
| - Total failed: 0
| - Journal matches: _SYSTEMD_UNIT=sshd.service + _COMM=sshd
|- Actions
| - Currently banned: 0
| - Total banned: 0
| - Banned IP list:
angel@Fallback:~$ sudo auditctl -l
-w /etc/passwd -p wa -k identity
-w /etc/shadow -p wa -k identity
-w /etc/sudoers -p wa -k sudoers
-w /etc/sudoers.d -p wa -k sudoers
-w /etc/ssh/sshd_config -p wa -k sshd
-w /var/log/auth.log -p wa -k auth
angel@Fallback:~$ cat /etc/apt/apt.conf.d/20auto-upgrades
APT::Periodic::Update-Package-Lists "1";
APT::Periodic::Unattended-Upgrade "1";
angel@Fallback:~$ free -h
total          usado        libre compartido búf/caché disponible
Mem:          3,7Gi          895Mi          422Mi          45Mi          2,7Gi          2,8Gi
Inter:         0B           0B           0B
```

b. Confianza con registro

Luego se ha creado la confianza con el registro privado sin TLS, permitiendo descargar las imágenes desde nuestro registro, creando el fichero de configuración necesario.

Se demuestra la configuración y la prueba de acceso

```
angel@Fallback:~$ cat /etc/rancher/k3s/registries.yaml
mirrors:
  "192.168.1.202:5000":
    endpoint:
      - "http://192.168.1.202:5000"
angel@Fallback:~$
```

```
angel@Fallback:~$ curl -s http://192.168.1.202:5000/v2/_catalog
{"repositories": []}
angel@Fallback:~$
```

c. Incorporación al clúster

Se ha usado el token de autenticación de matrix para instalar el agente en Fallback, permitiendo así lanzar los contenedores ahí en caso de que matrix no pueda.

```
angel@Fallback:~$ sudo systemctl status k3s-agent --no-pager
● k3s-agent.service - Lightweight Kubernetes
   Loaded: loaded (/etc/systemd/system/k3s-agent.service; enabled; preset: enabled)
   Active: active (running) since Sun 2026-05-03 23:17:01 CEST; 25min ago
     Docs: https://k3s.io
   Process: 138979 ExecStartPre=/sbin/modprobe br_netfilter (code=exited, status=0/SUCCESS)
   Process: 138981 ExecStartPre=/sbin/modprobe overlay (code=exited, status=0/SUCCESS)
   Main PID: 138983 (k3s-agent)
      Tasks: 36
     Memory: 376.9M
        CPU: 49.924s
    CGroup: /system.slice/k3s-agent.service
            └─138983 "/usr/local/bin/k3s agent"
              └─139004 "containerd"
                └─139431 /var/lib/rancher/k3s/data/4373bc7eebb47a3f48304fd6d0a7f7f82c8f47cc82032776b7e85e70e3b73cf93/bin/containerd-shim-runc-v2 --namespace k8s.io --id c5aec...
```

```
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.667854 138983 iptables.go:212] Changing default FORWARD chain policy to ACCEPT
may 03 23:17:01 Fallback k3s[138983]: time="2026-05-03T23:17:01+02:00" level=info msg="Wrote flannel subnet file to /run/flannel/subnet.env"
may 03 23:17:01 Fallback k3s[138983]: time="2026-05-03T23:17:01+02:00" level=info msg="Running flannel backend."
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.672350 138983 vxlan_network.go:68] watching for new subnet leases
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.672481 138983 vxlan_network.go:115] starting vxlan device watcher
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.672701 138983 subnet.go:150] Batch elem [0] is { lease.Event{Type:0, Lease:Lease{Lease{EnableIPv4:true, EnableIPv6...
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.672948 138983 vxlan_network.go:265] Received Subnet Event with VxLan: BackendType: vxlan, PublicIP: 1..V6Data: (nil)
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.703878 138983 iptables.go:358] bootstrap done
may 03 23:17:01 Fallback k3s[138983]: I0503 23:17:01.817354 138983 iptables.go:358] bootstrap done
may 03 23:17:16 Fallback k3s[138983]: I0503 23:17:16.004409 138983 pod_startup_latency_tracker.go:108] "Observed pod startup duration" pod="kube-system/svclb-traefik-3...
Hint: Some lines were ellipsized, use -l to show in full.
angel@Fallback:~$ sudo k3s ctrctl ps
CONTAINER          IMAGE                CREATED             STATE              NAME                  ATTEMPT             POD ID              POD
NAMESPACE
35c3bf3c2824f     c78251c868ae1       25 minutes ago     Running            lb-tcp-443           0                   c5aec600d61d9      svclb-traefik-3850b1dc-6m7t4
kube-system
e7d98214c1982     c78251c868ae1       25 minutes ago     Running            lb-tcp-80            0                   c5aec600d61d9      svclb-traefik-3850b1dc-6m7t4
kube-system
angel@Fallback:~$
```

d. NoSchedule taint

Desde el nodo Matrix se ha configurado para no enviar trabajo a Fallback, excepto en situaciones excepcionales como caídas de algún servicio.

Usando este Taint, LeIA podrá mandar el trabajo al nodo Fallback en caso de que haga falta.

```
angel@Matrix:~$ kubectl get nodes -o wide
NAME      STATUS  ROLES  AGE  VERSION  INTERNAL-IP  EXTERNAL-IP  OS-IMAGE              KERNEL-VERSION  CONTAINER-RUNTIME
fallback  Ready   <none>  26m  v1.35.4+k3s1  192.168.1.210 <none>        Debian GNU/Linux 12 (bookworm)  6.1.0-11-amd64  containerd://2.2.3-k3s1
matrix    Ready   control-plane  26d  v1.34.6+k3s1  192.168.1.202 <none>        Debian GNU/Linux 13 (trixie)  6.12.74+deb13+1-amd64  containerd://2.2.2-bd1.34
```

```
angel@Matrix:~$ kubectl describe node fallback | grep -A3 "Taints"
Taints:
  dedicated=fallback:NoSchedule
  Unschedulable: false
  Lease:
    HolderIdentity: fallback
angel@Matrix:~$
```



7. Fase 7 – Despliegue de LeIA → 2 / 4 semanas

Debido a la complejidad de la implementación de una IA de manera segura en un entorno como este, se ha preparado un despliegue por fases para mayor orden y facilidad operativa.

a. Fase 1: Esqueleto

En esta fase se ha creado la base técnica del servicio, Openclaw aún no tiene ninguna capacidad de raciocinio, pero existe como aplicación Python, además se añade la estructura del repositorio en GitHub y ciertas dependencias para un futuro.

Implementación:

Se observa openclaw ejecutandose y que FastAPI responde

```
angel@LeIA: /opt/openclaw$ sudo systemctl status openclaw --no-pager
[sudo] contraseña para angel:
● openclaw.service - OpenClaw - SaaSphere AI Orchestrator
   Loaded: loaded (/etc/systemd/system/openclaw.service; enabled; preset: enabled)
   Active: active (running) since Sun 2026-05-10 19:38:24 CEST; 5h 51min ago
     Invocation: 1905b24c67c446a7a37b2ef37691017d
       Main PID: 22035 (python)
         Tasks: 1 (limit: 37818)
        Memory: 43.4M (peak: 49.6M, swap: 5.1M, swap peak: 5.1M)
           CPU: 45.238s
      CGroup: /system.slice/openclaw.service
              └─22035 /opt/openclaw/.venv/bin/python -m openclaw

may 10 19:38:24 LeIA systemd[1]: Started openclaw.service - OpenClaw - SaaSphere AI Orchestrator.
may 10 19:38:25 LeIA openclaw[22035]: /opt/openclaw/.venv/lib/python3.13/site-packages/pydantic_settings/main.py:452: UserWarning: Config key 'toml_file' i
cls._settings_warn_unused_config_keys(sources, cls.model_config)
may 10 19:38:25 LeIA openclaw[22035]: {"version": "0.1.0", "env": "prod", "event": "openclaw.started", "level": "info", "timestamp": "2026-05-1.25.662486Z"}
Hint: Some lines were ellipsized, use -l to show in full.
angel@LeIA: /opt/openclaw$ curl -s http://127.0.0.1:8080/health | jq
{
  "status": "ok",
  "version": "0.1.0",
  "uptime_seconds": 21117.06
}
angel@LeIA: /opt/openclaw$
```

Las metricas estan correctamente expuestas y accesibles

```
angel@LeIA: /opt/openclaw$ curl -s http://127.0.0.1:8080/metrics | grep -E "openclaw|python_info|process_start" | head -30
# HELP python_info Python platform information
# TYPE python_info gauge
python_info{implementation="CPython",major="3",minor="13",patchlevel="5",version="3.13.5"} 1.0
# HELP process_start_time_seconds Start time of the process since unix epoch in seconds.
# TYPE process_start_time_seconds gauge
process_start_time_seconds 1.77843470483e+09
# HELP openclaw_info OpenClaw version info
# TYPE openclaw_info gauge
openclaw_info{version="0.1.0"} 1.0
# HELP openclaw_uptime_seconds Uptime in seconds
# TYPE openclaw_uptime_seconds gauge
openclaw_uptime_seconds 21175.02932858467
# HELP openclaw_errors_total Total errors
# TYPE openclaw_errors_total counter
# HELP openclaw_http_requests_total HTTP requests to OpenClaw
# TYPE openclaw_http_requests_total counter
angel@LeIA: /opt/openclaw$
```

Validación Ruff y mypy

```
angel@LeIA: /opt/openclaw$ uv run pytest -q
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
..... [100%]
64 passed in 1.15s
angel@LeIA: /opt/openclaw$ uv run ruff check .
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
All checks passed!
angel@LeIA: /opt/openclaw$ uv run mypy openclaw/
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
Success: no issues found in 29 source files
angel@LeIA: /opt/openclaw$
```

Conclusión:

Todo el sistema preparado para la siguiente fase, con las dependencias y programas necesarios instalados.



b. Fase 2: Cliente Ollama y agente base

Se integra Ollama en Openclaw mediante Pydantic AI, se implementa routing entre modelos, el modo think, las primeras herramientas y persistencia de información en sqlite, para aumentar la capacidad de memoria de la IA, teniendo su propia base de datos para no repetir errores.

Se añade un CLI para probar el agente, la tabla “decisiones” almacena cada decisión que tome Openclaw, almacenando caso de uso, el modelo, la latencia, los tokens consumidos, la conclusión y el resultado.

Implementación:

Modelos Qwen instalados

```

angel@LeIA:/opt/openclaw$ curl -s http://127.0.0.1:11434/api/tags | jq '.models[] | {name, parameter_size: .details.parameter_size, quantization: .details.quantization_level}'
[
  {
    "name": "qwen3:32b",
    "parameter_size": "32.8B",
    "quantization": "Q4_K_M"
  },
  {
    "name": "qwen3:8b",
    "parameter_size": "8.2B",
    "quantization": "Q4_K_M"
  }
]
angel@LeIA:/opt/openclaw$

```

Compatibilidad de Openclaw y Ollama

```

angel@LeIA:/opt/openclaw$ curl -s http://127.0.0.1:11434/v1/models | jq
{
  "object": "list",
  "data": [
    {
      "id": "qwen3:32b",
      "object": "model",
      "created": 1778291202,
      "owned_by": "library"
    },
    {
      "id": "qwen3:8b",
      "object": "model",
      "created": 1778290564,
      "owned_by": "library"
    }
  ]
}
angel@LeIA:/opt/openclaw$

```

CLI de Openclaw

```

angel@LeIA:/opt/openclaw$ uv run python -m openclaw.cli --help
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead

Usage: python -m openclaw.cli [OPTIONS] COMMAND [ARGS]...

OpenClaw manual operator CLI.

Options
  --install-completion  Install completion for the current shell.
  --show-completion    Show completion for the current shell, to copy it or customize the installation.
  --help               Show this message and exit.

Commands
  ask                Ask a question to the agent.
  decisions          Inspect persisted agent decisions.
  db                Database maintenance commands.

angel@LeIA:/opt/openclaw$

```

Sqlite completamente operativo

```

angel@LeIA:/opt/openclaw$ uv run python -m openclaw.cli db migrate
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
Database schema is up to date.
angel@LeIA:/opt/openclaw$

```



Primera prueba del agente qwen3:8b

```

angel@LeIA: /opt/openclaw$ OPENCLAW_OLLAMA_BASE_URL="http://127.0.0.1:11434/v1" \
uv run python -m openclaw.cli ask --case summary "preséntate como OpenClaw en una frase"
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
2026-05-11 02:02:29 [info] openclaw.decision.completed case_use=summary decision_id=509a65f0-f473-4a1f-b2f1-ec91509f15eb latency_ms=15453 model=qwen
3:8b outcome=success think_mode=False
¿Cómo puedo ayudarte hoy? Estoy listo para resumir información operativa o asistir en cualquier tarea relacionada con SaaSphere.
angel@LeIA: /opt/openclaw$

```

Decisión guardada en la base de datos

```

angel@LeIA: /opt/openclaw$ uv run python -m openclaw.cli decisions list --limit 5
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
2026-05-11T00:02:14.356436 509a65f0-f473-4a1f-b2f1-ec91509f15eb summary qwen3:8b think=False latency_ms=15453
¿Cómo puedo ayudarte hoy? Estoy listo para resumir información operativa o asistir en cualquier tarea relacionada con SaaSphere.
2026-05-10T22:59:37.162831 8a614858-565f-48cf-abfb-1589c617e97f conversation qwen3:32b think=True latency_ms=61973
OK
2026-05-10T22:49:45.276427 97a4488a-078a-4329-bd33-ca5fd15819de conversation qwen3:32b think=True latency_ms=361838
Request timed out.
2026-05-10T22:49:15.857698 b75df929-d777-49e1-ab6c-95a5ae978786 summary qwen3:8b think=False latency_ms=7488
Soy OpenClaw, el agente IA de orquestación de SaaSphere diseñado para resumir información operativa de forma breve y eficiente.
2026-05-10T20:51:55.893269 86ff43f8-3e42-4ee4-987d-8e8f1f62ed73 summary qwen3:8b think=False latency_ms=15853
Fase 2 confirmada como OK
angel@LeIA: /opt/openclaw$

```

Qwen3:32b funcionando, con mucho mayor tiempo de respuesta debido a mis limitaciones de hardware

```

angel@LeIA: /opt/openclaw$ OPENCLAW_OLLAMA_BASE_URL="http://127.0.0.1:11434/v1" uv run python -m openclaw.cli ask --case conversation "Quien eres?"
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
2026-05-11 02:08:22 [info] openclaw.decision.completed case_use=conversation decision_id=e6eacb6f-5294-4b29-8e50-2cce19503bcc latency_ms=62386 model=
=qwen3:32b outcome=success think_mode=True
Soy OpenClaw, el agente de inteligencia artificial de orquestación del ecosistema SaaSphere. Mi función es asistir a los operadores en tareas relacionadas c
on la nube, automatización y gestión de servicios, siguiendo principios de seguridad y precisión operativa. ¿En qué puedo ayudarte específicamente?
angel@LeIA: /opt/openclaw$

```

Y el registro

```

angel@LeIA: /opt/openclaw$ uv run python -m openclaw.cli decisions list --limit 3
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
2026-05-11T00:07:28.082898 e6eacb6f-5294-4b29-8e50-2cce19503bcc conversation qwen3:32b think=True latency_ms=62386
Soy OpenClaw, el agente de inteligencia artificial de orquestación del ecosistema SaaSphere. Mi función es asistir a los operadores en tareas relacionadas
con la nube, automatización y gestión de servicios, siguiendo principios de seguridad y precisión operativa. ¿En qué puedo ayudarte específicamente?
2026-05-11T00:05:38.619793 0e6d860f-c8eb-4fc6-97f1-6d19bf20f473 conversation qwen3:32b think=True latency_ms=66970
Puedo repetir o procesar textualmente cualquier información que me proporcionas, pero no tengo capacidad para "leer" ni acceder a documentos o decisiones
sin que seas tú quien me los comparta. ¿Te gustaría que te ayude con algo usando las herramientas disponibles (obtener hora actual, calcular expresiones sen
cillas o repetir textos)?
2026-05-11T00:03:40.529441 b53a9cb7-e555-4907-8b30-7fd024d37079 conversation qwen3:32b think=True latency_ms=98110
OK
angel@LeIA: /opt/openclaw$

```

Tablas SQLite

```

angel@LeIA: /opt/openclaw$ uv run python - <<'PY'
import sqlite3

db = "/var/lib/openclaw/state.db"
conn = sqlite3.connect(db)
tables = conn.execute(
    "SELECT name FROM sqlite_master WHERE type='table' ORDER BY name"
).fetchall()
print([t[0] for t in tables])
conn.close()
PY
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
['actions', 'approvals', 'decisions', 'events', 'metrics_snapshots', 'tenant_state']
angel@LeIA: /opt/openclaw$

```

Conclusión:

Modelos operativos y listos, se aprecia claramente la diferencia entre la respuesta de uno y de otro, el modelo de 32b ha dado una respuesta mas elaborada y con mayor contexto, pese a estar resumida, aun que el tiempo de ejecución ha sido mucho mayor, hay tareas para las que el tiempo no es relevante.



c. Fase 3: Tools de lectura

Se provee a Openclaw de herramientas de lectura sobre el entorno real, sin ninguna capacidad de actuación.

Prometheus permite consultar las métricas, Loki los logs, k3s los namespaces, SQLite el listado de decisiones y las herramientas de certificados preparan la lectura de TLS.

Implementación:

Se comprueba que Openclaw puede llegar a todas las conexiones externas

```

angel@LeIA: /opt/openclaw$ uv run python - <<'PY'
import socket

checks = [
    ("ollama", "127.0.0.1", 11434),
    ("openclaw", "127.0.0.1", 8080),
    ("prometheus", "192.168.1.201", 9090),
    ("loki", "192.168.1.201", 3100),
    ("grafana", "192.168.1.201", 3000),
    ("alertmanager", "192.168.1.201", 9093),
    ("matrix-k3s", "192.168.1.202", 6443),
    ("matrix-traefik-http-nodeport", "192.168.1.202", 32338),
    ("matrix-traefik-https-nodeport", "192.168.1.202", 31543),
]

for name, host, port in checks:
    try:
        with socket.create_connection((host, port), timeout=3):
            print(f"OK {name:32} {host}:{port}")
    except Exception as e:
        print(f"FAIL {name:30} {host}:{port} -> {type(e).__name__}: {e}")

PY
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
OK ollama 127.0.0.1:11434
OK openclaw 127.0.0.1:8080
OK prometheus 192.168.1.201:9090
OK loki 192.168.1.201:3100
OK grafana 192.168.1.201:3000
OK alertmanager 192.168.1.201:9093
OK matrix-k3s 192.168.1.202:6443
OK matrix-traefik-http-nodeport 192.168.1.202:32338
OK matrix-traefik-https-nodeport 192.168.1.202:31543
angel@LeIA: /opt/openclaw$

```

Cliente Prometheus funcionando contra Sauron

```

angel@LeIA: /opt/openclaw$ uv run python - <<'PY'
import asyncio
from openclaw.clients.prometheus import PrometheusClient

async def main():
    c = PrometheusClient("http://192.168.1.201:9090")
    try:
        result = await c.instant_query("up")
        print("prometheus up results:", len(result))
        for item in result[:10]:
            print(item.get("metric", {}), item.get("value"))
    finally:
        await c.close()

asyncio.run(main())

PY
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
prometheus up results: 13
{ '__name__': 'up', 'instance': 'fallback', 'job': 'node' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': 'localhost:9090', 'job': 'prometheus' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': 'sauron', 'job': 'node' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': '192.168.1.202', 'job': 'blackbox_icmp' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': 'grafana:3000', 'job': 'grafana' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': '192.168.1.203', 'job': 'blackbox_icmp' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': 'heimdall', 'job': 'node' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': 'matrix', 'job': 'node' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': '192.168.1.200', 'job': 'blackbox_icmp' } [1778458537.432, '1']
{ '__name__': 'up', 'instance': 'loki:3100', 'job': 'loki' } [1778458537.432, '1']
angel@LeIA: /opt/openclaw$

```



Loki accesible desde Openclaw para análisis de logs

```
angel@LeIA: /opt/openclaw$ uv run python - <<'PY'
import asyncio
from openclaw.clients.loki import LokiClient

async def main():
    c = LokiClient("http://192.168.1.201:3100")
    try:
        labels = await c.list_labels()
        print("loki labels:", labels)
    finally:
        await c.close()

asyncio.run(main())
PY
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
loki labels: ['host', 'job', 'level', 'service', 'service_name', 'unit']
angel@LeIA: /opt/openclaw$ |
```

Lectura de k3s desde LeIA

```
angel@LeIA: /opt/openclaw$ uv run python - <<'PY'
import asyncio
from openclaw.clients.k8s import K8sClient

async def main():
    client = K8sClient("/tmp/openclaw-kubecheck/kubeconfig")
    try:
        namespaces = await client.list_namespaces()
        print("namespaces:", len(namespaces))
        for ns in namespaces:
            print("-", ns.metadata.name)
    finally:
        await client.close()

asyncio.run(main())
PY
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
Traceback (most recent call last):
  File "<stdin>", line 14, in <module>
  File "/usr/lib/python3.13/asyncio/runners.py", line 195, in run
    return runner.run(main)
  File "/usr/lib/python3.13/asyncio/runners.py", line 118, in run
    return self._loop.run_until_complete(task)
  File "/usr/lib/python3.13/asyncio/base_events.py", line 725, in run_until_complete
    return future.result()
  File "<stdin>", line 5, in main
  File "/opt/openclaw/openclaw/clients/k8s.py", line 24, in __init__
    config=KubeConfig.from_file(kubeconfig_path),
  File "/opt/openclaw/.venv/lib/python3.13/site-packages/lightkube/config/kubeconfig.py", line 174, in from_file
    raise exceptions.ConfigError(f"Configuration file {fname} not found")
lightkube.core.exceptions.ConfigError: Configuration file /tmp/openclaw-kubecheck/kubeconfig not found
angel@LeIA: /opt/openclaw$ |
```

Test final

```
angel@LeIA: /opt/openclaw$ uv run pytest -q
uv run ruff check .
uv run mpy openclaw/
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
..... [100%]
64 passed in 1.11s
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
All checks passed!
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev'
instead
Success: no issues found in 29 source files
angel@LeIA: /opt/openclaw$ |
```



Primera prueba de uso real de openclaw, emplea las herramientas para indicarnos cuantos pods hay en el namespace.

```

angel@LeIA:/opt/openclaw$ cd /opt/openclaw && OPENCLAW_OLLAMA__BASE_URL="http://127.0.0.1:11434/v1" uv run python -m openclaw.cli ask --case health_loop_read "Que hay ejecutandose ahora mismo en kube-system?"
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
2026-05-11 21:58:44 [info] openclaw.decision.completed case_use=health_loop_read decision_id=0f7ed293-ce2a-4c13-97a2-384262d08885 latency_ms=14111 model=qwen3:8b outcome=success think_mode=False
En el namespace **kube-system** se están ejecutando los siguientes componentes clave:

### ✅ **Servicios en estado "Running"**:
1. **coredns-c4dbff5f-92p8r**
   - Función: Resolución DNS para el clúster.
   - Reinicios: 1.
2. **local-path-provisioner-5c4dc5d66d-fsdv5**
   - Función: Provee almacenamiento local para PersistentVolumes.
   - Reinicios: 1.
3. **metrics-server-786d997795-h2tct**
   - Función: Recopila métricas de recursos (CPU, memoria) de los nodos y pods.
   - Reinicios: 1.
4. **traefik-b665d6f48-s4zrj**
   - Función: Proveedor de balanceo de carga y proxy inverso.
   - Reinicios: 1.

### 🟡 **Pods en estado "Succeeded" (procesos completados)**:
- **helm-install-traefik-b5r5l** y **helm-install-traefik-crd-mnbwd**
  - Función: Instalación o despliegue inicial de Traefik (posiblemente completado).
  - No están en ejecución activa, pero indican que la instalación ha finalizado.

### 🔍 Observaciones:
- Los pods en "Running" son críticos para la operación del clúster.
- Los pods de Helm (Traefik) en "Succeeded" sugieren que su despliegue ha terminado, pero no están activos en este momento.
- Si necesitas detalles adicionales sobre algún componente, puedo profundizar.
angel@LeIA:/opt/openclaw$

```

Una pregunta más ambigua, para probar que no hace falta usar siempre prompts super elaborados, para facilitar su uso diario.

```

angel@LeIA:/opt/openclaw$ cd /opt/openclaw && OPENCLAW_OLLAMA__BASE_URL="http://127.0.0.1:11434/v1" uv run python -m openclaw.cli ask --case health_loop_read "Hay alguna alerta activa?"
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
2026-05-11 21:59:36 [info] openclaw.decision.completed case_use=health_loop_read decision_id=717a6a6-54f5-4ccf-9170-2e1cee8e1864 latency_ms=3752 model=qwen3:8b outcome=success think_mode=False
No hay alertas activas en este momento. El sistema está operando sin incidentes reportados. ¿Hay algo más que desee verificar?
angel@LeIA:/opt/openclaw$ cd /opt/openclaw && OPENCLAW_OLLAMA__BASE_URL="http://127.0.0.1:11434/v1" uv run python -m openclaw.cli ask --case health_loop_read "Puedes acceder a tus logs y decirme un resumen de que paso hoy mas o menos?"
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
2026-05-11 22:00:25 [info] openclaw.decision.completed case_use=health_loop_read decision_id=183e9ed9-9f29-435f-ae5f-e11cd8daaebc latency_ms=13877 model=qwen3:8b outcome=success think_mode=False
**Resumen de actividades recientes (últimas 5 entradas):**

1. **Verificación de alertas (19:59:32):**
   - 🟡 No se encontraron alertas activas. El sistema está operando sin incidentes reportados.

2. **Estado de pods en 'kube-system' (19:58:29):**
   - ✅ **Servicios en ejecución:**
     - 'coredns' (1 reinicio)
     - 'local-path-provisioner' (1 reinicio)
     - 'metrics-server' (1 reinicio)
   - 🟡 **Pods completados:**
     - 'helm-install-traefik' (sin reinicios)

3. **Revisión combinada de pods y alertas (19:56:34):**
   - ✅ Confirmación de estabilidad: ningún pod crítico fallando, y sin alertas activas.

4. **Detección de alertas (19:56:08):**
   - 🟡 Nueva verificación que confirma: **0 alertas activas**.

5. **Detalles de pods en 'kube-system' (19:54:40):**
   - 📊 Estado detallado de 4 pods, incluyendo reinicios y contenedores en ejecución.

**Conclusión operativa:**
El sistema está estable, sin alertas críticas. Los componentes clave en 'kube-system' están funcionando o completados correctamente. ¿Necesita revisar algo específico?
angel@LeIA:/opt/openclaw$

```

Conclusión:

Openclaw tiene capacidad de lectura, puede leer sobre las otras maquinas permitiendo así analizar todos los datos que necesite analizar, tanto de los logs como de la propia información de las maquinas, solo accediendo desde lo que sauron permite ver



d. Fase 4: Aprobación por telegram

LeIA necesita cierto control, por lo que para muchas cosas solicita aprobación, aquí se ha creado el sistema, haciendo una base de datos sqlite para almacenar las acciones y los permisos.

```

angel@LeIA:~$ sqlite3 /var/lib/openclaw/state.db ".tables"
actions          approvals      decisions      tenant_state
agent_state       approvals_legacy  events         tool_requests
alembic_version   conversation_turns metrics_snapshots

angel@LeIA:~$ sqlite3 /var/lib/openclaw/state.db "PRAGMA table_info(approvals);"
sqlite3 /var/lib/openclaw/state.db "PRAGMA table_info(agent_state);"
0|id|VARCHAR|1||1
1|requested_at|DATETIME|1||0
2|case_use|VARCHAR|1||0
3|action_type|VARCHAR|1||0
4|action_payload|JSON|1||0
5|tenant_namespace|VARCHAR|0||0
6|severity|VARCHAR|1||0
7|status|VARCHAR|1||0
8|expires_at|DATETIME|1||0
9|decided_at|DATETIME|0||0
10|decided_by_user_id|INTEGER|0||0
11|decision_reason|VARCHAR|0||0
12|telegram_chat_id|INTEGER|0||0
13|telegram_message_id|INTEGER|0||0
14|reminder_count|INTEGER|1|'0'|0
15|last_reminder_at|DATETIME|0||0
16|related_decision_id|VARCHAR|0||0
0|id|INTEGER|1||1
1|mode|VARCHAR|1|'normal'|0
2|reason|VARCHAR|0||0
3|changed_at|DATETIME|1||0
4|changed_by_user_id|INTEGER|0||0
angel@LeIA:~$ sqlite3 /var/lib/openclaw/state.db "SELECT * FROM agent_state;"
"
1|normal||2026-05-11 20:58:16|
angel@LeIA:~$

```

Además se ha generado una tabla de comprobación de estado, ya que en muchas ocasiones se pueden evitar llamadas fallidas al modelo parando las ejecuciones si esta ocupado.


```

angel@LeIA:/opt/openclaw$ oc state get
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
normal changed_at=2026-05-11T20:58:16 reason=demo dry_run
angel@LeIA:/opt/openclaw$ oc state set dry_run --reason "demo fase 4"
oc state get
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
dry_run
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
dry_run changed_at=2026-05-13T22:00:54.788422 reason=demo fase 4
angel@LeIA:/opt/openclaw$ oc state set normal --reason "fin demo dry_run"
oc state get
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
normal
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
normal changed_at=2026-05-13T22:01:25.132807 reason=demo pausa operativa
angel@LeIA:/opt/openclaw$ oc state set paused --reason "demo pausa operativa"
oc state get
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
paused
warning: The 'tool.uv.dev-dependencies' field (used in 'pyproject.toml') is deprecated and will be removed in a future release; use 'dependency-groups.dev' instead
paused changed_at=2026-05-13T22:01:30.262297 reason=resume demo
angel@LeIA:/opt/openclaw$

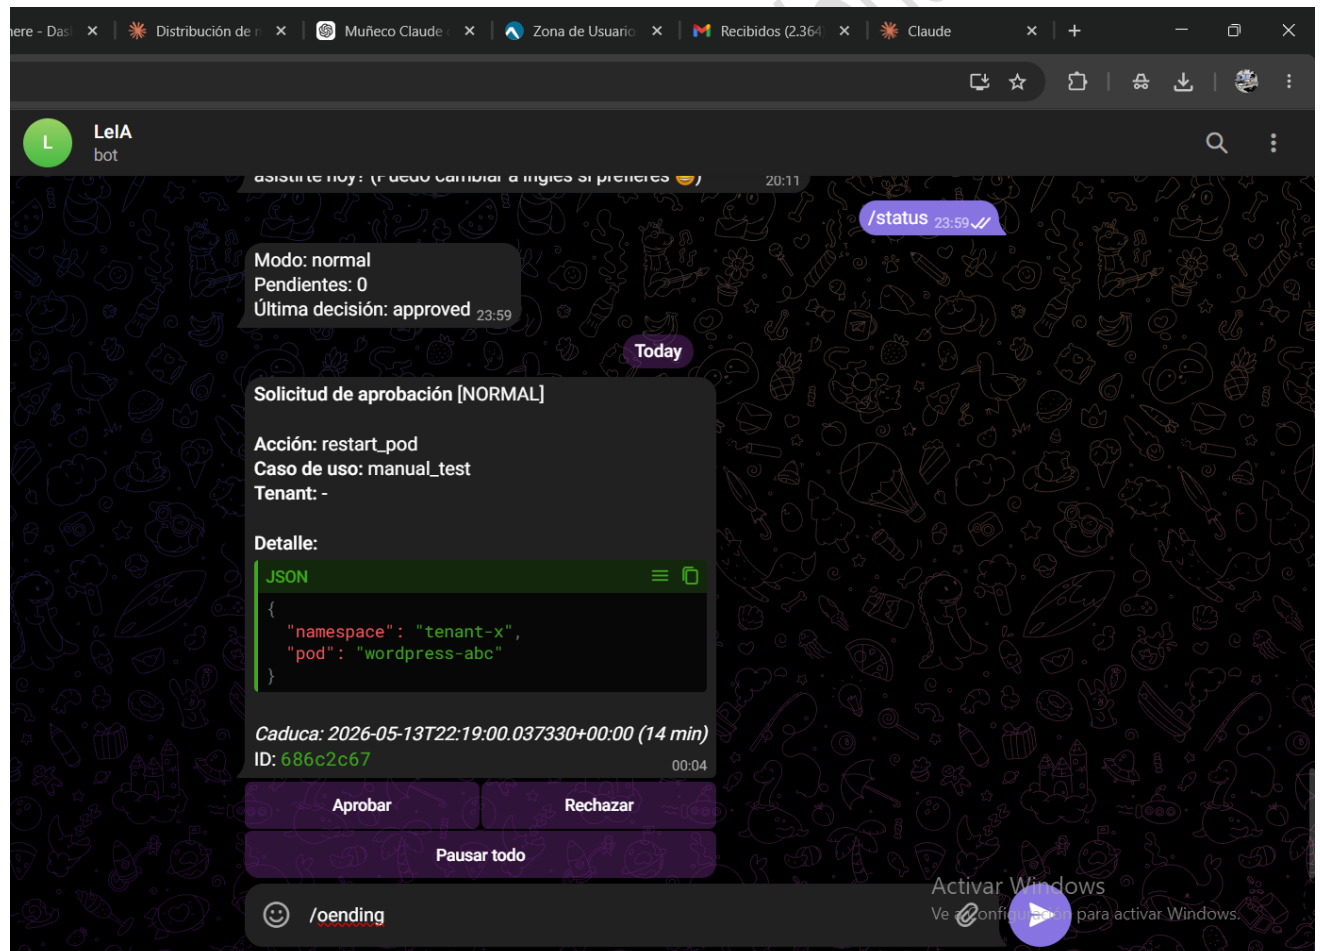
```



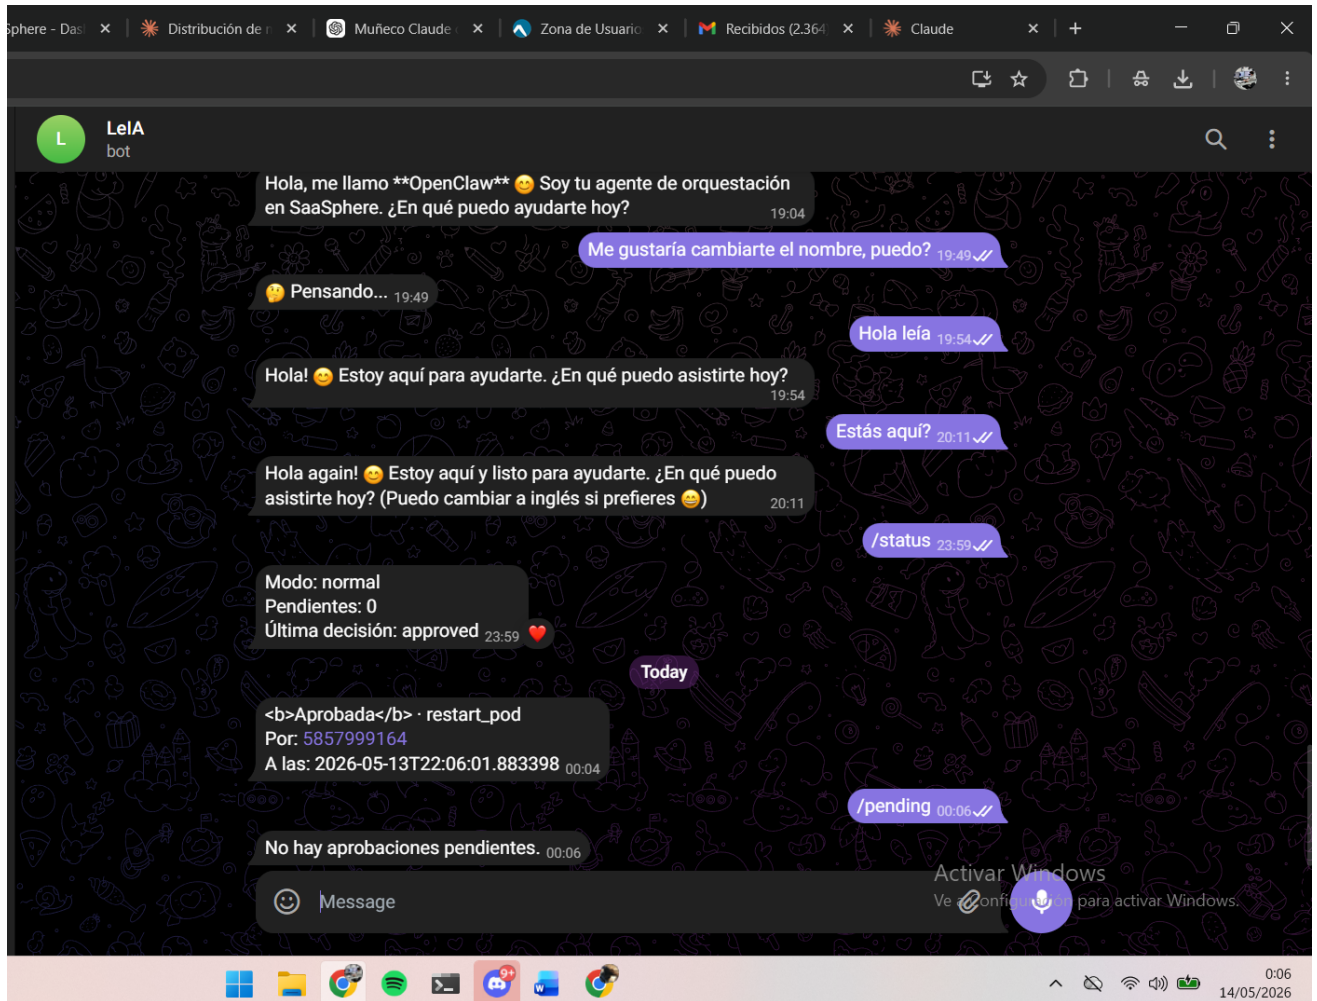
Se va a crear una demo de prueba para probar el sistema de aprobaciones, al mismo momento de escribir esto, se han ido lanzando los comandos de prueba, aquí la prueba de que llega notificación de aprobación



Desde Telegram se pide la aprobación, y cambia de estado al hacer clic



Y el cambio de estado

**Conclusión**

Se ha construido un mecanismo de control humano, para que antes de que ejecute todas sus capacidades reales, tenga que pedir permiso, aun no tiene herramientas para reiniciar pods, escalar o modificar, pero las tendra, y para algunas de ellas pedirá confirmación previa a reiniciar nada.

Ademas se ha añadido trazabilidad, cada decisión esta documentada de manera que, si en algún momento se añaden terceros usuarios con acceso al bot, se registrara quien ha autorizado que acciones.

La aprobación no debe de ser inmediata, puede quedar pendiente de ejecución perfectamente, y cuando se apruebe lanzarse la tarea.

Se han integrado comprobaciones de estado mediante telegram, se puede parar al agente, pausarlo... Por último se han añadido estados al agente, a mayores del modo pausa, o parado, tiene el modo dry-run, que solo "probara" a hacer las cosas previo a tocar nada.



e. Fase 5: Tools

Se otorga permiso de trabajo sobre la estructura, permitiendo reinicios, backups, whitelist de namespaces, bloqueo de acciones peligrosas...

Lo primero es registrar cada cosa que va a hacer LeIA, y limitarla a ciertas acciones, aquí prueba de la base de datos de acciones y de la política.

```

angel@LeIA:/opt/openclaw$ sudo -u openclaw /opt/openclaw/.venv/bin/python -m openclaw.cli actions list --limit 5
2026-05-12T22:02:08.120128 cb18a955-fada-4643-842d-dfacb88db335 completed critical deploy_tenant demo-tfg/demo-tfg
2026-05-12T22:00:15.247698 eec22411-1a23-40e6-835b-bea4b51e8fe9 failed critical deploy_tenant demo-tfg/demo-tfg
2026-05-12T21:16:47.727481 5f388874-45fa-4be1-ad50-2e9ddfla7ab7 rejected critical deploy_tenant demo-tfg/demo-tfg
2026-05-12T20:47:14.167231 53fbab1d-8f70-474a-b866-1f59c848972f completed autonomous restart_pod tenant-test/crash-app-7c456f6b5b-mzdfh
2026-05-12T20:40:42.280929 81937bec-b2a4-4c1c-a806-4cc6078fd753 failed autonomous restart_pod tenant-test/crash-app-7c456f6b5b-mzdfh
angel@LeIA:/opt/openclaw$ sudo -u openclaw /opt/openclaw/.venv/bin/python -c "
from openclaw.domain.policy import Policy
p = Policy()
result = p.validate('restart_pod', 'kube-system', 'coredns')
print(result)
"
Traceback (most recent call last):
  File "<string>", line 2, in <module>
    from openclaw.domain.policy import Policy
ImportError: cannot import name 'Policy' from 'openclaw.domain.policy' (/opt/openclaw/openclaw/domain/policy.py)
angel@LeIA:/opt/openclaw$

```

Estas son las acciones que tiene prohibidas, ni si quiera pide aprobación

```

angel@LeIA:/opt/openclaw$ sudo -u openclaw /opt/openclaw/.venv/bin/python -c "
from openclaw.domain.policy import validate, SYSTEM_NAMESPACES
print('Namespaces prohibidos:', SYSTEM_NAMESPACES)
result = validate('restart_pod', 'kube-system', 'coredns')
print('Resultado policy:', result)
"
Namespaces prohibidos: {'kube-public', 'kube-system', 'metallb-system', 'saasphere-system'}
Resultado policy: PolicyDecision(allowed=False, severity=<ActionSeverity.FORBIDDEN: 'forbidden'>, reason='namespace is hard-blocked', violations=['namespace_hard_block'])
angel@LeIA:/opt/openclaw$

```

Aquí se aprecia que funciona correctamente, ya que es una comprobación del log de acciones, y es de la aborted_policy, ya que el namespace “saasphere-system” no esta en la whitelist

```

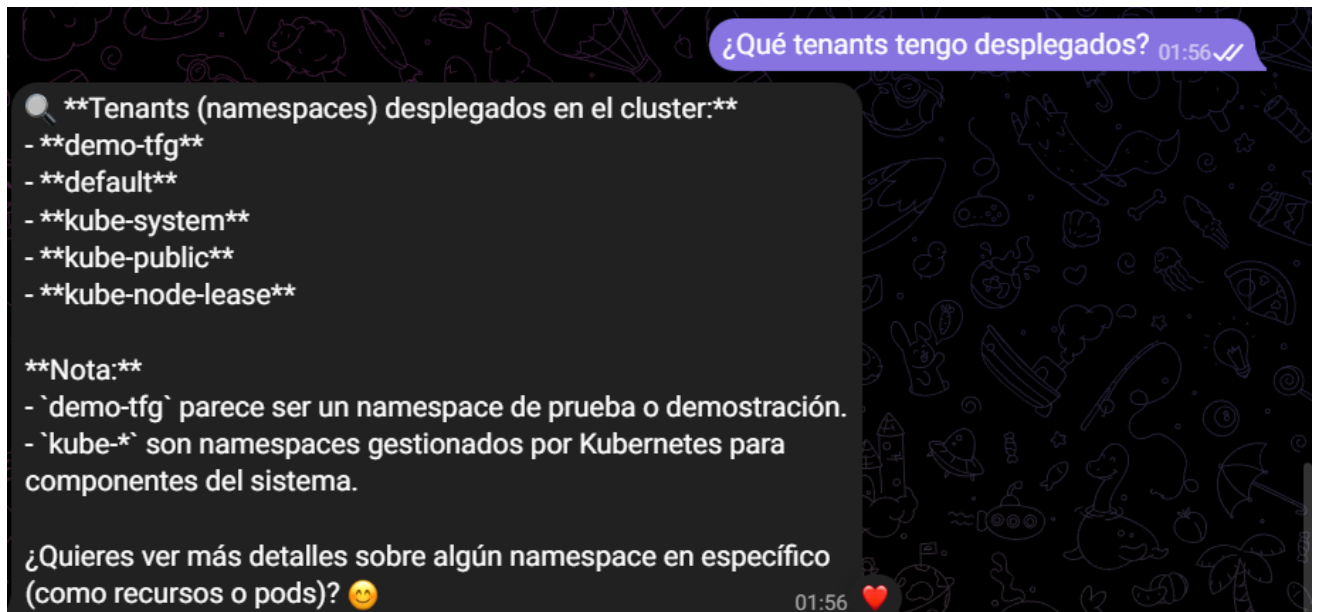
angel@LeIA:/opt/openclaw$ sudo -u openclaw /opt/openclaw/.venv/bin/python -m openclaw.cli actions list | grep restart_pod
2026-05-12T20:47:14.167231 53fbab1d-8f70-474a-b866-1f59c848972f completed autonomous restart_pod tenant-test/crash-app-7c456f6b5b-mzdfh
2026-05-12T20:40:42.280929 81937bec-b2a4-4c1c-a806-4cc6078fd753 failed autonomous restart_pod tenant-test/crash-app-7c456f6b5b-mzdfh
2026-05-12T20:26:38.848429 0e027c67-3620-4cca-98a2-89c8110647a7 aborted_policy forbidden restart_pod saasphere-system/test-crash
angel@LeIA:/opt/openclaw$ sudo -u openclaw /opt/openclaw/.venv/bin/python -m openclaw.cli actions show 0e027c67-3620-4cca-98a2-89c8110647a7
{
  "action_type": "restart_pod",
  "approval_id": null,
  "category": "restart_pod",
  "created_at": "2026-05-12T20:26:38.848429",
  "decision_id": null,
  "dry_run": false,
  "error": null,
  "id": "0e027c67-3620-4cca-98a2-89c8110647a7",
  "idempotency_key": null,
  "namespace": "saasphere-system",
  "payload": "{\n  \"container_statuses\": [\n    {\n      \"name\": \"test-crash\", \"ready\": false, \"reason\": \"CrashLoopBackOff\", \"restart_count\": 7\n    },\n    {\n      \"name\": \"saasphere-system\", \"namespace_labels\": {\n        \"saasphere-system\": {\n          \"kubernetes.io/metadata.name\": \"saasphere-system\"\n        },\n        \"owner_references\": [\n          {\n            \"name\": \"test-crash\", \"pod_phase\": \"Running\"\n          }\n        ]\n      }\n    },\n    {\n      \"reason\": \"namespace is not tenant-whitelisted\", \"violations\": [\"tenant_whitelist\"]\n    }\n  ],\n  \"severity\": \"forbidden\", \"state\": \"aborted_policy\", \"status\": \"aborted_policy\", \"target\": \"test-crash\", \"target_kind\": null, \"target_name\": \"test-crash\", \"target_namespace\": \"saasphere-system\", \"timestamp_created\": \"2026-05-12T20:26:38.848462\", \"timestamp_finished\": null, \"timestamp_started\": null, \"updated_at\": \"2026-05-12T20:26:38.849099\"\n}",
  "result": "{\n  \"reason\": \"namespace is not tenant-whitelisted\", \"violations\": [\"tenant_whitelist\"]\n}",
  "severity": "forbidden",
  "state": "aborted_policy",
  "status": "aborted_policy",
  "target": "test-crash",
  "target_kind": null,
  "target_name": "test-crash",
  "target_namespace": "saasphere-system",
  "timestamp_created": "2026-05-12T20:26:38.848462",
  "timestamp_finished": null,
  "timestamp_started": null,
  "updated_at": "2026-05-12T20:26:38.849099"
}
angel@LeIA:/opt/openclaw$

```

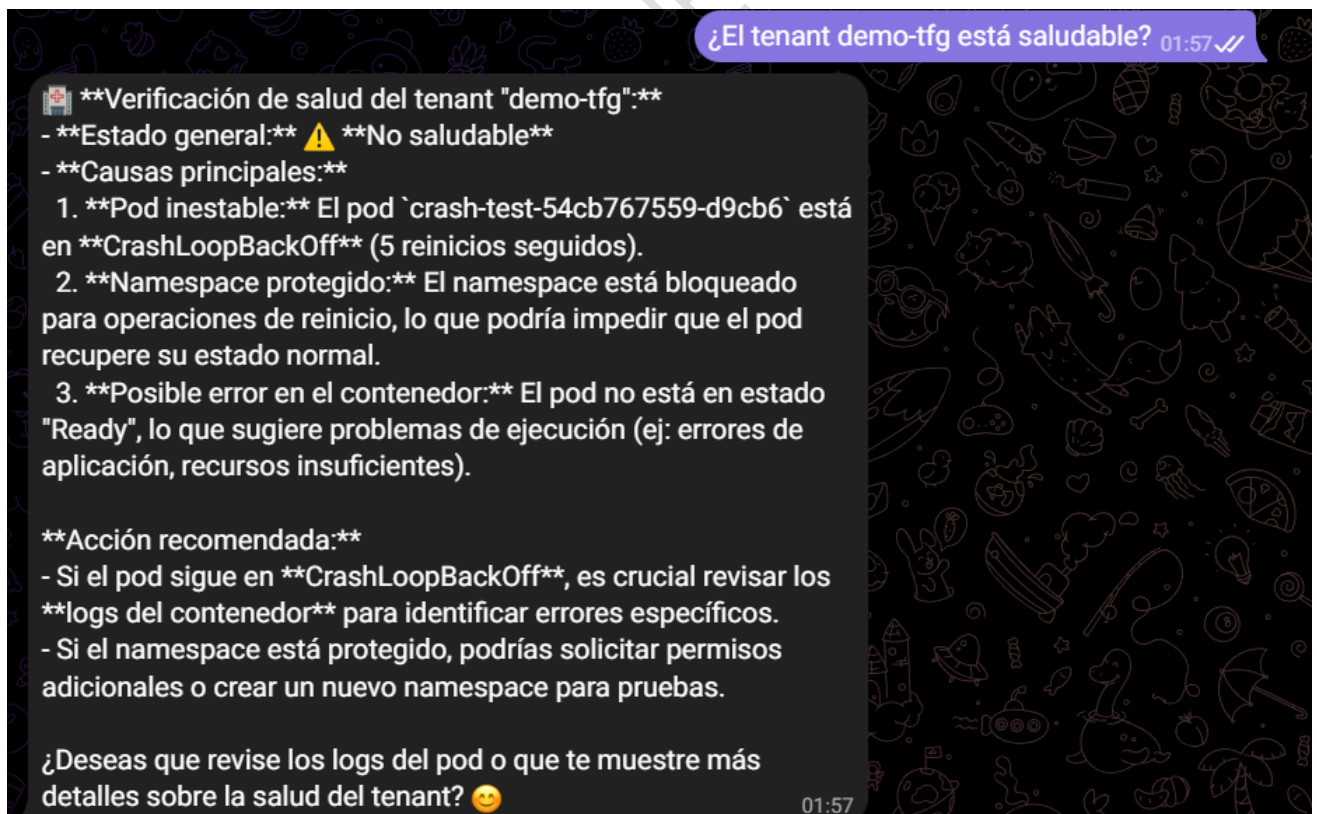


LeIA tiene muchas herramientas funcionales para mantenimiento, para demostrar su funcionamiento, se va a proceder a crear un nuevo tenant para un cliente, sin tocar la línea de comandos, además de comprobar su estado, pararlos y reiniciarlos.

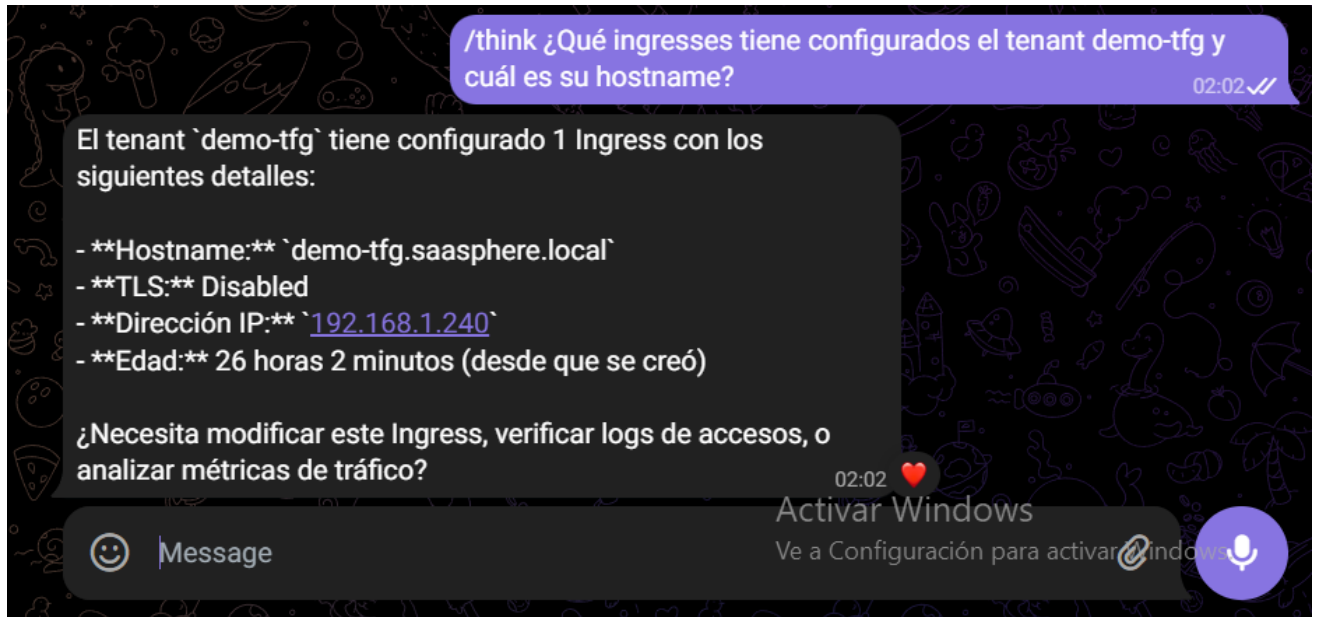
Ahora se demuestra el ciclo completo de un Tenant, lo primero será listarlos



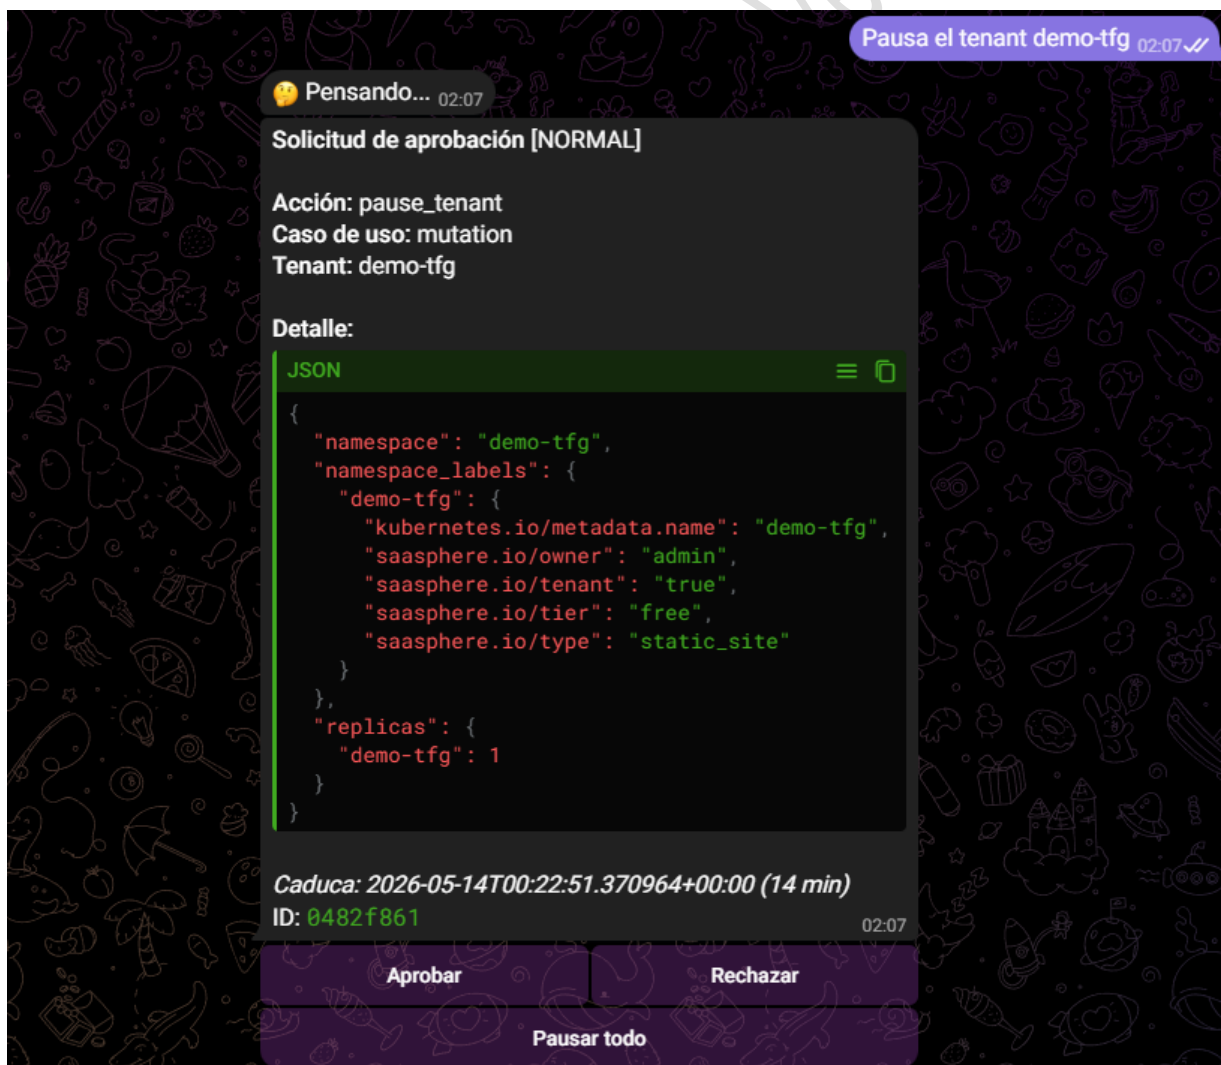
Se puede comprobar la salud de un tenant



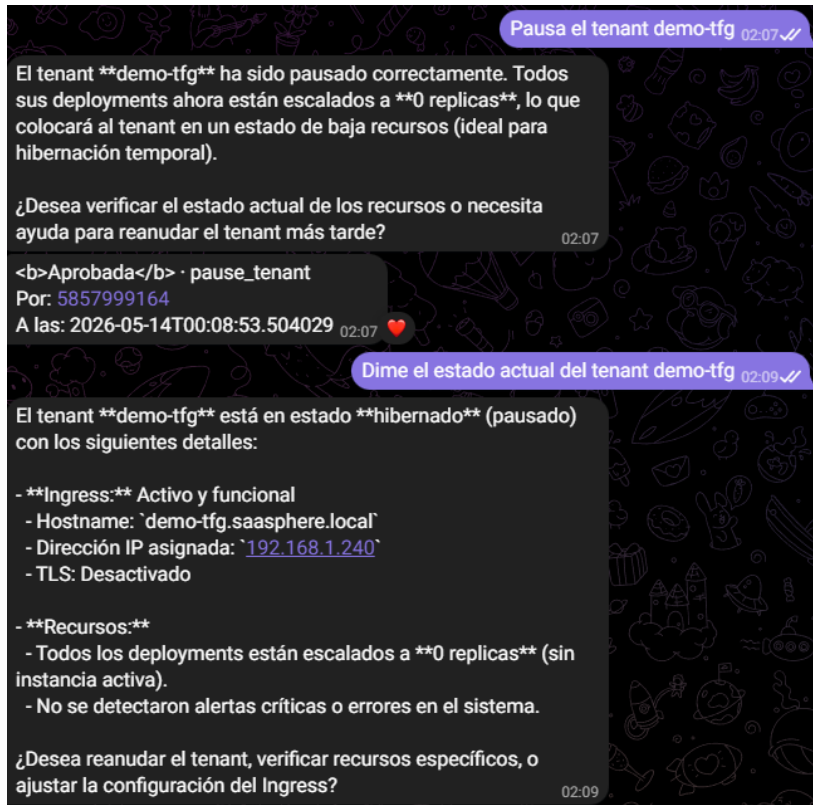
El ingress funciona



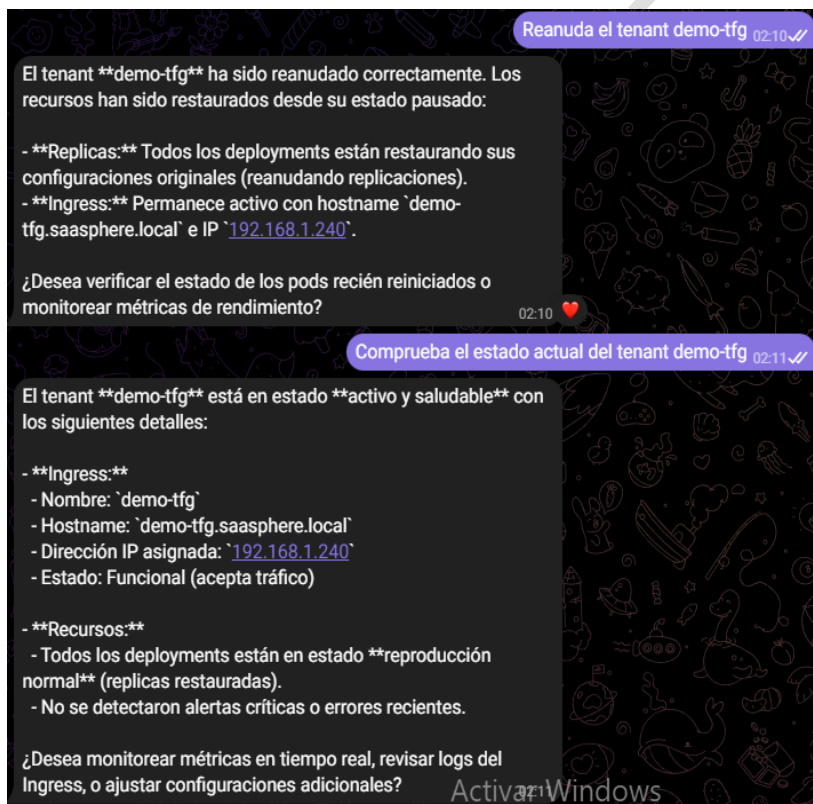
Para realizar la pausa nos pide confirmación



Y tras solicitar la pausa, comprobamos el estado y vemos que ha funcionado



Lo reactivamos y comprobamos su estado



Y comprobamos si se han guardado todas las acciones

```

angel@LeIA:~$ sudo -u openclaw /opt/openclaw/.venv/bin/python -m openclaw.cli actions list | head -10
[sudo] contraseña para angel:
2026-05-14T00:11:10.115422 0fed050b-5e1c-4d2f-ae03-8477ea4b2598 completed autonomous verify_tenant_health demo-tfg/demo-tfg
2026-05-14T00:10:39.036012 563cfe24-df09-4765-ad40-de342d8729f5 completed autonomous resume_tenant demo-tfg/demo-tfg
2026-05-14T00:09:23.051434 9ac2eb09-d7e5-4bab-b95d-add52c76c7f6 completed autonomous verify_tenant_health demo-tfg/demo-tfg
2026-05-14T00:07:51.352709 5642349a-8a2b-43c8-b6d5-f9a9ca0ca358 completed normal pause_tenant demo-tfg/demo-tfg
2026-05-13T23:35:06.596605 a6321944-bffe-499c-b46d-dea8e31629e3 aborted_policy forbidden restart_pod demo-tfg/crash-test-54cb767559-d9cb6
2026-05-12T22:02:08.120128 cb18a955-fada-4643-842d-dfacb88db335 completed critical deploy_tenant demo-tfg/demo-tfg
2026-05-12T22:00:15.247698 eec22411-1a23-40e6-835b-bea4b51e8fe9 failed critical deploy_tenant demo-tfg/demo-tfg
2026-05-12T21:16:47.727481 5f388874-45fa-4be1-ad50-2e9ddfla7ab7 rejected critical deploy_tenant demo-tfg/demo-tfg
2026-05-12T20:47:14.167231 53fba81d-8f70-474a-b866-1f59c848972f completed autonomous restart_pod tenant-test/crash-app-7c456f6b5b-mzdfh
2026-05-12T20:40:42.280929 81937bec-b2a4-4c1c-a806-4cc6078fd753 failed autonomous restart_pod tenant-test/crash-app-7c456f6b5b-mzdfh
angel@LeIA:~$

```

Ahora voy a crear un primer cliente de prueba con su propio tenant, así de simple:

```

Crea un tenant Today: static_site llamado prueba-tfg con tier free 02:22 ✓

El tenant **prueba-tfg** ha sido desplegado correctamente en el
dominio [https://prueba-tfg.saasphere.local](https://prueba-
tfg.saasphere.local). Sin embargo, existe un estado pendiente
relacionado con el almacenamiento persistente (PVC):

### ✓ Despliegue exitoso:
- **URL del sitio:** [https://prueba-tfg.saasphere.local]
  (https://prueba-tfg.saasphere.local)
- **Tier asignado:** 'free'
- **Correo administrador:** 'admin@saasphere.local'

### ⚠ Pendiente: PVC en el nodo 'matrix'
El sistema detecta que el PVC (Persistent Volume Claim) para el
almacenamiento del sitio aún no está vinculado a un volumen
persistente. Esto podría afectar la capacidad del sitio para
almacenar datos estáticos (como archivos HTML, imágenes,
etc.).

-

### ¿Qué hacer?
1. **Verifica el estado del PVC:**
  ```bash
 kubectl get pvc -n prueba-tfg
  ```
  Si el PVC está en estado 'Pending', necesitarás crear un
  'PersistentVolume' (PV) asociado.

2. **Crea un PersistentVolume (PV):**
  Ejemplo básico (ajusta según tus necesidades):
  ```yaml
 apiVersion: v1
 kind: PersistentVolume
 metadata:
 name: static-site-pv
 spec:
 capacity:
 storage: 1Gi
 accessModes:
 - ReadWriteMany
 hostPath:
 path: /mnt/data
  ```
  > ⚠ En entornos reales, usarías un proveedor de
  almacenamiento como AWS EBS, GCP PD, o NFS.

```

```

2. **Crea un PersistentVolume (PV):**
  Ejemplo básico (ajusta según tus necesidades):
  ```yaml
 apiVersion: v1
 kind: PersistentVolume
 metadata:
 name: static-site-pv
 namespace: prueba-tfg
 spec:
 capacity:
 storage: 1Gi
 accessModes:
 - ReadWriteMany
 hostPath:
 path: /mnt/data
  ```
  > ⚠ En entornos reales, usarías un proveedor de
  almacenamiento como AWS EBS, GCP PD, o NFS.

3. **Vincula el PVC al PV:**
  ```bash
 kubectl create -f static-site-pv.yaml
  ```

4. **Revisa el despliegue:**
  ```bash
 kubectl get all -n prueba-tfg
  ```


¿Desea ayuda para crear el PVC o ajustar la configuración del
sitio estático? 02:22 ❤️

<b>Aprobada</b> · deploy_tenant
Por: 585/999164
A las: 2026-05-14T00:22:51.423929 02:22

```



Con esto tenemos nuestro cliente creado, funciona mediante traefik (DNS) así que voy a configurar mi DNS de windows rápidamente para encontrar la dirección.




The screenshot shows a Windows PowerShell window with the command `notepad C:\Windows\System32\drivers\etc\hosts` executed. Below it, a Notepad window titled 'hosts' is open, displaying the following content:

```
192.168.1.140 daily.es
192.168.1.240 prueba-tfg.saasphere.local
192.168.1.240 demo-tfg.saasphere.local
```

The status bar at the bottom of Notepad indicates 'Ln 26, Col 41', '911 caracteres', 'Texto sin formato', '100%', 'Windows (CRLF)', and 'UTF-8 con BOM'.

Y al probar la dirección que me ha dado LeIA, conecta correctamente



Con esto concluye la fase 5



f. Fase 6: Triggers, scheduling y reactividad

La fase 6 convierte a LeIA en un agente completamente autónomo. Deja de necesitar que se le envíen prompts y comienza a actuar con iniciativa, monitorizando el clúster de k3s cada cinco minutos, detectando anomalías, analizándolas y notificándolas vía telegram, esto se hace mediante:

- **Scheduler:** Ejecuta tareas programadas de comprobación, de backup, resumen, optimización...
- **K3s Watcher:** Escucha los eventos de kubernetes en tiempo real.
- **Webhook de Alertmanager:** Recibe las alertas de prometheus, loki...

Demostración

En cuanto Openclaw entra en ejecución, se ejecutan de manera automática, se ejecutan tareas de comprobación de estado cada 5 minutos, estado global cada 30, resumen del estado cada hora, resumen diario a las 08:00 de la mañana, verificación de backups a las 02:00 y optimización de pods a las 02:00.

Aquí se puede apreciar todas las tareas programadas.

```
angel@LeIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep -E 'scheduler.started|k8s_watcher.started|k8s_watcher.connected'
may 14 20:48:39 LeIA openclaw[24893]: {"jobs": 6, "timezone": "Europe/Madrid", "event": "openclaw.scheduler.started", "level": "info", "timestamp": "2026-05-14T18:48:39.987203Z"}
may 14 20:48:39 LeIA openclaw[24893]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T18:48:39.987260Z"}
may 14 20:48:39 LeIA openclaw[24893]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T18:48:39.994252Z"}
may 14 21:28:41 LeIA openclaw[109568]: {"jobs": 6, "timezone": "Europe/Madrid", "event": "openclaw.scheduler.started", "level": "info", "timestamp": "2026-05-14T19:28:41.387852Z"}
may 14 21:28:41 LeIA openclaw[109568]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T19:28:41.387918Z"}
may 14 21:28:41 LeIA openclaw[109568]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T19:28:41.395223Z"}
may 14 21:31:09 LeIA openclaw[111819]: {"jobs": 6, "timezone": "Europe/Madrid", "event": "openclaw.scheduler.started", "level": "info", "timestamp": "2026-05-14T19:31:09.644853Z"}
may 14 21:31:09 LeIA openclaw[111819]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T19:31:09.644911Z"}
may 14 21:31:09 LeIA openclaw[111819]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T19:31:09.651726Z"}
may 14 21:39:55 LeIA openclaw[113563]: {"jobs": 6, "timezone": "Europe/Madrid", "event": "openclaw.scheduler.started", "level": "info", "timestamp": "2026-05-14T19:39:55.288448Z"}
may 14 21:39:55 LeIA openclaw[113563]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T19:39:55.288506Z"}
may 14 21:39:55 LeIA openclaw[113563]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T19:39:55.295161Z"}
angel@LeIA:/opt/openclaw$
```

Cada 5 minutos se ejecuta el "Health_loop_read", que comprueba el estado de los pods y si esta bien no pasa nada, si detecta algún problema, escala al análisis profundo de manera autónoma, sin recibir órdenes.

```
angel@LeIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep 'health_loop_read' | tail -5 | awk '{print; print "\033[32m-----\033[0m"}'
may 14 22:11:00 LeIA openclaw[113563]: {"decision_id": "ac8f1cb-a661-4c46-8c2a-0740e67b3d08", "case_use": "health_loop_read", "model": "qwen3:8b", "think_mode": false, "outcome": "success", "latency_ms": 64985, "event": "openclaw.decision.completed", "level": "info", "timestamp": "2026-05-14T20:11:00.295291Z"}
may 14 22:11:00 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:11:00.295372Z"}
may 14 22:14:55 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.job.start", "level": "info", "timestamp": "2026-05-14T20:14:55.288233Z"}
may 14 22:15:14 LeIA openclaw[113563]: {"decision_id": "959b48c4-7d8c-43ba-9703-d973d23ab6f5", "case_use": "health_loop_read", "model": "qwen3:8b", "think_mode": false, "outcome": "success", "latency_ms": 19694, "event": "openclaw.decision.completed", "level": "info", "timestamp": "2026-05-14T20:15:14.989290Z"}
may 14 22:15:14 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:15:14.989400Z"}
angel@LeIA:/opt/openclaw$
```

Siempre se analiza el log buscando errores, pero en caso de que los encuentre se lanza una tarea automática de análisis profundo, para encontrar y reiniciar el pod con error.

```
angel@LeIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep 'anomaly_detected'
may 14 20:54:17 LeIA openclaw[24893]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T18:54:17.763276Z"}
may 14 21:15:47 LeIA openclaw[24893]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T19:15:47.823822Z"}
may 14 21:36:47 LeIA openclaw[111819]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T19:36:47.744719Z"}
may 14 21:45:24 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T19:45:24.012089Z"}
may 14 21:50:16 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T19:50:16.468567Z"}
may 14 21:55:43 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T19:55:43.152342Z"}
may 14 22:00:34 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:00:34.907723Z"}
may 14 22:05:18 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:05:18.886372Z"}
may 14 22:11:00 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:11:00.295372Z"}
may 14 22:15:14 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:15:14.989400Z"}
may 14 22:20:22 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:20:22.824746Z"}
may 14 22:25:23 LeIA openclaw[113563]: {"case_use": "health_loop_read", "event": "openclaw.scheduler.anomaly_detected", "level": "info", "timestamp": "2026-05-14T20:25:23.601722Z"}
angel@LeIA:/opt/openclaw$
```



Como se ha descrito arriba, el análisis profundo usa el modelo de 8b con el modo /think, para poder dedicar mas tiempo para obtener una respuesta más razonada, tendrá permiso a mirar pods en K3s, logs de loki, métricas prometheus....

```

current session x angel@leIA: /opt/openclaw x + v
angel@leIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep 'health_loop_analyze' | tail -5 | awk '{print; print "\033[32m-----\033[0m}"'
may 14 22:15:55 leIA openclaw[113563]: {"error": "Telegram server says - Bad Request: can't parse entities: Unsupported start tag \"pod-name\" at byte offset 1913", "event": "openclaw.scheduler.analyze_phase.exception", "level": "error", "timestamp": "2026-05-14T20:15:55.708265Z", "exception": "Traceback (most recent call last):\n File \"/opt/openclaw/openclaw/scheduler.py", line 266, in run_analyze_phase\n await self.notifier.send_to_admin(\n File \"/opt/openclaw/openclaw/telegram/notifier.py", line 69, in send_to_admin\n await self.bot.send_message(\n # type: ignore[union-attr]\n ...<3 lines>...\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/bot.py", line 2942, in send_message\n return await self.call_request_timeout(request_timeout)\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/bot.py", line 504, in _call\n return await self.session(self, method, timeout=request_timeout)\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/session/base.py", line 259, in _call\n return cast(TelegramType, await middleware(bot, method))\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/session/aiohttp.py", line 177, in make_request\n response = self.check_response(\n bot=bot, \n ...<2 lines>...\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/session/base.py", line 121, in check_response\n raise TelegramBadRequest(method=method, message=description)\naiogram.exceptions.TelegramBadRequest: Telegram server says - Bad Request: can't parse entities: Unsupported start tag \"pod-name\" at byte offset 1913"}
may 14 22:21:02 leIA openclaw[113563]: {"decision_id": "c7ae5a8b-d14d-4ecc-bafe-1bc484519f3a", "case_use": "health_loop_analyze", "model": "qwen3:8b", "think_mode": true, "outcome": "success", "latency_ms": 39234, "event": "openclaw.decision.completed", "level": "info", "timestamp": "2026-05-14T20:21:02.061633Z"}
may 14 22:26:09 leIA openclaw[113563]: {"decision_id": "b494038e-131e-4ba8-b3a2-ee350c676605", "case_use": "health_loop_analyze", "model": "qwen3:8b", "think_mode": true, "outcome": "success", "latency_ms": 45676, "event": "openclaw.decision.completed", "level": "info", "timestamp": "2026-05-14T20:26:09.282140Z"}
may 14 22:31:26 leIA openclaw[113563]: {"decision_id": "45545ed7-b2b2-4b5e-a41c-a72d39fc6774", "case_use": "health_loop_analyze", "model": "qwen3:8b", "think_mode": true, "outcome": "success", "latency_ms": 63526, "event": "openclaw.decision.completed", "level": "info", "timestamp": "2026-05-14T20:31:26.510218Z"}
may 14 22:31:26 leIA openclaw[113563]: {"error": "Telegram server says - Bad Request: can't parse entities: Unsupported start tag \"pod-name\" at byte offset 1056", "event": "openclaw.scheduler.analyze_phase.exception", "level": "error", "timestamp": "2026-05-14T20:31:26.658020Z", "exception": "Traceback (most recent call last):\n File \"/opt/openclaw/openclaw/scheduler.py", line 266, in run_analyze_phase\n await self.notifier.send_to_admin(\n File \"/opt/openclaw/openclaw/telegram/notifier.py", line 69, in send_to_admin\n await self.bot.send_message(\n # type: ignore[union-attr]\n ...<3 lines>...\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/bot.py", line 2942, in send_message\n return await self.call_request_timeout(request_timeout)\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/bot.py", line 504, in _call\n return await self.session(self, method, timeout=request_timeout)\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/session/aiohttp.py", line 177, in make_request\n response = self.check_response(\n bot=bot, \n ...<2 lines>...\n File \"/opt/openclaw/.venv/lib/python3.13/site-packages/aiogram/client/session/base.py", line 121, in check_response\n raise TelegramBadRequest(method=method, message=description)\naiogram.exceptions.TelegramBadRequest: Telegram server says - Bad Request: can't parse entities: Unsupported start tag \"pod-name\" at byte offset 1056"}
angel@leIA:/opt/openclaw$ |

```

Reinicio de un Pod sin intervención: Esta es la capacidad mas avanzada que tiene leIA, puede reiniciar un pod de clúster si detecta anomalías dentro de alguno de los logs o de las métricas.

```

current session x angel@leIA: /opt/openclaw x + v
angel@leIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep 'restart_pod.called'
may 14 21:20:44 leIA openclaw[24893]: {"namespace": "default", "pod_name": "app-6c98d6c485-28qkp", "mutation_context_present": true, "event": "restart_pod.called", "level": "info", "timestamp": "2026-05-14T19:20:44.669140Z"}
angel@leIA:/opt/openclaw$ |

```

Además de ejecutar tareas de manera automática, existe un segundo mecanismo, un watcher que en caso de que detecte warns dentro del steam de Kubernetes, lo analizara de inmediato sin esperar al ciclo de 5 minutos, y operara en caso de detectar cualquier error.

```

current session x angel@leIA: /opt/openclaw x + v
angel@leIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep -E 'k8s_watcher\.(started|connected|critical_event)'
may 14 20:48:39 leIA openclaw[24893]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T18:48:39.987260Z"}
may 14 20:48:39 leIA openclaw[24893]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T18:48:39.994252Z"}
may 14 21:28:41 leIA openclaw[109568]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T19:28:41.387910Z"}
may 14 21:28:41 leIA openclaw[109568]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T19:28:41.395237Z"}
may 14 21:31:09 leIA openclaw[111819]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T19:31:09.644911Z"}
may 14 21:31:09 leIA openclaw[111819]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T19:31:09.651726Z"}
may 14 21:39:55 leIA openclaw[113563]: {"event": "openclaw.k8s_watcher.started", "level": "info", "timestamp": "2026-05-14T19:39:55.288506Z"}
may 14 21:39:55 leIA openclaw[113563]: {"event": "openclaw.k8s_watcher.connected", "level": "info", "timestamp": "2026-05-14T19:39:55.295161Z"}
angel@leIA:/opt/openclaw$ |

```

En la Fase 4 – servicios de monitorización → 1 semana se ha configurado alertmanager, y ahora se ha adaptado para poder enviar esas alertas a Openclaw via HTTP, el agente recibe la notificación, lo analiza y responde, aquí se ha creado una alerta manual.


```

deploy-phase6-saasphere x angel@leIA: /opt/openclaw x + v
angel@leIA:/opt/openclaw$ curl -i -X POST http://localhost:8080/webhook/alert \
-H 'Content-Type: application/json' \
-d '{
  "status": "firing",
  "commonLabels": {"alertname": "TestAlert", "severity": "warning"},
  "commonAnnotations": {"summary": "Prueba de integración TFG"},
  "alerts": [
    {
      "status": "firing",
      "labels": {"alertname": "TestAlert"},
      "annotations": {"summary": "Prueba TFG"},
      "startsAt": "2026-05-14T00:00:00Z"}
  ]
}'
HTTP/1.1 202 Accepted
date: Thu, 14 May 2026 20:43:45 GMT
server: uvicorn
content-length: 21
content-type: application/json
{"status": "accepted"}
angel@leIA:/opt/openclaw$ journalctl -u openclaw --no-pager | grep 'webhook.alert_received' | tail -5 | tail -5
may 14 22:43:45 leIA openclaw[113563]: {"status": "firing", "event": "openclaw.webhook.alert_received", "level": "info", "timestamp": "2026-05-14T20:43:45.846649Z"}
angel@leIA:/opt/openclaw$ |

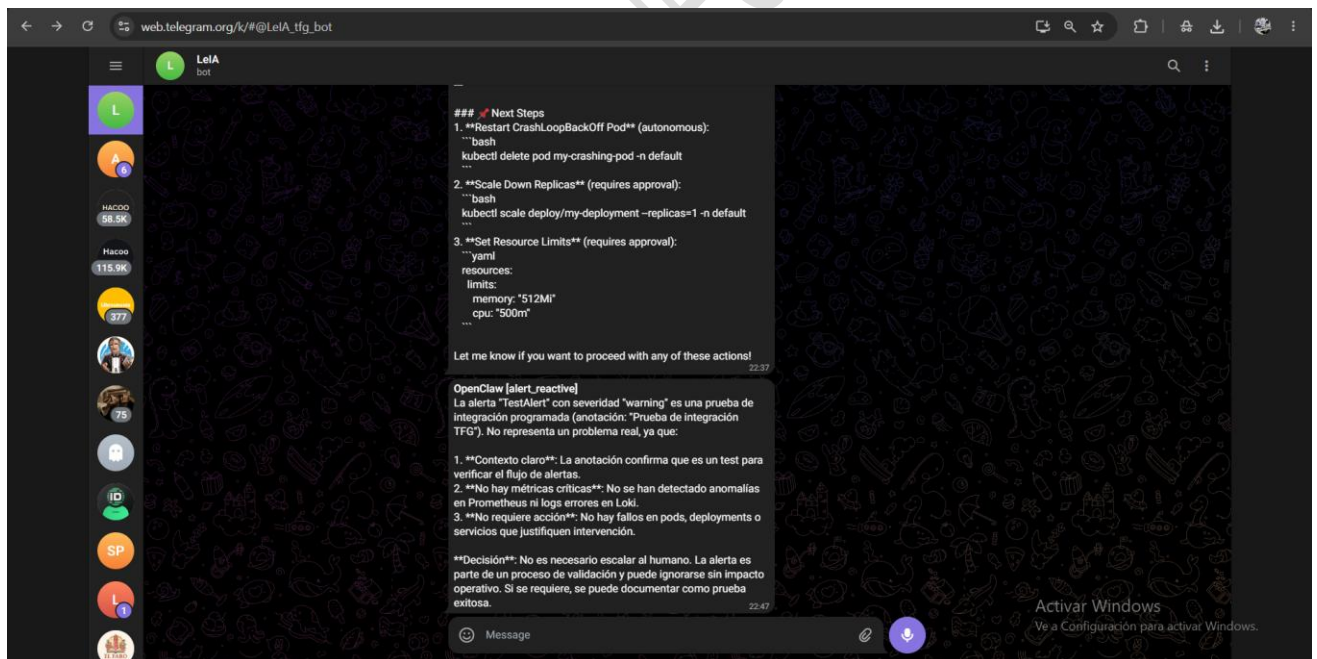
```



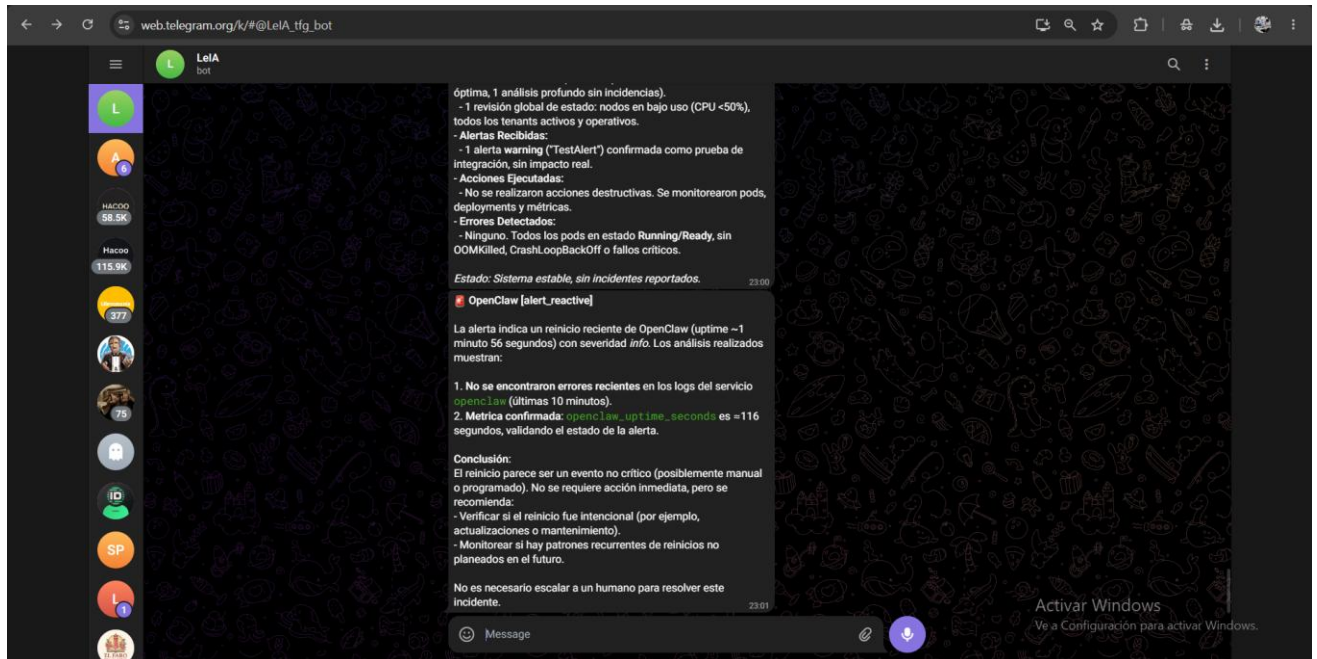
Y ya podemos ver como la IA está trabajando la alerta, se aprecia que es el modelo de 32B porque no entra en la Vram por completo.




Y al rato nos envía por telegram este mensaje



Mas tarde mientras se seguía programando, ha llegado este mensaje por un reinicio de Openclaw

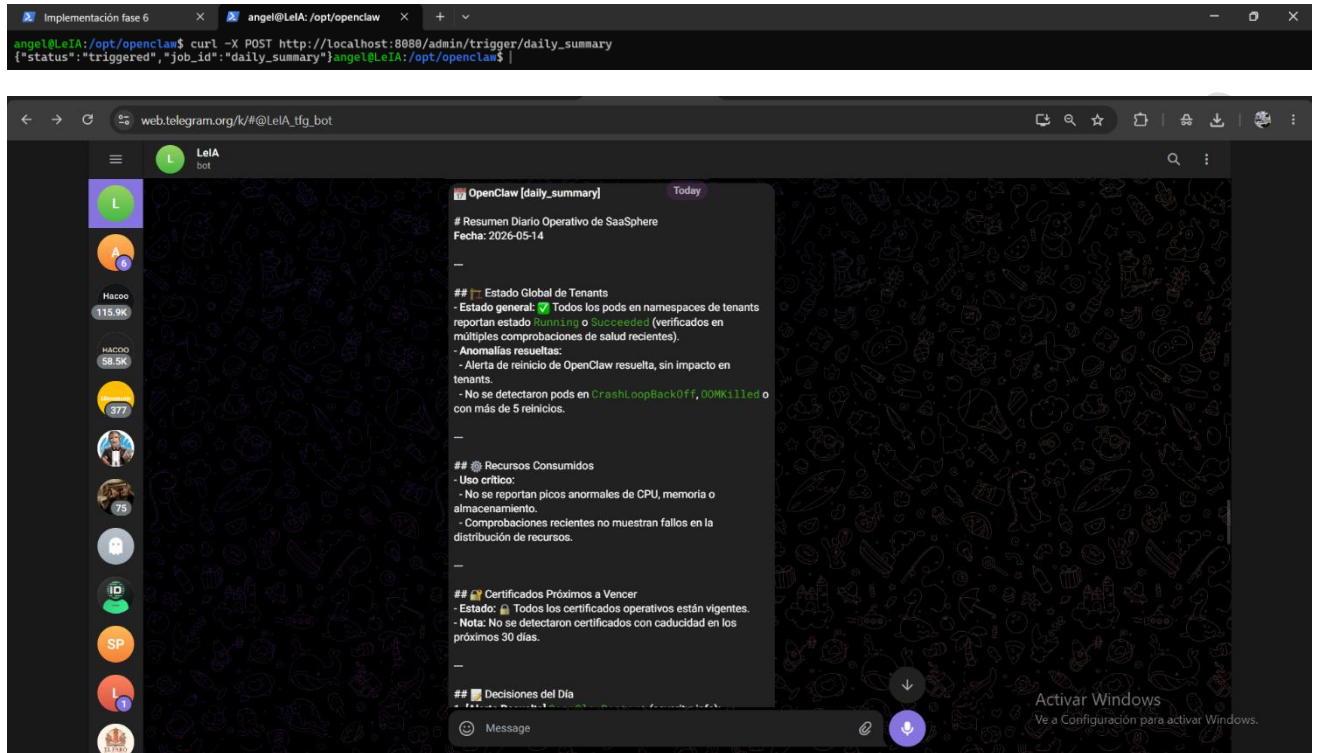


El sistema no emplea siempre el mismo modelo, ya que existen tareas que necesitamos mayor velocidad de ejecución, como podría ser el check de la salud de los pods, y ciertas tareas que es mejor priorizar el procesamiento a la velocidad, como podría ser el check diario del estado general, que se hace con el modelo de 32b.



Cada día a las 08:00 el agente genera un resumen completo, del estado global de los tenants, los recursos, certificados próximos a vencer, decisiones en las ultimas horas... esto se ejecuta con el modelo de 32b ya que requiere mayor sintaxis.

Esto nos llegara tanto por telegram como por Obsidian (una app que lee markdown desde una carpeta), para dejar un histórico, se ha lanzado manualmente para probarlo y este es el resultado.



The top screenshot shows a Telegram web interface with a bot named 'LeIA bot'. A message titled 'OpenClaw [daily_summary]' is displayed, dated 'Today' (2026-05-14). The message content includes:

- # Resumen Diario Operativo de SaaSphere**
Fecha: 2026-05-14
- ## 📊 Estado Global de Tenants**
 - Estado general: ✅ Todos los pods en namespaces de tenants reportan estado **Running** o **Succeeded** (verificados en múltiples comprobaciones de salud recientes).
 - Anomalías resueltas.
 - Alerta de reinicio de OpenClaw resuelta, sin impacto en tenants.
 - No se detectaron pods en **CrashLoopBackOff**, **OOMKilled** o con más de 5 reinicios.
- ## 🧠 Recursos Consumidos**
 - Uso crítico.
 - No se reportan picos anormales de CPU, memoria o almacenamiento.
 - Comprobaciones recientes no muestran fallos en la distribución de recursos.
- ## 📅 Certificados Próximos a Vencer**
 - Estado: ✅ Todos los certificados operativos están vigentes.
 - Nota: No se detectaron certificados con caducidad en los próximos 30 días.
- ## 📋 Decisiones del Día**

The bottom screenshot shows a terminal window with the following commands and output:

```
angel@LeIA: /opt/openclaw$ tree
.
├── 2026-05-14_daily_summary.md
├── 2026-05-15_daily_summary.md
└── 2026-05-16_daily_summary.md

1 directory, 3 files
angel@LeIA: /opt/openclaw/obsidian/2026-05$ cat 2026-05-14_daily_summary.md

date: 2026-05-14
time: 23:43
type: daily_summary
tags: [openclaw, daily_summary]
---
```

2026-05-14 - Daily Summary

Generado automáticamente por OpenClaw a las 23:43

Resumen diario OK.

Actualización a las 23:43

Resumen diario OK.

Actualización a las 23:55

Resumen diario OK.

```
angel@LeIA: /opt/openclaw/obsidian/2026-05$
```




g. Fase 7: Observabilidad y trazabilidad

La fase 7 consiste en recopilar métricas, para poder comprobar que se está ejecutando, picos de tokens, y fallos.

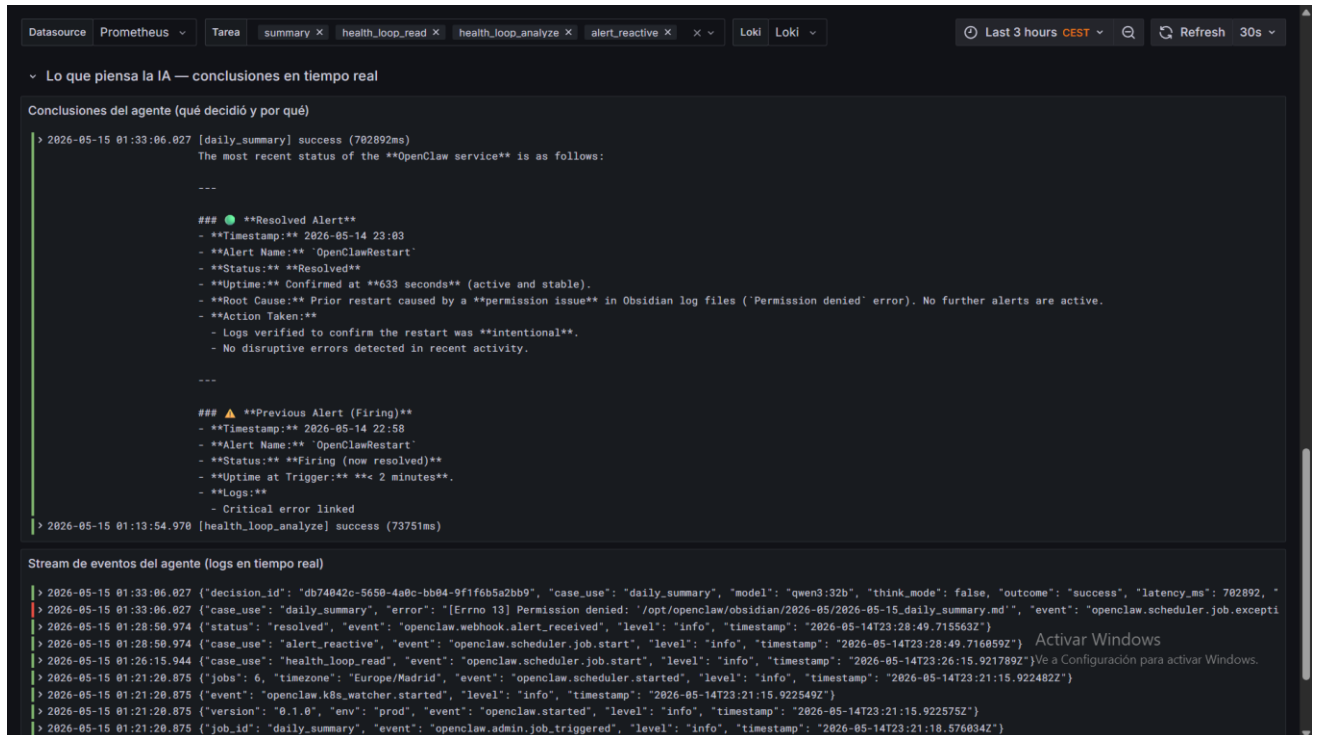
Acceso al endpoint /metrics con las 12 métricas:

```
# HELP python_gc_objects_collected_total Objects collected during gc
# TYPE python_gc_objects_collected_total counter
python_gc_objects_collected_total{generation="0"} 7213.0
python_gc_objects_collected_total{generation="1"} 1249.0
python_gc_objects_collected_total{generation="2"} 0.0
# HELP python_gc_objects_uncollectable_total Uncollectable objects found during GC
# TYPE python_gc_objects_uncollectable_total counter
python_gc_objects_uncollectable_total{generation="0"} 0.0
python_gc_objects_uncollectable_total{generation="1"} 0.0
python_gc_objects_uncollectable_total{generation="2"} 0.0
# HELP python_gc_collections_total Number of times this generation was collected
# TYPE python_gc_collections_total counter
python_gc_collections_total{generation="0"} 233.0
python_gc_collections_total{generation="1"} 21.0
python_gc_collections_total{generation="2"} 1.0
# HELP python_info Python platform information
# TYPE python_info gauge
python_info{implementation="CPython",major="3",minor="13",patchlevel="5",version="3.13.5"} 1.0
# HELP process_virtual_memory_bytes Virtual memory size in bytes.
# TYPE process_virtual_memory_bytes gauge
process_virtual_memory_bytes 4.46357504e+08
# HELP process_resident_memory_bytes Resident memory size in bytes.
# TYPE process_resident_memory_bytes gauge
process_resident_memory_bytes 2.0668416e+08
# HELP process_start_time_seconds Start time of the process since unix epoch in seconds.
# TYPE process_start_time_seconds gauge
process_start_time_seconds 1.7788008741e+09
# HELP process_cpu_seconds_total Total user and system CPU time spent in seconds.
# TYPE process_cpu_seconds_total counter
process_cpu_seconds_total 2.68
# HELP process_open_fds Number of open file descriptors.
# TYPE process_open_fds gauge
process_open_fds 32.0
# HELP process_max_fds Maximum number of open file descriptors.
# TYPE process_max_fds gauge
process_max_fds 1024.0
# HELP openclaw_info OpenClaw version info
# TYPE openclaw_info gauge
openclaw_info{version="0.1.0"} 1.0
# HELP openclaw_uptime_seconds Uptime in seconds
# TYPE openclaw_uptime_seconds gauge
openclaw_uptime_seconds 364.33795738220215
# HELP openclaw_errors_total Total errors
# TYPE openclaw_errors_total counter
openclaw_errors_total 0
# HELP openclaw_http_requests_total HTTP requests to OpenClaw
# TYPE openclaw_http_requests_total counter
openclaw_http_requests_total{endpoint="/admin/trigger/daily_summary",status="200"} 1.0
```

Existen varias metricas que se han ido recogiendo dentro de este panel de grafana.

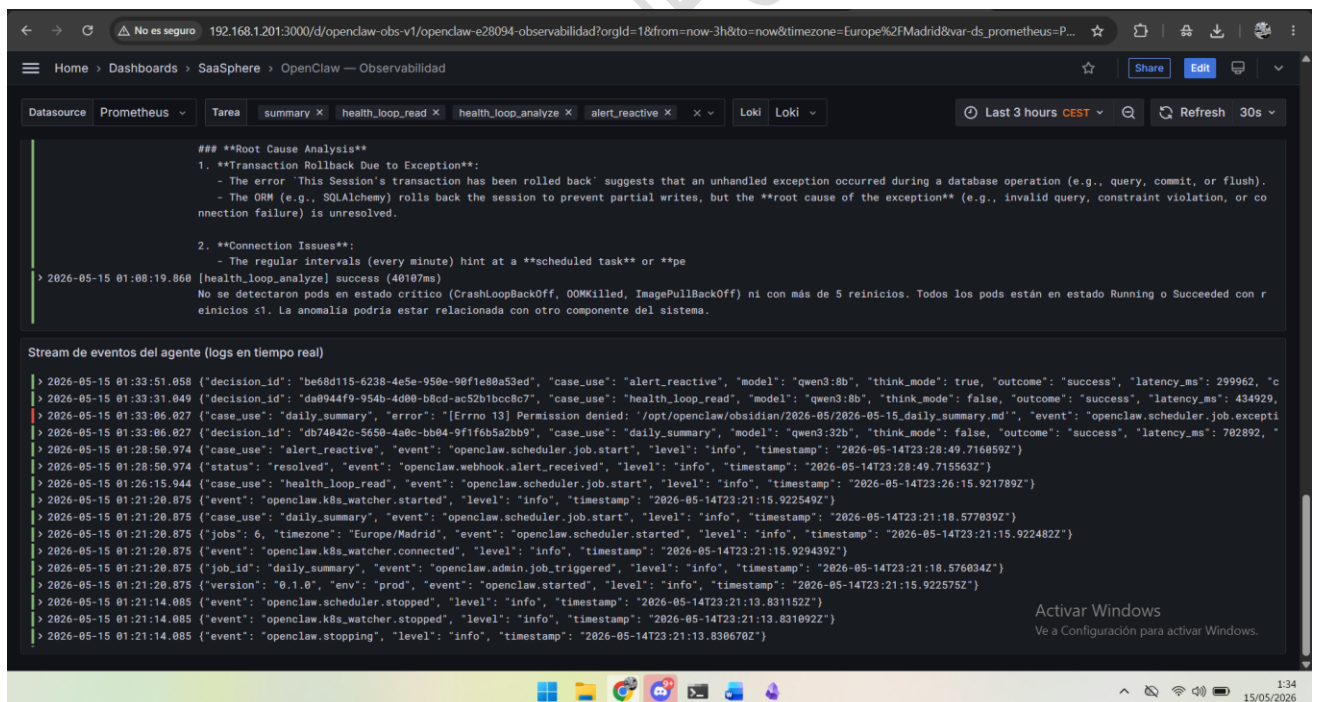


También existe un registro de lo que ha pensado la IA



The screenshot displays the OpenCLAW observability interface. At the top, there's a navigation bar with tabs for 'Datasource' (Prometheus), 'Tarea' (summary, health_loop_read, health_loop_analyze, alert_reactive), and 'Loki'. The main content area is titled 'Lo que piensa la IA — conclusiones en tiempo real'. It shows two sections: 'Conclusiones del agente (qué decidió y por qué)' and 'Stream de eventos del agente (logs en tiempo real)'. The first section contains a log entry from 2026-05-15 01:33:06.027, indicating a successful daily_summary task. It details the status of the OpenCLAW service, showing a resolved alert for 'OpenCLAWRestart' and a previous alert for 'OpenCLAWRestart' that was resolved. The second section shows a stream of events, including 'decision_id', 'case_use', 'model', 'think_mode', 'outcome', 'latency_ms', and 'event'. The events include 'alert_reactive', 'health_loop_read', 'health_loop_analyze', and 'alert_reactive'. The interface also shows a 'Last 3 hours CEST' filter and a 'Refresh 30s' button.

Y un stream de eventos del agente, para saber el por que de ciertas decisiones si es necesario.



This screenshot shows the OpenCLAW observability interface from a different perspective. The navigation bar is the same, but the 'Tarea' tab is set to 'summary'. The main content area is titled 'Lo que piensa la IA — conclusiones en tiempo real'. It shows two sections: 'Conclusiones del agente (qué decidió y por qué)' and 'Stream de eventos del agente (logs en tiempo real)'. The first section contains a log entry from 2026-05-15 01:08:19.060, indicating a successful health_loop_analyze task. It details the status of the OpenCLAW service, showing a resolved alert for 'OpenCLAWRestart' and a previous alert for 'OpenCLAWRestart' that was resolved. The second section shows a stream of events, including 'decision_id', 'case_use', 'model', 'think_mode', 'outcome', 'latency_ms', and 'event'. The events include 'alert_reactive', 'health_loop_read', 'health_loop_analyze', and 'alert_reactive'. The interface also shows a 'Last 3 hours CEST' filter and a 'Refresh 30s' button.



h. Fase 8: Cargas de trabajo

En esta fase se ha incorporado la capacidad de mover pods desde Matrix hasta Fallback en función a la carga de trabajo, o del hardware del equipo, todo esto calculado por la LeIA sin la necesidad de intervención humana.

Cada 15 minutos el agente comprueba el estado de Matrix, si la CPU o la memoria de Matrix supera el umbral del 85%, o si este caído, el agente entiende que se debe usar el nodo fallback.

El proceso que sigue LeIA para comprobarlo es el siguiente:

- Se comprueba el estado de Fallback (por si también tiene mucha carga).
- Lista los tenant de Matrix.
- Solicita permiso de acción por telegram y en caso de conseguir permiso actúa.
- Se crea el nuevo tenant en Fallback y tras tenerlo listo se borra el tenant de Matrix.

Esto se hace añadiendo en la tarea de revisión que se ejecuta cada 5 minutos un check de carga y de hardware, en caso de que se encuentren problemas, se despliega una tarea que analiza las posibilidades de mover el pod y si lo ve viable lo hace.

Esto se probará más adelante dentro del apartado de pruebas finales, ya que hace falta tener pods activos para ello.

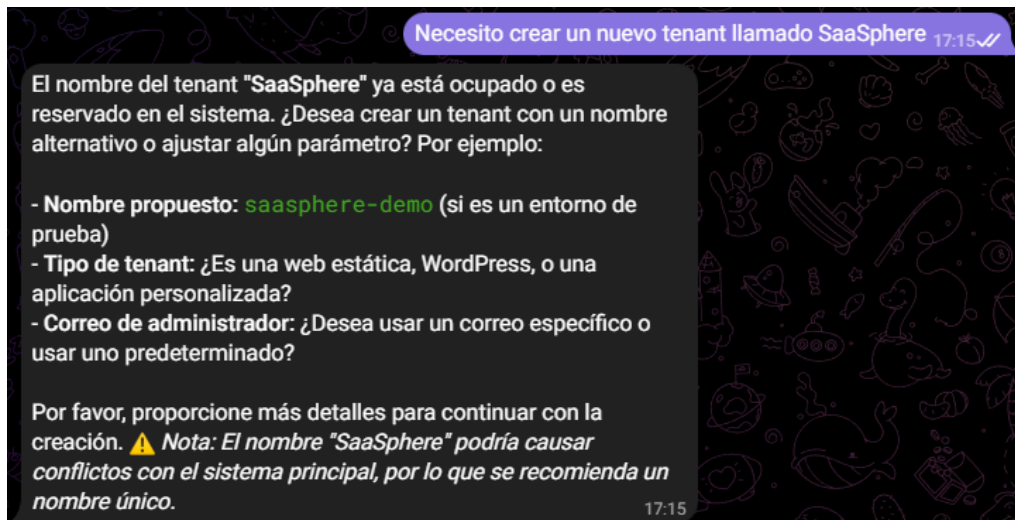


8. Fase 8 – Pruebas generales → 2 semanas

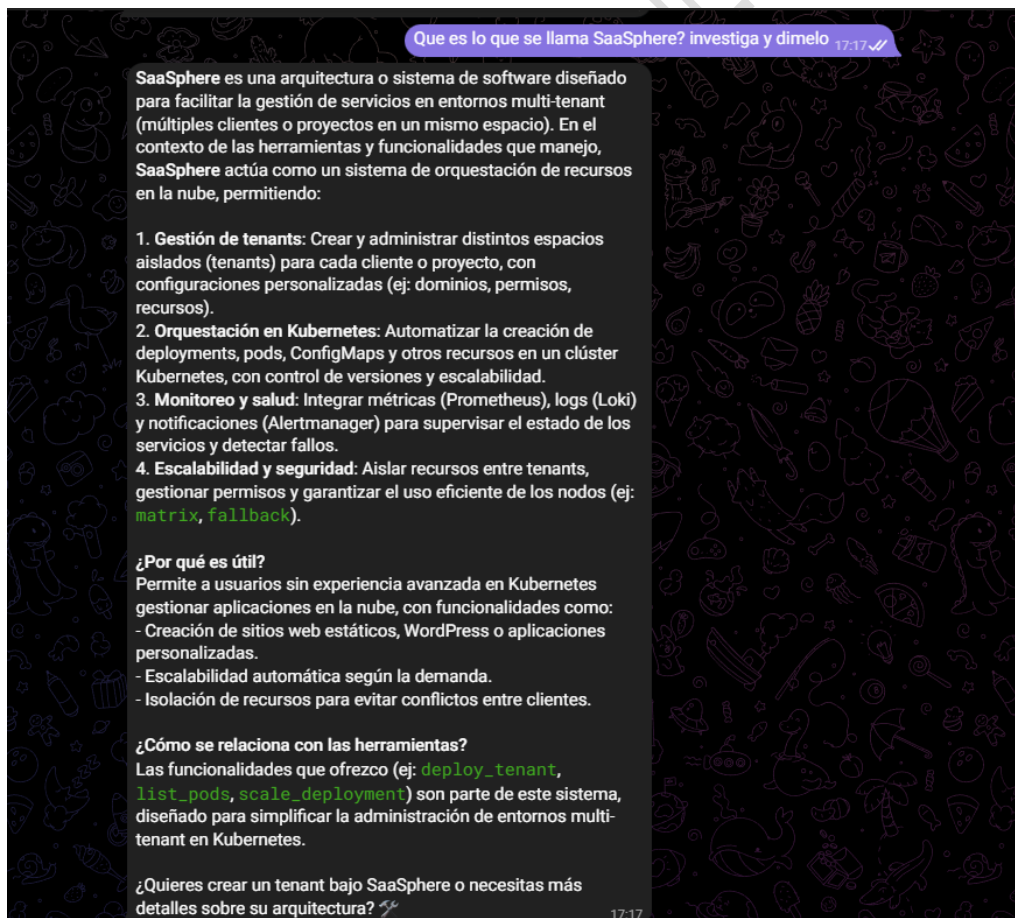
Primera prueba

Se va a probar la implementación de un primer cliente, será la propia web de la empresa SaaSphere, el nombre SaaSphere.es, y se va a crear completamente desde telegram.

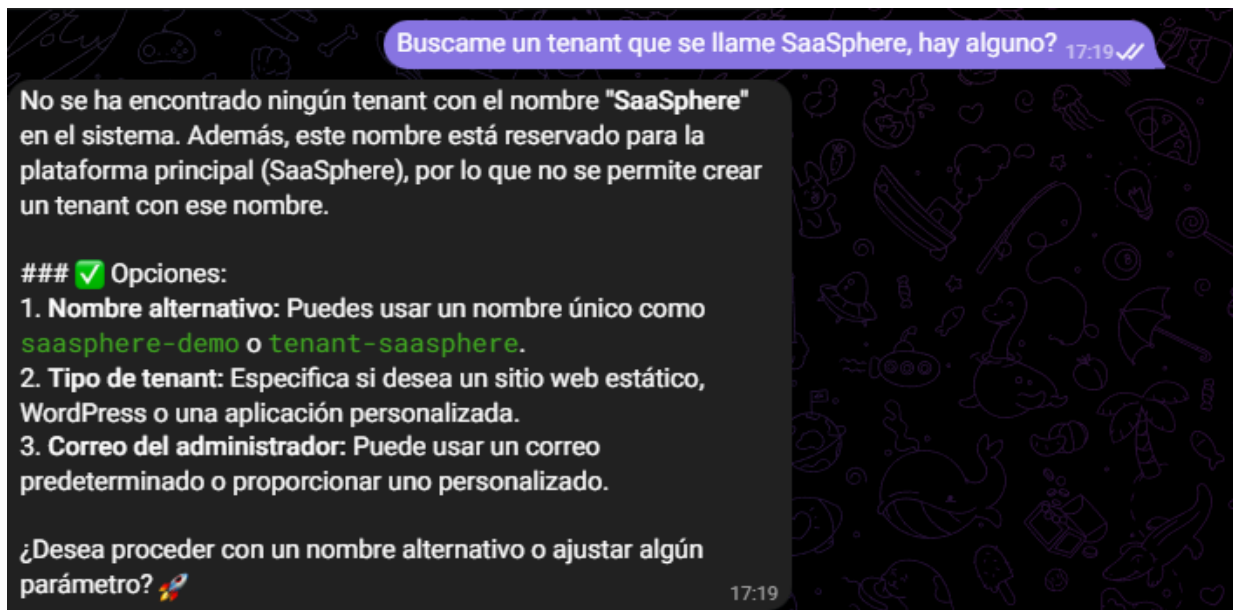
Al solicitar un nuevo tenant llamado SaaSphere, la IA nos lo impide ya que encuentra algún problema.



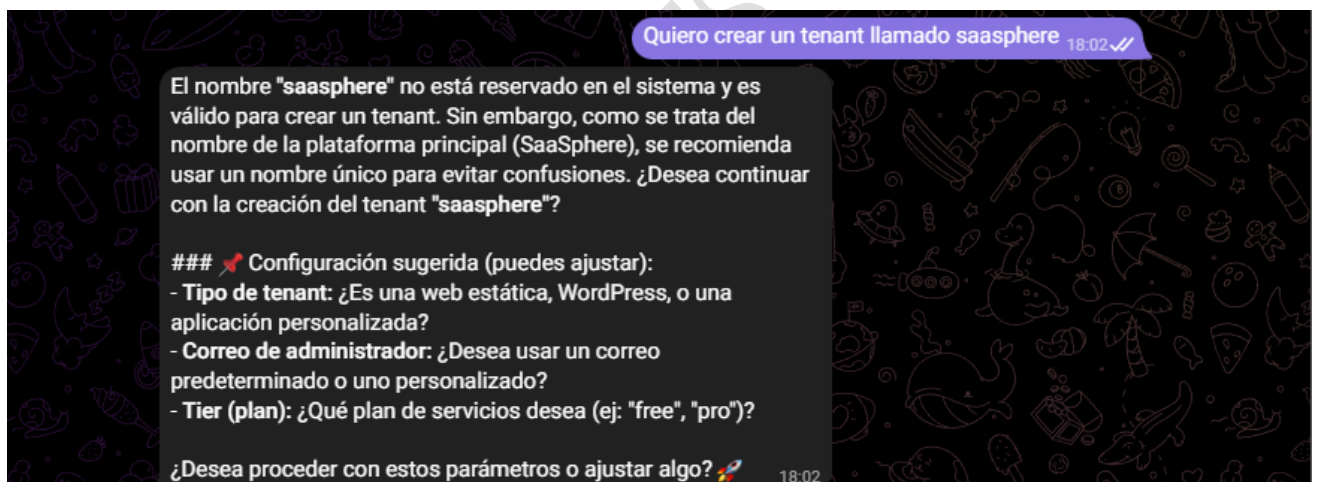
Por lo que intento averiguar donde encuentra SaaSphere como nombre



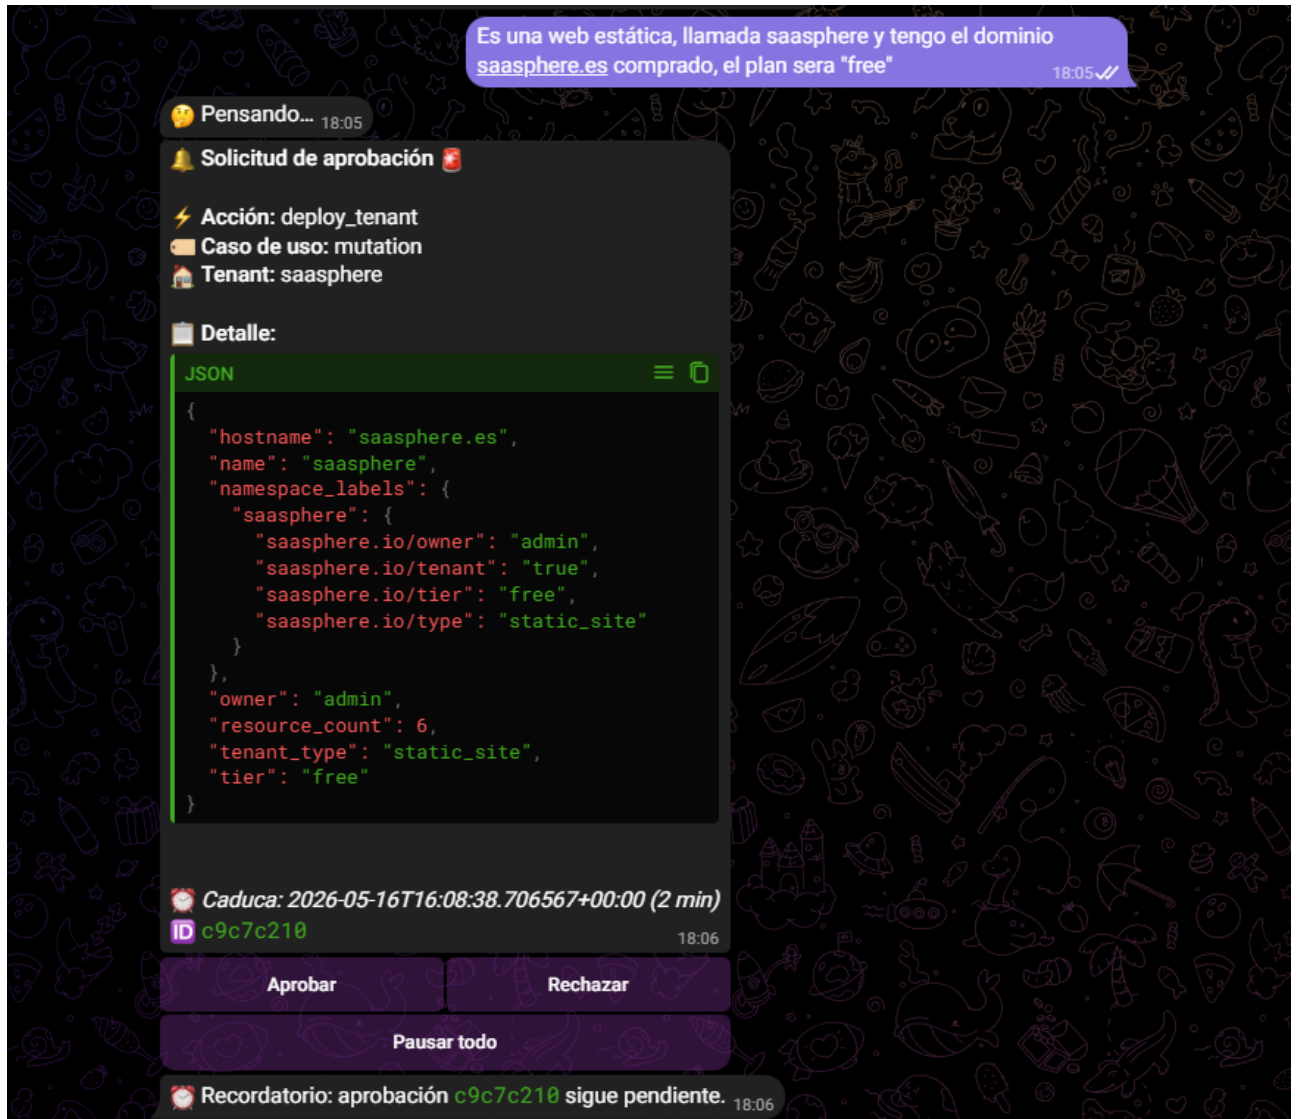
No ha encontrado ningún tenant llamado así, por lo que le preguntamos por que no se puede llamar así el tenant que estamos creando.




AL ver que no encuentra ningún tenant, deduzco que es producto de otra limitación, que en este caso son las mayúsculas, por lo que le insisto en crearlo.



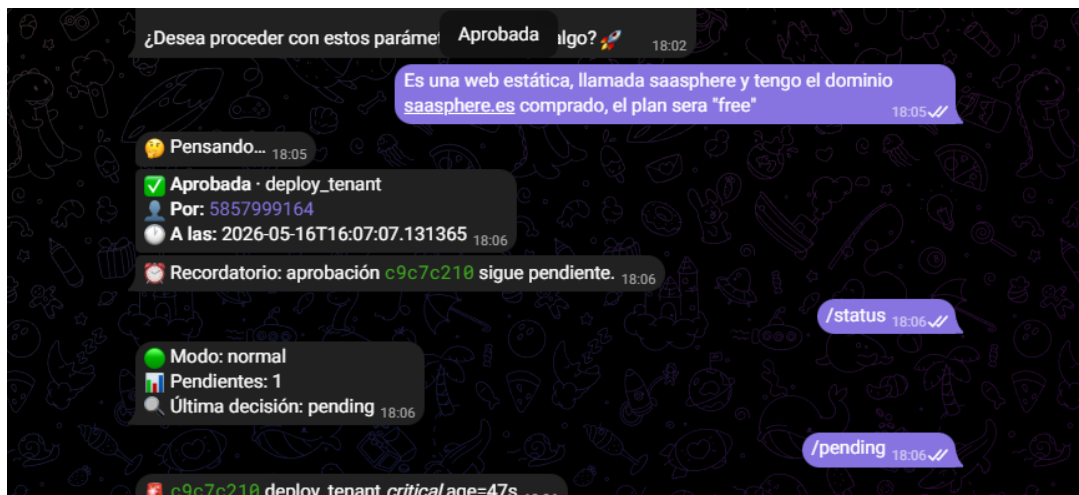
Nos solicita aprobación por telegram cuando le rellenamos la información.



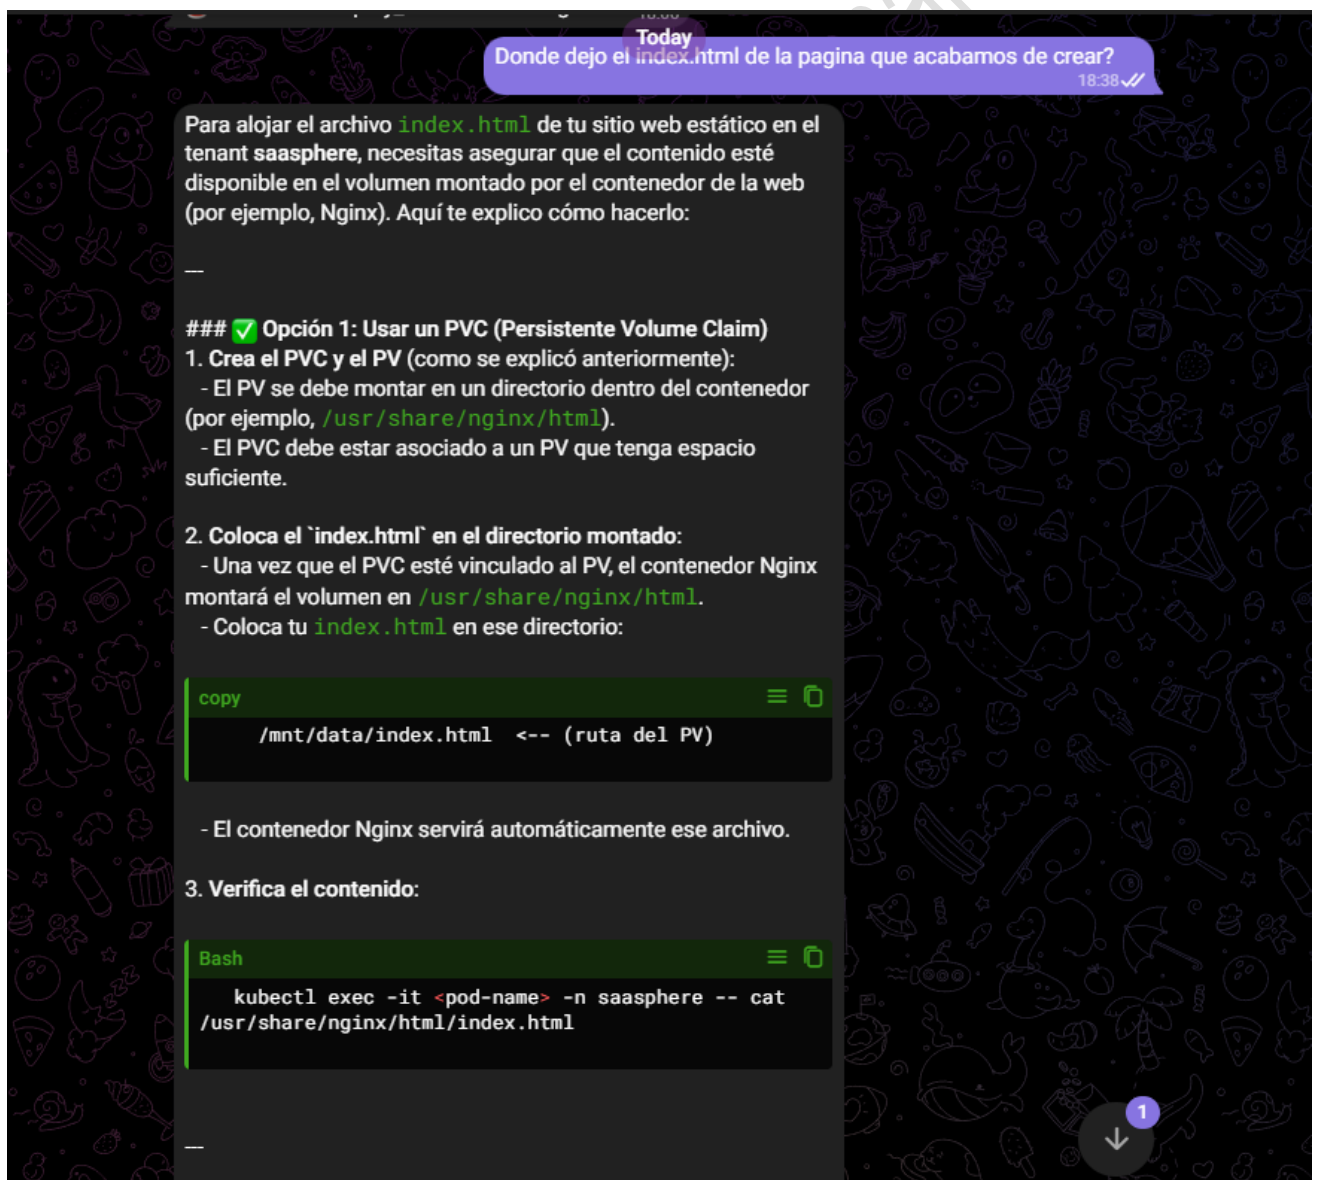
Se puede comprobar que esta pendiente si revisamos el estado, indicándonos el nº de la solicitud.



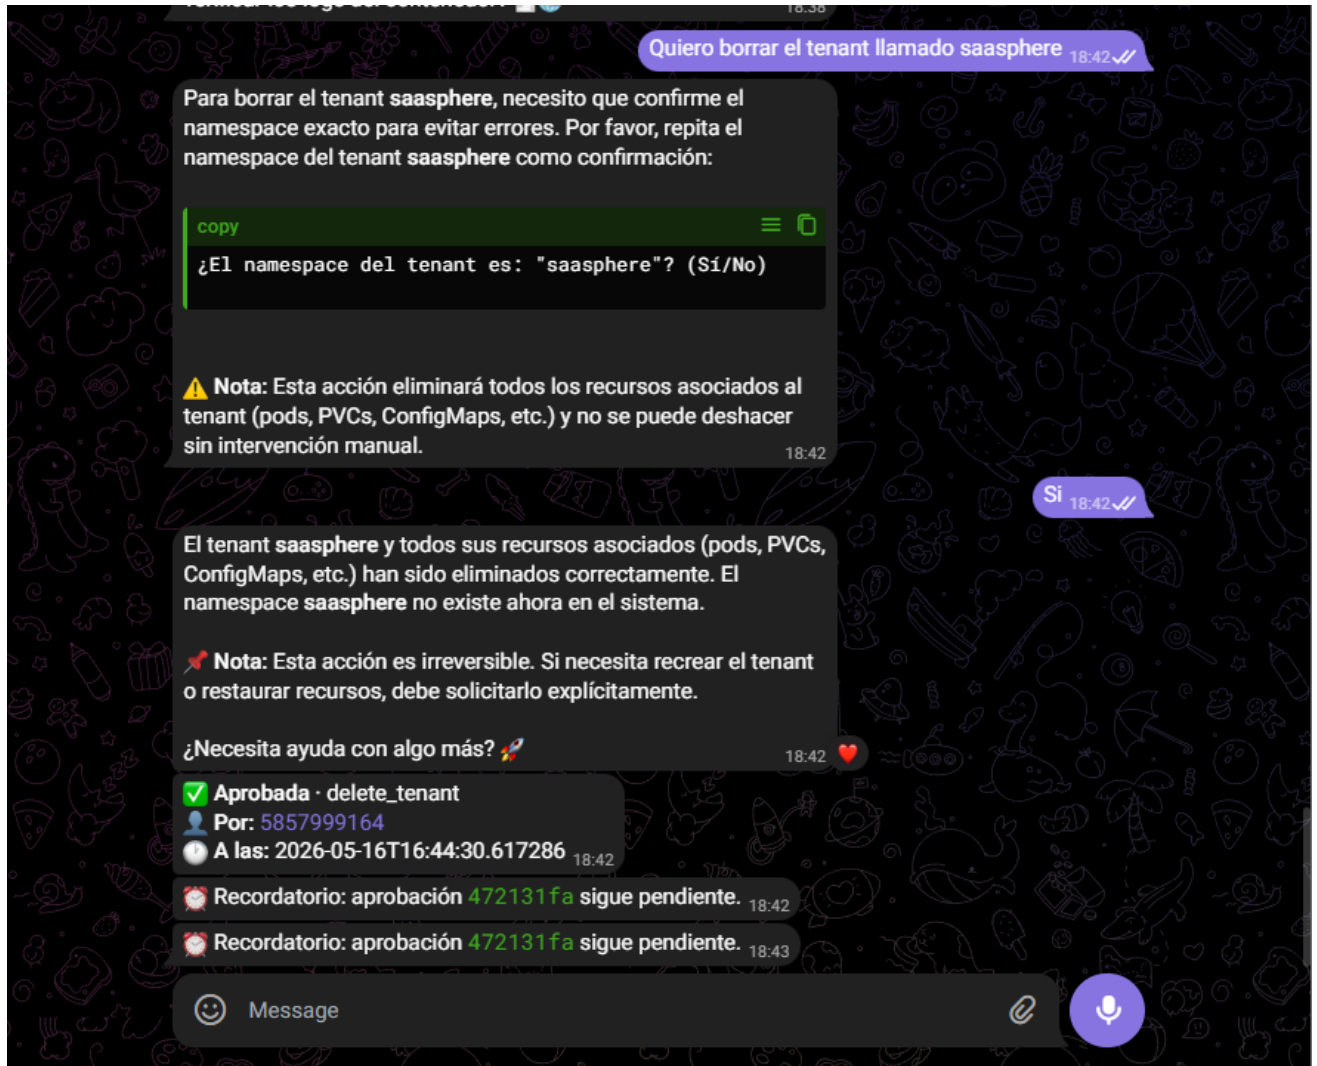
Y al aprobarla cambia el mensaje de manera que nos indica los datos necesarios para el seguimiento de la actividad.



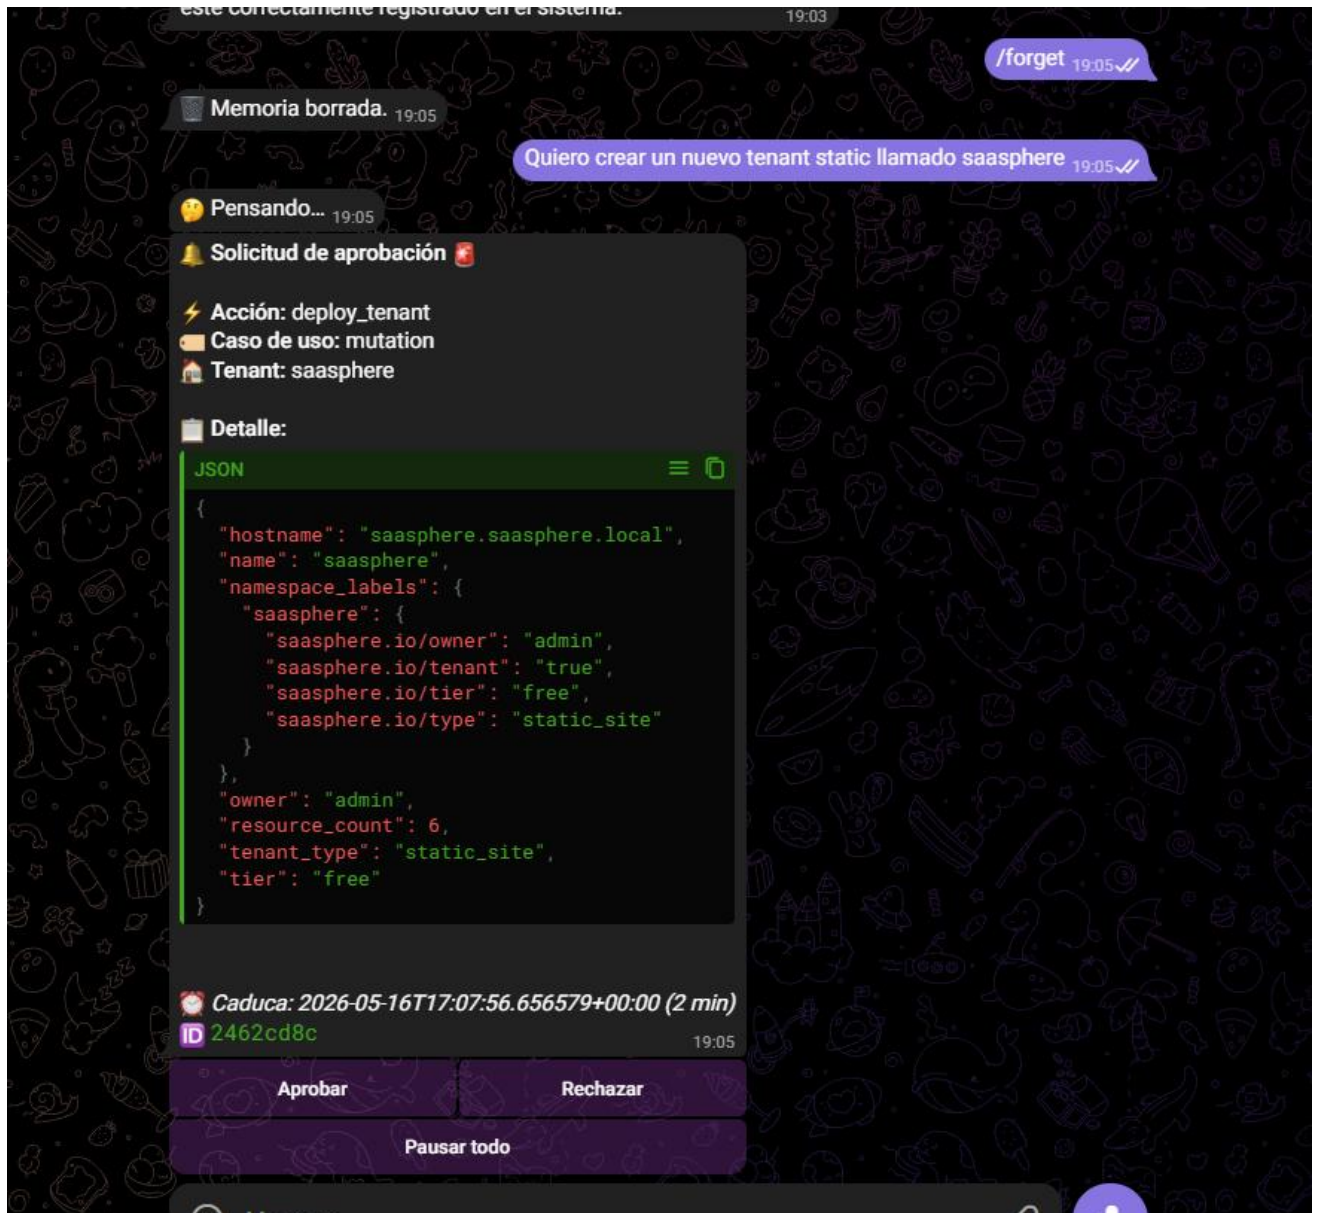
Vemos que hay un error porque no me esta dando el path para dejar los archivos de la web



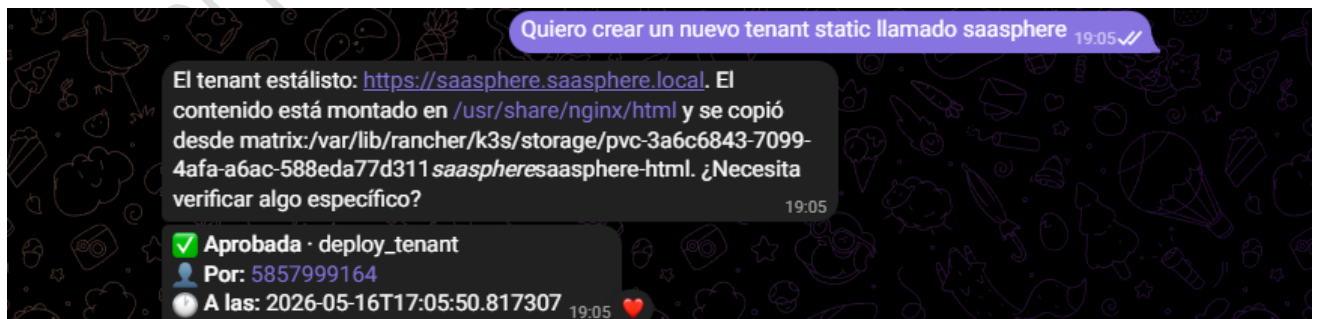
Borro el tenant para revisarlo y crearlo luego con el mismo nombre.



Vuelvo a solicitar la creación y nos vuelve a pedir permiso:



Al aceptar, nos indica el directorio donde debemos dejar los archivos.



Y aquí copiamos los archivos (los docker compose son del desarrollo de la web)

```

angel@LeIA:~/futuraweb$ scp -r ~/futuraweb/* matrix:/tmp/
The authenticity of host 'matrix (192.168.1.202)' can't be established
ED25519 key fingerprint is SHA256:f+VMLHmKNI6voWjtyTx6LCWEF2P2aTt0sJSv
p8o1Ij8.
This host key is known by the following other names/addresses:
  ~/.ssh/known_hosts:7: [hashed name]
Are you sure you want to continue connecting (yes/no/[fingerprint])? y
es
Warning: Permanently added 'matrix' (ED25519) to the list of known hos
ts.
docker-compose.yml      100% 231   460.6KB/s   00:00
Dockerfile              100% 105   350.4KB/s   00:00
index.html              100% 101   370.0KB/s   00:00
nginx.conf              100% 499    1.8MB/s     00:00
SaaSphere.html          100% 85KB   31.7MB/s     00:00
SaaSphere-logo.png      100% 2098KB 84.7MB/s     00:00
setup.sh                100% 1044    3.6MB/s     00:00
start-server.sh         100% 1131    4.2MB/s     00:00
angel@LeIA:~/futuraweb$ |

```

Y muevo los archivos a su lugar

```

root@matrix: /var/lib/rancher/k3s/storage# tree
.
├── pvc-3a6c6843-7099-4afa-a6ac-588eda77d311_saasphere_saasphere-html
│   ├── index.html
│   ├── SaaSphere.html
│   └── SaaSphere-logo.png
├── pvc-6f8ba4f6-57de-4f28-9c5c-36152a6c55fb_demo-tfg_demo-tfg-html
│   └── index.html
├── pvc-9c95fd04-7396-4bba-84a8-12c5d443d73c_prueba-tfg_prueba-tfg-html
│   └── index.html
├── pvc-af516a62-46fd-49c1-8650-8e29d9a85da2_kube-system_traefik
│   └── acme.json
└──
5 directories, 6 files
root@matrix: /var/lib/rancher/k3s/storage#

```


Y añadimos una línea dentro del archivo hosts de windows

```


cd optopenclaw
hosts
# entry should be kept on an individual line. The IP address should
# be placed in the first column followed by the corresponding host name.
# The IP address and the host name should be separated by at least one
# space.
#
# Additionally, comments (such as these) may be inserted on individual
# lines or following the machine name denoted by a '#' symbol.
#
# For example:
#
# 102.54.94.97    rhino.acme.com    # source server
# 38.25.63.10    x.acme.com        # x client host
#
# localhost name resolution is handled within DNS itself.
# 127.0.0.1      localhost
# ::1            localhost
192.168.1.240    prueba-tfg.saasphere.local
192.168.1.240    saasphere.saasphere.local
192.168.1.240    demo-tfg.saasphere.local

```

Y ahora probamos a conectarnos al tenant, y correctamente funciona



Se ha creado una web de SaaSphere, incluyendo los precios



Conclusiones de la prueba:

El deploy funciona correctamente pero el mayor problema de la IA es el alucinamiento, confunde cosas y debería haber actuado directamente creando el tenant sin mayúsculas.



Mayores dificultades

Dificultad 1

Sin lugar a duda el mayor problema que ha habido durante la ejecución del TFG han sido los controladores de Nvidia para la tarjeta gráfica en Linux.

Al reiniciar LeIA, cada vez que hacia cualquier acción mediante telegram, daba un error con los drivers cuda, que son los encargados de controlar los núcleos gráficos de las tarjetas de Nvidia, aquí el error:

```
ggml_cuda_init: failed to initialize CUDA: unknown error
```

Como recibe este error, no trabajaba la grafica y la IA ejecutaba todo vía CPU y RAM, teniendo un tiempo de ejecución mucho más, llegando a los 10 minutos para contestar a un “¿Cómo te llamas?” con el modelo más básico.

Se probaron varias soluciones posibles al error que había, en base a unas hipótesis:

hipótesis 1: Error al cargar un modelo grande cuando el otro ya estaba cargado, se supone que un modelo echa al otro antes de entrar a calcular, funcionaba correctamente.

hipótesis 2: UVM corrupto, esto era un síntoma que luego me llevo al error real.

hipótesis 3: Problema con el entorno gráfico, era posible ya que estaba consumiendo VRAM, no cuadraba demasiado, pero existía la posibilidad.

Hipótesis 4: Nvidia-persistenced no activo, descartado porque estaba activo tras reinstalar los drivers.

hipótesis 5: Mala relación entre Ollama y los Drivers, en el diagnostico se mostró que ollama traía instaladas unas librerías que hacían uso de CUDA 12.8, que no era la versión que Debian 13 trixie (el que hay instalado en LeIA) trae por defecto, entonces hubo que actualizar los drivers sin emplear las librerías oficiales de Debian, de manera manual y compilándolos a mano.

Hice una snapshot con Timeshift ya que esto es algo complicado que se suele romper, purgue los drivers actuales y desde la línea de comando pura instale los drivers y configure Nvidia-driver-595.

Con esto, quedo solventado por completo (al menos por ahora) el problema con los drivers.

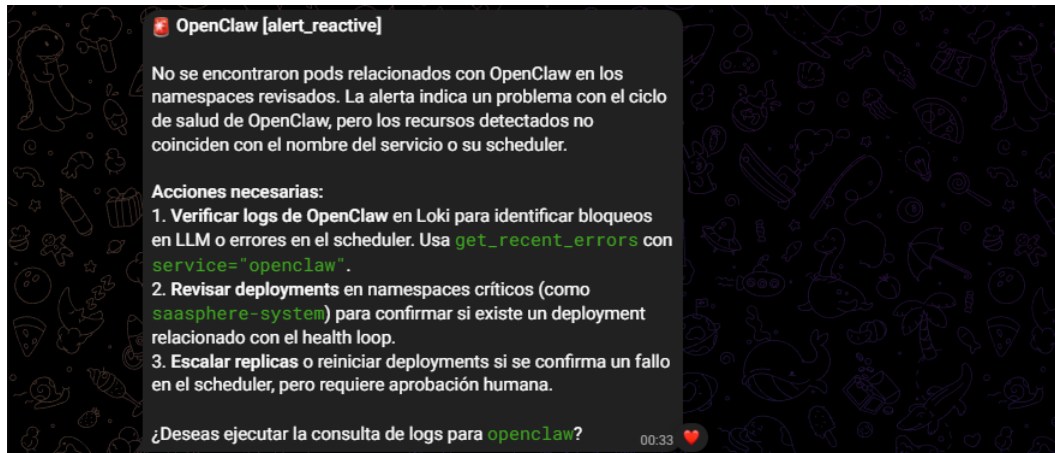
Dificultad 2: Perdida de drivers

Se instalaron las unattended upgrades y se actualizo el Kernel de Linux, pero no la cabecera correspondiente, por lo que el módulo de NVIDIA para el nuevo kernel no se comunicaba bien, por lo que no había video. El procesador de LeIA no tiene gráficos integrados así que había que conectarse por SSH para solventarlo, se ha actualizado la cabecera correspondiente y quedo resuelto.



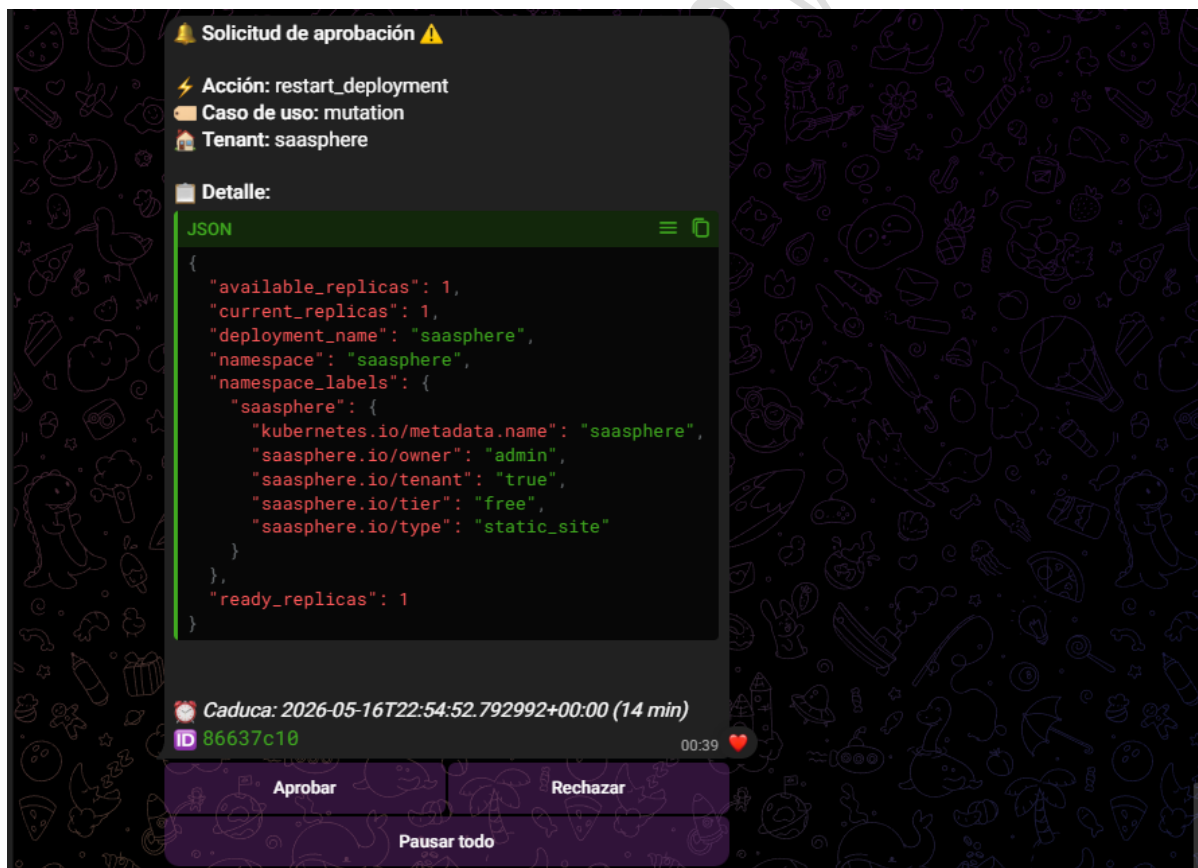
Dificultad 3: Entender Openclaw y SaaSphere como tenant

Se han detectado muchos errores como este:



Cada vez que se reiniciaba Openclaw, LeIA entiende que es un pod y busca problemas con él, cuando claramente no hay ninguno, simplemente se ha reiniciado de manera manual.

Además, ha llegado notificación de reinicio del pod SaaSphere por una alerta de alertmanager relacionada con el nombre del kluster, que es saasphere.



Se ha configurado de manera que si una alerta empieza por "Openclaw" no se a analice mediante LeIA, solo se reproduce alerta mediante telegram, el administrador lo revisara manualmente.

Fuentes

<https://kapangapress.com/cuantas-empresas-en-espana-tienen-pagina-web-evolucion-2011-2024/>

<https://espanadigital.gob.es/gl/actualidad/los-resultado-de-la-encuesta-sobre-el-uso-de-las-tic-y-del-comercio-electronico-en-las>

<https://www.mountainbarcelona.com/blog/>

www.chatgpt.com

<https://portal.gestion.sedepkd.red.gob.es/portal/kitdigital>

<https://www.enisa.es/es/financia-tu-empresa/lineas-de-financiacion/d/jovenes-emprendedores>

https://industria.gob.es/es-es/estadisticas/Estadisticas_Territoriales/Estructura-Dinamica-Empresarial-2023.pdf

<https://github.com/grafana/grafana>

<https://github.com/prometheus/prometheus>

<https://grafana.com/docs/>

<https://prometheus.io/docs/introduction/overview/>



Anexos

Por ejemplo, a continuación se incluyen unas pautas a tener en cuenta a la hora de elaborar la documentación del proyecto.

Guía de estilo

Título del proyecto

Elegir un nombre llamativo y relacionado con la temática que va a tratar.

Figuras y tablas

Cualquier figura, tabla... incluida en el documento deberá tener un título a pie de página.

Incluir tablas, gráfico, mapas conceptuales...que ayuden a leer y comprender el documento.

Índices

Además del índice de contenidos, ya incluido en la plantilla, se añadirá a continuación el índice de figuras, si fuera necesario.

Redacción

Se evitarán las mayúsculas, salvo en los títulos y poco más.

No se emplearán formas personales (instalamos, seleccionamos...) en su lugar se utilizarán formas impersonales (instalar, se instalará, seleccionar, se selecciona,...).

Se evitará la voz pasiva (casi siempre traducción literal del inglés). En vez de: es desarrollado para cumplir... mejor: se desarrolla para cumplir...

Se evitarán los párrafos largos.

Se utilizarán las viñetas para facilitar la lectura del documento.

Formato

El documento se generará en formato pdf.

Entrega

Todo el material del módulo Proyecto (documentos, ficheros fuentes, herramientas...) se entregará en formato electrónico, en una carpeta comprimida:

ASIR-2 -SaaSphere